Detección de Anomalías

joseangeldiazg

19/2/2018

Datos

Vamos a trabajar con el dataset Seismic, que contiene informacion sobre medidas sísmicas. Trata de detectar el peligro sismico en función de ciertas característcas de medida y registros. Sus datos, en inglés, son:

- 1. seismic: result of shift seismic hazard assessment in the mine working obtained by the seismic method (a - lack of hazard, b - low hazard, c - high hazard, d - danger state);
- 2. seismoacoustic: result of shift seismic hazard assessment in the mine working obtained by the seismoacoustic method;
- 3. shift: information about type of a shift (W - coal-getting, N -preparation shift);
- 4. genergy: seismic energy recorded within previous shift by the most active geophone (GMax) out of geophones monitoring the longwall;
- 5. gpuls: a number of pulses recorded within previous shift by GMax;
- 6. gdenergy: a deviation of energy recorded within previous shift by GMax from average energy recordedduring eight previous shifts;
- 7. gdpuls: a deviation of a number of pulses recorded within previous shift by GMax from average number of pulses recorded during eight previous shifts;
- 8. ghazard: result of shift seismic hazard assessment in the mine working obtained by the seismoacoustic method based on registration coming form GMax only; - 9. nbumps: the number of seismic bumps recorded within previous shift;
- 10. nbumps2: the number of seismic bumps (in energy range $[10^{2,10}3)$) registered within previous shift;
- 11. nbumps3: the number of seismic bumps (in energy range $[10^{3,10}4)$) registered within previous shift;
- 12. nbumps4: the number of seismic bumps (in energy range $[10^{4,10}5)$) registered within previous shift;
- 13. nbumps5: the number of seismic bumps (in energy range $[10^{5,10}6)$) registered within the last shift;
- 14. nbumps6: the number of seismic bumps (in energy range $[10^{6,10}7)$) registered within previous shift;
- 15. nbumps7: the number of seismic bumps (in energy range $[10^{7,10}8)$) registered within previous shift;
- 16. nbumps89: the number of seismic bumps (in energy range $[10^{8,10}10)$) registered within previous shift;
- 17. energy: total energy of seismic bumps registered within previous shift;
- 18. maxenergy: the maximum energy of the seismic bumps registered within previous shift;
- 19. class: the decision attribute - '1' means that high energy seismic bump occurred in the next shift('hazardous state'), '0' means that no high energy seismic bumps occurred in the next shift ('non-hazardous state').

Los datos han sido recopilados del repositorio UCI y vienen en formato arrf.

```
library(foreign)
seismic<-read.arff("data/seismic-bumps.arff")
head(seismic,5)
```

```
##   seismic seismoacoustic shift genergy gpuls gdenergy gdpuls ghazard
## 1       a              a     N   15180    48      -72    -72       a
## 2       a              a     N   14720    33      -70    -79       a
## 3       a              a     N    8050    30      -81    -78       a
## 4       a              a     N   28820   171      -23     40       a
## 5       a              a     N   12640    57      -63    -52       a
##   nbumps nbumps2 nbumps3 nbumps4 nbumps5 nbumps6 nbumps7 nbumps89 energy
## 1      0       0       0       0       0       0       0        0      0
## 2      1       0       1       0       0       0       0        0   2000
## 3      0       0       0       0       0       0       0        0      0
## 4      1       0       1       0       0       0       0        0   3000
## 5      0       0       0       0       0       0       0        0      0
##   maxenergy class
## 1         0     0
## 2      2000     0
## 3         0     0
## 4      3000     0
## 5         0     0
```

```
str(seismic)
```

```
## 'data.frame':    2584 obs. of  19 variables:
##  $ seismic       : Factor w/ 2 levels "a","b": 1 1 1 1 1 1 1 1 1 1 ...
##  $ seismoacoustic: Factor w/ 3 levels "a","b","c": 1 1 1 1 1 1 1 1 1 1 ...
##  $ shift         : Factor w/ 2 levels "N","W": 1 1 1 1 1 2 2 1 1 2 ...
##  $ genergy       : num  15180 14720 8050 28820 12640 ...
##  $ gpuls         : num  48 33 30 171 57 195 614 194 303 675 ...
##  $ gdenergy      : num  -72 -70 -81 -23 -63 -73 -6 -27 54 4 ...
##  $ gdpuls        : num  -72 -79 -78 40 -52 -65 18 -3 52 25 ...
##  $ ghazard       : Factor w/ 3 levels "a","b","c": 1 1 1 1 1 1 1 1 1 1 ...
##  $ nbumps        : num  0 1 0 1 0 0 2 1 0 1 ...
##  $ nbumps2       : num  0 0 0 0 0 0 2 0 0 1 ...
##  $ nbumps3       : num  0 1 0 1 0 0 0 1 0 0 ...
##  $ nbumps4       : num  0 0 0 0 0 0 0 0 0 0 ...
##  $ nbumps5       : num  0 0 0 0 0 0 0 0 0 0 ...
##  $ nbumps6       : num  0 0 0 0 0 0 0 0 0 0 ...
##  $ nbumps7       : num  0 0 0 0 0 0 0 0 0 0 ...
##  $ nbumps89      : num  0 0 0 0 0 0 0 0 0 0 ...
##  $ energy        : num  0 2000 0 3000 0 0 1000 4000 0 500 ...
##  $ maxenergy     : num  0 2000 0 3000 0 0 700 4000 0 500 ...
##  $ class         : Factor w/ 2 levels "0","1": 1 1 1 1 1 1 1 1 1 1 ...
```

Para este análisis nos querdaremos con las variables numéricas, eliminando todas las demás de nuestros datos. Dado el caracter de las funciones que usaremos, ademas tendremos que definir un indice de columna y un nombre para los gráficos.

```
mydata.numeric  = seismic[,-c(1,2,3,8,19)]
indice.columna  = 1
nombre.mydata   = "seismic"
head(mydata.numeric,5)
```

```
##   genergy gpuls gdenergy gdpuls nbumps nbumps2 nbumps3 nbumps4 nbumps5
## 1   15180    48      -72    -72      0       0       0       0       0
## 2   14720    33      -70    -79      1       0       1       0       0
## 3    8050    30      -81    -78      0       0       0       0       0
## 4   28820   171      -23     40      1       0       1       0       0
```

```
## 5   12640    57      -63    -52      0       0       0       0       0
##   nbumps6 nbumps7 nbumps89 energy maxenergy
## 1       0       0        0      0         0
## 2       0       0        0   2000      2000
## 3       0       0        0      0         0
## 4       0       0        0   3000      3000
## 5       0       0        0      0         0
```

Por último para facilitar tambien procesos posteriores obtemeos los datos escalados:

```
mydata.numeric.scaled<-scale(mydata.numeric)
columna<-mydata.numeric[indice.columna]
nombre.columna<-names(columna)
columna.scaled<-mydata.numeric.scaled[,nombre.columna]
```

Análisis estadístico de Outliers en una variable mediante IQR

En esta primera parte se obtendrán los outliers de manera manual sin utilizar funciones. Para obtener estos, usaremos el IQR, o lo que es lo mismo la distancia intercuartil, es decir, necesitaremos obtener el primer cuartil, el tercer cuartil y la diferencia entre ambos.

```
cuartil.primero<-quantile(columna.scaled,0.25)
cuartil.primero
```

```
##        25%
## -0.3428549
```

```
cuartil.tercero<-quantile(columna.scaled,0.75)
cuartil.tercero
```

```
##        75%
## -0.1632196
```

```
iqr<-IQR(columna.scaled)
iqr
```

```
## [1] 0.1796353
```

Ahora debemos obtener los límites normales y extremops, que se calcularán de la siguiente manera:

- extremo.superior.outlier.normal = cuartil tercero + 1.5 IQR
- extremo.inferior.outlier.normal = cuartil primero - 1.5 IQR
- extremo.superior.outlier.extremo = cuartil tercero + 3 IQR
- extremo.inferior.outlier.extremo = cuartil primero - 3 IQR

```
extremo.superior.outlier.normal<-cuartil.tercero+1.5*iqr
extremo.inferior.outlier.normal<-cuartil.primero-1.5*iqr
extremo.superior.outlier.extremo<-cuartil.tercero+3*iqr
extremo.inferior.outlier.extremo<-cuartil.primero-3*iqr
```

Una vez tenemos todas estas variables, deberemos estudiar si hay outliers comparando la columna con el valor minimo y maximo de outliers normales y extremos.

Calculamos los **outliers normales**:

```
vector.es.outlier.normal<-columna.scaled>extremo.superior.outlier.normal | columna.scaled<extremo.infer
```

Calculamos los **outliers extremos**:

```
vector.es.outlier.extremo<-columna.scaled>extremo.superior.outlier.extremo | columna.scaled<extremo.inf
```

En base a los resultados obtenidos parece que estamos ante un problema con bastantes outliers, y dado que estos provienen de sensores sismicos, el problema es a la par complejo e interesante porque a muy seguro estos outliers, valores que se salen del las tablas por decirlo de alguna manera, indicarán o podrán indicar un riesgo de terremoto alto. Vamos a analizar estos outliers.

Índices y valores de los outliers

Vamos a obtener los indices de los outliers, para posteriormente mostrar todos sus datos.

Para los normales:

```
claves.outiers.normales<-which(vector.es.outlier.normal)
claves.outiers.normales
```

```
##   [1]    7   10   13   16   25   28   30   31   33   34   36   37   46   49
##  [15]   52   58   60   66   67   68   71   74   75   77   79   81   84   86
##  [29]   87   89   91   94   97  100  102  108  109  111  112  114  115  117
##  [43]  118  119  120  121  123  124  125  126  128  129  130  132  133  135
##  [57]  136  138  139  141  142  144  146  150  151  153  154  156  157  159
##  [71]  160  162  163  165  166  167  168  169  170  171  172  174  175  176
##  [85]  177  178  180  181  182  183  184  187  188  189  190  191  192  193
##  [99]  194  195  196  197  198  199  200  201  202  203  204  205  206  207
## [113]  208  209  210  211  212  213  214  215  216  217  218  219  220  221
## [127]  222  223  224  225  226  227  228  229  230  231  232  233  234  235
## [141]  236  237  238  239  240  241  242  243  244  245  246  247  248  249
## [155]  250  251  252  253  254  255  256  257  258  259  260  261  262  263
## [169]  264  265  266  267  268  269  270  271  272  273  274  275  276  277
## [183]  278  279  280  281  282  283  284  285  286  287  288  289  296  297
## [197]  298  299  300  301  302  303  304  305  306  307  308  309  310  314
## [211]  315  316  317  318  319  320  321  322  323  324  325  326  327  328
## [225]  329  330  331  335  336  337  338  339  340  341  342  343  344  345
## [239]  346  347  348  350  351  352  353  354  355  356  357  358  362  363
## [253]  364  365  381  384  387  390  391  392  393  399  558  665  666  672
## [267]  675  681  682  684  686  687  688  689  690  693  694  695  696  700
## [281]  702  703  704  705  706  707  708  713  714  715  716  717  718  719
## [295]  720  721  722  723  724  725  735  737  738  823  825  826  828  831
## [309]  843  844  846  847  849  850  852  853  854  855  861  862  864  865
## [323]  870  873  882  883  936  937 1692 2178 2180 2181 2211 2214
```

```
data.frame.outliers.normales<-data.frame(mydata.numeric[claves.outiers.normales,])
data.frame.outliers.normales
```

```
##      genergy gpuls gdenergy gdpuls nbumps nbumps2 nbumps3 nbumps4 nbumps5
## 7     207930   614       -6     18      2       2       0       0       0
## 10    247620   675        4     25      1       1       0       0       0
## 13    166180   448      -30    -19      1       1       0       0       0
## 16    225040   575       -3      5      2       0       2       0       0
## 25    424650  1069        1      7      2       0       2       0       0
## 28    212260   729      -50    -28      2       1       1       0       0
## 30    172290   437      -57    -55      1       1       0       0       0
## 31    395110  1043       46     40      3       0       3       0       0
## 33    144880   361      -46    -52      1       0       1       0       0
## 34    477750  1132       86     60      3       3       0       0       0
```

```
## 36    127360   351      -54    -53      1       1       0       0       0
## 37    514800  1369       95     94      7       4       2       1       0
## 46    250030   687       -8     -5      0       0       0       0       0
## 49    309010   983       15     38      2       1       1       0       0
## 52    248900   739       -9      0      1       1       0       0       0
## 58    269070   767       -1      4      2       2       0       0       0
## 60    372770   975       37     32      3       3       0       0       0
## 66    147520   472       -2     -6      0       0       0       0       0
## 67    202640   588      -33    -41      2       1       1       0       0
## 68    259110  1409      -11     46      1       1       0       0       0
## 71    590510  1780       23     -6      1       1       0       0       0
## 74    317360  1068      -36    -44      0       0       0       0       0
## 75    227990   734      -52    -59      2       1       1       0       0
## 77    210960   773      -44    -35      1       0       1       0       0
## 79    302440  1250      -16      9      2       2       0       0       0
## 81    436650  1232       23      6      0       0       0       0       0
## 84    169370   644      -53    -45      0       0       0       0       0
## 86    233810   839      -31    -24      0       0       0       0       0
## 87    149050   697      -54    -35      1       0       1       0       0
## 89    194580   697      -35    -32      0       0       0       0       0
## 91    194580   697      -35    -32      0       0       0       0       0
## 94    285750   791        1    -19      0       0       0       0       0
## 97    298230   916        9     -2      0       0       0       0       0
## 100   172120   537      -35    -41      0       0       0       0       0
## 102   270040   717       10    -14      2       2       0       0       0
## 108   166700   363      -34    -56      0       0       0       0       0
## 109   274170   997       15     34      0       0       0       0       0
## 111   226790   717        2      0      0       0       0       0       0
## 112   134640   611      -41    -16      0       0       0       0       0
## 114   328050   707       51      0      1       1       0       0       0
## 115   140090   380      -40    -46      0       0       0       0       0
## 117   157740   440      -31    -35      0       0       0       0       0
## 118   325750  1068       50     67      1       0       1       0       0
## 119   300520   894       37     37      0       0       0       0       0
## 120   465730  1325       -7    -12      1       0       1       0       0
## 121   336600   984      -32    -34      1       0       1       0       0
## 123   951410  1332       98     -7      0       0       0       0       0
## 124   203850   476      -14    -32      1       0       1       0       0
## 125   715390  1923       36     36      1       1       0       0       0
## 126   160350   828      -31     23      0       0       0       0       0
## 128   373180  1246      -32    -14      1       0       1       0       0
## 129   481630  1678      -10     17      0       0       0       0       0
## 130   620720  1789       17     23      0       0       0       0       0
## 132   280830   689       94     39      1       0       1       0       0
## 133   557230  1642        2     11      0       0       0       0       0
## 135   270490   865       83     78      0       0       0       0       0
## 136   307540  1020      -44    -32      0       0       0       0       0
## 138   314100   904      -41    -37      0       0       0       0       0
## 139   368340  1325      -28     -4      1       0       1       0       0
## 141   316200  1089      -37    -21      3       1       2       0       0
## 142   209760   919       46     89      0       0       0       0       0
## 144   372380  1264      -26     -9      0       0       0       0       0
## 146   396530  1209      -10    -13      1       0       1       0       0
## 150   303610  1034      -26    -21      0       0       0       0       0
```

```
## 151   278230  1060      -31    -18      1       1       0       0       0
## 153   498960  1447       30     17      1       1       0       0       0
## 154   443740  1321       20     10      0       0       0       0       0
## 156   788230  1484       -1     -1      0       0       0       0       0
## 157   119460   269      -70    -64      0       0       0       0       0
## 159  1049580  1807       31     21      0       0       0       0       0
## 160   715540  1471      -13     -4      2       2       0       0       0
##      nbumps6 nbumps7 nbumps89 energy maxenergy
## 7          0       0        0   1000     7e+02
## 10         0       0        0    500     5e+02
## 13         0       0        0    400     4e+02
## 16         0       0        0   7000     6e+03
## 25         0       0        0   6000     4e+03
## 28         0       0        0   1400     1e+03
## 30         0       0        0    600     6e+02
## 31         0       0        0   6000     2e+03
## 33         0       0        0   2000     2e+03
## 34         0       0        0   1500     6e+02
## 36         0       0        0    700     7e+02
## 37         0       0        0  15700     1e+04
## 46         0       0        0      0     0e+00
## 49         0       0        0   1800     1e+03
## 52         0       0        0    400     4e+02
## 58         0       0        0    800     4e+02
## 60         0       0        0   1400     7e+02
## 66         0       0        0      0     0e+00
## 67         0       0        0   4300     4e+03
## 68         0       0        0    900     9e+02
## 71         0       0        0    800     8e+02
## 74         0       0        0      0     0e+00
## 75         0       0        0   4300     4e+03
## 77         0       0        0   5000     5e+03
## 79         0       0        0    600     3e+02
## 81         0       0        0      0     0e+00
## 84         0       0        0      0     0e+00
## 86         0       0        0      0     0e+00
## 87         0       0        0   6000     6e+03
## 89         0       0        0      0     0e+00
## 91         0       0        0      0     0e+00
## 94         0       0        0      0     0e+00
## 97         0       0        0      0     0e+00
## 100        0       0        0      0     0e+00
## 102        0       0        0    800     5e+02
## 108        0       0        0      0     0e+00
## 109        0       0        0      0     0e+00
## 111        0       0        0      0     0e+00
## 112        0       0        0      0     0e+00
## 114        0       0        0    200     2e+02
## 115        0       0        0      0     0e+00
## 117        0       0        0      0     0e+00
## 118        0       0        0   3000     3e+03
## 119        0       0        0      0     0e+00
## 120        0       0        0   4000     4e+03
## 121        0       0        0   4000     4e+03
```

```
## 123        0       0        0      0     0e+00
## 124        0       0        0   3000     3e+03
## 125        0       0        0    300     3e+02
## 126        0       0        0      0     0e+00
## 128        0       0        0   2000     2e+03
## 129        0       0        0      0     0e+00
## 130        0       0        0      0     0e+00
## 132        0       0        0   3000     3e+03
## 133        0       0        0      0     0e+00
## 135        0       0        0      0     0e+00
## 136        0       0        0      0     0e+00
## 138        0       0        0      0     0e+00
## 139        0       0        0   2000     2e+03
## 141        0       0        0   2700     1e+03
## 142        0       0        0      0     0e+00
## 144        0       0        0      0     0e+00
## 146        0       0        0   6000     6e+03
## 150        0       0        0      0     0e+00
## 151        0       0        0    900     9e+02
## 153        0       0        0    900     9e+02
## 154        0       0        0      0     0e+00
## 156        0       0        0      0     0e+00
## 157        0       0        0      0     0e+00
## 159        0       0        0      0     0e+00
## 160        0       0        0    900     6e+02
##  [ reached getOption("max.print") -- omitted 263 rows ]
```

```
nombres.outliers.normales <- row.names(data.frame.outliers.normales)
nombres.outliers.normales
```

```
##   [1] "7"    "10"   "13"   "16"   "25"   "28"   "30"   "31"   "33"   "34"
##  [11] "36"   "37"   "46"   "49"   "52"   "58"   "60"   "66"   "67"   "68"
##  [21] "71"   "74"   "75"   "77"   "79"   "81"   "84"   "86"   "87"   "89"
##  [31] "91"   "94"   "97"   "100"  "102"  "108"  "109"  "111"  "112"  "114"
##  [41] "115"  "117"  "118"  "119"  "120"  "121"  "123"  "124"  "125"  "126"
##  [51] "128"  "129"  "130"  "132"  "133"  "135"  "136"  "138"  "139"  "141"
##  [61] "142"  "144"  "146"  "150"  "151"  "153"  "154"  "156"  "157"  "159"
##  [71] "160"  "162"  "163"  "165"  "166"  "167"  "168"  "169"  "170"  "171"
##  [81] "172"  "174"  "175"  "176"  "177"  "178"  "180"  "181"  "182"  "183"
##  [91] "184"  "187"  "188"  "189"  "190"  "191"  "192"  "193"  "194"  "195"
## [101] "196"  "197"  "198"  "199"  "200"  "201"  "202"  "203"  "204"  "205"
## [111] "206"  "207"  "208"  "209"  "210"  "211"  "212"  "213"  "214"  "215"
## [121] "216"  "217"  "218"  "219"  "220"  "221"  "222"  "223"  "224"  "225"
## [131] "226"  "227"  "228"  "229"  "230"  "231"  "232"  "233"  "234"  "235"
## [141] "236"  "237"  "238"  "239"  "240"  "241"  "242"  "243"  "244"  "245"
## [151] "246"  "247"  "248"  "249"  "250"  "251"  "252"  "253"  "254"  "255"
## [161] "256"  "257"  "258"  "259"  "260"  "261"  "262"  "263"  "264"  "265"
## [171] "266"  "267"  "268"  "269"  "270"  "271"  "272"  "273"  "274"  "275"
## [181] "276"  "277"  "278"  "279"  "280"  "281"  "282"  "283"  "284"  "285"
## [191] "286"  "287"  "288"  "289"  "296"  "297"  "298"  "299"  "300"  "301"
## [201] "302"  "303"  "304"  "305"  "306"  "307"  "308"  "309"  "310"  "314"
## [211] "315"  "316"  "317"  "318"  "319"  "320"  "321"  "322"  "323"  "324"
## [221] "325"  "326"  "327"  "328"  "329"  "330"  "331"  "335"  "336"  "337"
## [231] "338"  "339"  "340"  "341"  "342"  "343"  "344"  "345"  "346"  "347"
## [241] "348"  "350"  "351"  "352"  "353"  "354"  "355"  "356"  "357"  "358"
```

```
## [251] "362"  "363"  "364"  "365"  "381"  "384"  "387"  "390"  "391"  "392"
## [261] "393"  "399"  "558"  "665"  "666"  "672"  "675"  "681"  "682"  "684"
## [271] "686"  "687"  "688"  "689"  "690"  "693"  "694"  "695"  "696"  "700"
## [281] "702"  "703"  "704"  "705"  "706"  "707"  "708"  "713"  "714"  "715"
## [291] "716"  "717"  "718"  "719"  "720"  "721"  "722"  "723"  "724"  "725"
## [301] "735"  "737"  "738"  "823"  "825"  "826"  "828"  "831"  "843"  "844"
## [311] "846"  "847"  "849"  "850"  "852"  "853"  "854"  "855"  "861"  "862"
## [321] "864"  "865"  "870"  "873"  "882"  "883"  "936"  "937"  "1692" "2178"
## [331] "2180" "2181" "2211" "2214"
```

```
valores.outliers.normales <- mydata.numeric[claves.outiers.normales,indice.columna]
valores.outliers.normales
```

```
##   [1]  207930  247620  166180  225040  424650  212260  172290  395110
##   [9]  144880  477750  127360  514800  250030  309010  248900  269070
##  [17]  372770  147520  202640  259110  590510  317360  227990  210960
##  [25]  302440  436650  169370  233810  149050  194580  194580  285750
##  [33]  298230  172120  270040  166700  274170  226790  134640  328050
##  [41]  140090  157740  325750  300520  465730  336600  951410  203850
##  [49]  715390  160350  373180  481630  620720  280830  557230  270490
##  [57]  307540  314100  368340  316200  209760  372380  396530  303610
##  [65]  278230  498960  443740  788230  119460 1049580  715540  974430
##  [73]  696470 1124850  640820 1096910  155540  722590  582700  691310
##  [81]  698810  716630  641120  384230  790830  390180  936850  432690
##  [89]  441960  912890  446210  117040  414700  960770  763520  541040
##  [97] 1127430  664090  320150  768080  474770  682910 1256570  576040
## [105]  782750 1371400  891720 1034700 2129020 1547010  924910 1988970
## [113]  218630 1018360 1189240 1582550  927530 2052510 1260100 1062280
## [121] 2196220 1138340  918020 1766860 1699290  301550 1355970 2595650
## [129] 2160800 1367850  251120  157450  129740  144520 1345240 2102300
## [137]  219070  628360 1449990 1531530  195510 1312110  315650 1061760
## [145] 1283710 1134540  525630 1661100 1310730 1101540 1496830 1323740
## [153]  943300  348780  154420 1514120 1811640 1446770 1132810 1367690
## [161]  814170  600400  886800  588930  542890 1104700  734930  509190
## [169]  480250  428740  450060  627380  448900  453850  779850  146840
## [177]  675030  811060  538060  372470  439210  286300  576200  833250
## [185]  836500  571990  754760  834760  450490  932410  568200  452730
## [193]  833660  131820  447360  993080  593950  570400  788650  383490
## [201]  415690  645750  649840  380320  401730  459160  285990  557510
## [209]  536260  498400  342050  434360  366500  507230  388530  329680
## [217]  579440  292040  261010  394660  464220  393140  742750  820600
## [225]  289580  577770  347400  268170  632800  332180  172250  256850
## [233]  199030  192650  320110  233800  206610  244480  430310  311200
## [241]  478520  379670  887140  690550  397280  609620  136810  358490
## [249]  581540  545470  532290  511560  546980  155980  189840  122850
## [257]  151660  122640  176830  122410  184710  127770  150220  122820
## [265]  132520  118860  182210  154830  121720  190960  133430  253510
## [273]  121870  148160  156780  127110  163510  134890  306400  128260
## [281]  186280  195950  117120  273200  121400  200350  130940  166220
## [289]  265250  162190  127010  229070  167100  132470  254750  151210
## [297]  118110  118120  185910  197590  134870  159910  172530  145440
## [305]  239660  229690  197620  179710  178220  121520  254510  180530
## [313]  362360  140610  211440  189170  232470  240350  147570  140890
## [321]  122030  154470  120690  161390  129190  125340  147400  175660
## [329]  135210  134070  124380  162810  151920  124850
```

Para los extremos:

```
claves.outiers.extremo<-which(vector.es.outlier.extremo)
claves.outiers.extremo
```

```
##   [1]   7  10  16  25  28  31  34  37  46  49  52  58  60  67  68  71  74
##  [18]  75  77  79  81  86  89  91  94  97 102 109 111 114 118 119 120 121
##  [35] 123 124 125 128 129 130 132 133 135 136 138 139 141 142 144 146 150
##  [52] 151 153 154 156 159 160 162 163 165 166 167 169 170 171 172 174 175
##  [69] 176 177 178 180 181 182 183 184 188 189 190 191 192 193 194 195 196
##  [86] 197 198 199 200 201 202 203 204 205 206 207 208 209 210 211 212 213
## [103] 214 215 216 217 218 219 220 221 222 223 224 225 226 230 231 232 233
## [120] 234 235 236 237 238 239 240 241 242 243 244 245 246 247 248 249 251
## [137] 252 253 254 255 256 257 258 259 260 261 262 263 264 265 266 267 268
## [154] 269 270 272 273 274 275 276 277 278 279 280 281 282 283 284 285 286
## [171] 287 288 296 297 298 299 300 301 302 303 304 305 306 307 308 309 310
## [188] 314 315 316 317 318 319 320 321 322 323 324 325 326 327 328 329 330
## [205] 331 335 336 337 339 340 341 342 343 344 345 346 347 348 350 351 352
## [222] 353 354 356 357 358 362 363 364 381 391 393 675 684 687 696 702 703
## [239] 705 707 714 717 720 724 725 825 826 828 831 843 846 847 849 852 853
## [256] 854 855
```

```
data.frame.outliers.extremo<-data.frame(mydata.numeric[claves.outiers.extremo,])
data.frame.outliers.extremo
```

```
##     genergy gpuls gdenergy gdpuls nbumps nbumps2 nbumps3 nbumps4 nbumps5
## 7    207930   614       -6     18      2       2       0       0       0
## 10   247620   675        4     25      1       1       0       0       0
## 16   225040   575       -3      5      2       0       2       0       0
## 25   424650  1069        1      7      2       0       2       0       0
## 28   212260   729      -50    -28      2       1       1       0       0
## 31   395110  1043       46     40      3       0       3       0       0
## 34   477750  1132       86     60      3       3       0       0       0
## 37   514800  1369       95     94      7       4       2       1       0
## 46   250030   687       -8     -5      0       0       0       0       0
## 49   309010   983       15     38      2       1       1       0       0
## 52   248900   739       -9      0      1       1       0       0       0
## 58   269070   767       -1      4      2       2       0       0       0
## 60   372770   975       37     32      3       3       0       0       0
## 67   202640   588      -33    -41      2       1       1       0       0
## 68   259110  1409      -11     46      1       1       0       0       0
## 71   590510  1780       23     -6      1       1       0       0       0
## 74   317360  1068      -36    -44      0       0       0       0       0
## 75   227990   734      -52    -59      2       1       1       0       0
## 77   210960   773      -44    -35      1       0       1       0       0
## 79   302440  1250      -16      9      2       2       0       0       0
## 81   436650  1232       23      6      0       0       0       0       0
## 86   233810   839      -31    -24      0       0       0       0       0
## 89   194580   697      -35    -32      0       0       0       0       0
## 91   194580   697      -35    -32      0       0       0       0       0
## 94   285750   791        1    -19      0       0       0       0       0
## 97   298230   916        9     -2      0       0       0       0       0
## 102  270040   717       10    -14      2       2       0       0       0
## 109  274170   997       15     34      0       0       0       0       0
## 111  226790   717        2      0      0       0       0       0       0
## 114  328050   707       51      0      1       1       0       0       0
```

```
## 118  325750  1068       50     67      1       0       1       0       0
## 119  300520   894       37     37      0       0       0       0       0
## 120  465730  1325       -7    -12      1       0       1       0       0
## 121  336600   984      -32    -34      1       0       1       0       0
## 123  951410  1332       98     -7      0       0       0       0       0
## 124  203850   476      -14    -32      1       0       1       0       0
## 125  715390  1923       36     36      1       1       0       0       0
## 128  373180  1246      -32    -14      1       0       1       0       0
## 129  481630  1678      -10     17      0       0       0       0       0
## 130  620720  1789       17     23      0       0       0       0       0
## 132  280830   689       94     39      1       0       1       0       0
## 133  557230  1642        2     11      0       0       0       0       0
## 135  270490   865       83     78      0       0       0       0       0
## 136  307540  1020      -44    -32      0       0       0       0       0
## 138  314100   904      -41    -37      0       0       0       0       0
## 139  368340  1325      -28     -4      1       0       1       0       0
## 141  316200  1089      -37    -21      3       1       2       0       0
## 142  209760   919       46     89      0       0       0       0       0
## 144  372380  1264      -26     -9      0       0       0       0       0
## 146  396530  1209      -10    -13      1       0       1       0       0
## 150  303610  1034      -26    -21      0       0       0       0       0
## 151  278230  1060      -31    -18      1       1       0       0       0
## 153  498960  1447       30     17      1       1       0       0       0
## 154  443740  1321       20     10      0       0       0       0       0
## 156  788230  1484       -1     -1      0       0       0       0       0
## 159 1049580  1807       31     21      0       0       0       0       0
## 160  715540  1471      -13     -4      2       2       0       0       0
## 162  974430  1828       20     20      2       1       0       1       0
## 163  696470  1368      -16    -12      2       1       1       0       0
## 165 1124850  2153       37     39      3       1       2       0       0
## 166  640820  1235      -25    -23      1       0       1       0       0
## 167 1096910  2037       31     29      2       1       1       0       0
## 169  722590  2125      -17     30      2       0       2       0       0
## 170  582700  1232      -32    -28      1       0       1       0       0
## 171  691310  1416      -14     -6      0       0       0       0       0
## 172  698810  1279      -11    -14      3       0       3       0       0
## 174  716630  1677       -8     14      2       2       0       0       0
## 175  641120  1571      -17      6      1       1       0       0       0
## 176  384230   751        4      6      3       1       2       0       0
## 177  790830  1434        5     -4      2       0       1       1       0
## 178  390180   938        6     33      0       0       0       0       0
##     nbumps6 nbumps7 nbumps89 energy maxenergy
## 7         0       0        0   1000       700
## 10        0       0        0    500       500
## 16        0       0        0   7000      6000
## 25        0       0        0   6000      4000
## 28        0       0        0   1400      1000
## 31        0       0        0   6000      2000
## 34        0       0        0   1500       600
## 37        0       0        0  15700     10000
## 46        0       0        0      0         0
## 49        0       0        0   1800      1000
## 52        0       0        0    400       400
## 58        0       0        0    800       400
```

```
## 60        0        0        0   1400        700
## 67        0        0        0   4300       4000
## 68        0        0        0    900        900
## 71        0        0        0    800        800
## 74        0        0        0      0          0
## 75        0        0        0   4300       4000
## 77        0        0        0   5000       5000
## 79        0        0        0    600        300
## 81        0        0        0      0          0
## 86        0        0        0      0          0
## 89        0        0        0      0          0
## 91        0        0        0      0          0
## 94        0        0        0      0          0
## 97        0        0        0      0          0
## 102       0        0        0    800        500
## 109       0        0        0      0          0
## 111       0        0        0      0          0
## 114       0        0        0    200        200
## 118       0        0        0   3000       3000
## 119       0        0        0      0          0
## 120       0        0        0   4000       4000
## 121       0        0        0   4000       4000
## 123       0        0        0      0          0
## 124       0        0        0   3000       3000
## 125       0        0        0    300        300
## 128       0        0        0   2000       2000
## 129       0        0        0      0          0
## 130       0        0        0      0          0
## 132       0        0        0   3000       3000
## 133       0        0        0      0          0
## 135       0        0        0      0          0
## 136       0        0        0      0          0
## 138       0        0        0      0          0
## 139       0        0        0   2000       2000
## 141       0        0        0   2700       1000
## 142       0        0        0      0          0
## 144       0        0        0      0          0
## 146       0        0        0   6000       6000
## 150       0        0        0      0          0
## 151       0        0        0    900        900
## 153       0        0        0    900        900
## 154       0        0        0      0          0
## 156       0        0        0      0          0
## 159       0        0        0      0          0
## 160       0        0        0    900        600
## 162       0        0        0  20600      20000
## 163       0        0        0   2400       2000
## 165       0        0        0   3900       2000
## 166       0        0        0   5000       5000
## 167       0        0        0   3700       3000
## 169       0        0        0   5000       4000
## 170       0        0        0   7000       7000
## 171       0        0        0      0          0
## 172       0        0        0   8000       4000
```

```
## 174       0       0        0    700       500
## 175       0       0        0    800       800
## 176       0       0        0   9700      6000
## 177       0       0        0  13000     10000
## 178       0       0        0      0         0
##  [ reached getOption("max.print") -- omitted 186 rows ]
```

```
nombres.outliers.extremo <- row.names(data.frame.outliers.extremo)
nombres.outliers.extremo
```

```
##   [1] "7"   "10"  "16"  "25"  "28"  "31"  "34"  "37"  "46"  "49"  "52"
##  [12] "58"  "60"  "67"  "68"  "71"  "74"  "75"  "77"  "79"  "81"  "86"
##  [23] "89"  "91"  "94"  "97"  "102" "109" "111" "114" "118" "119" "120"
##  [34] "121" "123" "124" "125" "128" "129" "130" "132" "133" "135" "136"
##  [45] "138" "139" "141" "142" "144" "146" "150" "151" "153" "154" "156"
##  [56] "159" "160" "162" "163" "165" "166" "167" "169" "170" "171" "172"
##  [67] "174" "175" "176" "177" "178" "180" "181" "182" "183" "184" "188"
##  [78] "189" "190" "191" "192" "193" "194" "195" "196" "197" "198" "199"
##  [89] "200" "201" "202" "203" "204" "205" "206" "207" "208" "209" "210"
## [100] "211" "212" "213" "214" "215" "216" "217" "218" "219" "220" "221"
## [111] "222" "223" "224" "225" "226" "230" "231" "232" "233" "234" "235"
## [122] "236" "237" "238" "239" "240" "241" "242" "243" "244" "245" "246"
## [133] "247" "248" "249" "251" "252" "253" "254" "255" "256" "257" "258"
## [144] "259" "260" "261" "262" "263" "264" "265" "266" "267" "268" "269"
## [155] "270" "272" "273" "274" "275" "276" "277" "278" "279" "280" "281"
## [166] "282" "283" "284" "285" "286" "287" "288" "296" "297" "298" "299"
## [177] "300" "301" "302" "303" "304" "305" "306" "307" "308" "309" "310"
## [188] "314" "315" "316" "317" "318" "319" "320" "321" "322" "323" "324"
## [199] "325" "326" "327" "328" "329" "330" "331" "335" "336" "337" "339"
## [210] "340" "341" "342" "343" "344" "345" "346" "347" "348" "350" "351"
## [221] "352" "353" "354" "356" "357" "358" "362" "363" "364" "381" "391"
## [232] "393" "675" "684" "687" "696" "702" "703" "705" "707" "714" "717"
## [243] "720" "724" "725" "825" "826" "828" "831" "843" "846" "847" "849"
## [254] "852" "853" "854" "855"
```

```
valores.outliers.extremo <- mydata.numeric[claves.outiers.extremo,indice.columna]
valores.outliers.extremo
```

```
##   [1]  207930  247620  225040  424650  212260  395110  477750  514800
##   [9]  250030  309010  248900  269070  372770  202640  259110  590510
##  [17]  317360  227990  210960  302440  436650  233810  194580  194580
##  [25]  285750  298230  270040  274170  226790  328050  325750  300520
##  [33]  465730  336600  951410  203850  715390  373180  481630  620720
##  [41]  280830  557230  270490  307540  314100  368340  316200  209760
##  [49]  372380  396530  303610  278230  498960  443740  788230 1049580
##  [57]  715540  974430  696470 1124850  640820 1096910  722590  582700
##  [65]  691310  698810  716630  641120  384230  790830  390180  936850
##  [73]  432690  441960  912890  446210  414700  960770  763520  541040
##  [81] 1127430  664090  320150  768080  474770  682910 1256570  576040
##  [89]  782750 1371400  891720 1034700 2129020 1547010  924910 1988970
##  [97]  218630 1018360 1189240 1582550  927530 2052510 1260100 1062280
## [105] 2196220 1138340  918020 1766860 1699290  301550 1355970 2595650
## [113] 2160800 1367850  251120 1345240 2102300  219070  628360 1449990
## [121] 1531530  195510 1312110  315650 1061760 1283710 1134540  525630
## [129] 1661100 1310730 1101540 1496830 1323740  943300  348780 1514120
## [137] 1811640 1446770 1132810 1367690  814170  600400  886800  588930
```

```
## [145]  542890 1104700  734930  509190  480250  428740  450060  627380
## [153]  448900  453850  779850  675030  811060  538060  372470  439210
## [161]  286300  576200  833250  836500  571990  754760  834760  450490
## [169]  932410  568200  452730  833660  447360  993080  593950  570400
## [177]  788650  383490  415690  645750  649840  380320  401730  459160
## [185]  285990  557510  536260  498400  342050  434360  366500  507230
## [193]  388530  329680  579440  292040  261010  394660  464220  393140
## [201]  742750  820600  289580  577770  347400  268170  632800  332180
## [209]  256850  199030  192650  320110  233800  206610  244480  430310
## [217]  311200  478520  379670  887140  690550  397280  609620  358490
## [225]  581540  545470  532290  511560  546980  189840  176830  184710
## [233]  182210  190960  253510  306400  186280  195950  273200  200350
## [241]  265250  229070  254750  185910  197590  239660  229690  197620
## [249]  179710  178220  254510  180530  362360  211440  189170  232470
## [257]  240350
```

Tenemos un total de 257 outliers extremos y 334 outliers normales, y esto solo en la variable genergy por lo que a muy probablemente el número de outliers aumente.

Desviación de los outliers con respecto a la media de la columna

Por último, obtendremos los valores de los outliers pero para la columna normalizada.

```
valores.normalizados.outliers.normales<-columna.scaled[claves.outiers.normales]
valores.normalizados.outliers.extremo<-columna.scaled[claves.outiers.extremo]
```

Plot

Por último usaremos un gráfico para ver estos outliers para ello, llamamos a la siguiente función:

MiPlot_Univariate_Outliers (columna de datos, indices -claves numéricas- de outliers , nombre de columna)

```
MiPlot_Univariate_Outliers(columna,claves.outiers.normales,nombre.columna)
```

```
##
## N?mero de datos: 2584
## ?Qui?n es outlier?: FALSE FALSE FALSE FALSE FALSE FALSE TRUE FALSE FALSE TRUE FALSE FALSE TRUE FALSE
```

```
MiPlot_Univariate_Outliers(columna,claves.outiers.extremo,nombre.columna)
```

```
##
## N?mero de datos: 2584
## ?Qui?n es outlier?: FALSE FALSE FALSE FALSE FALSE FALSE TRUE FALSE FALSE TRUE FALSE FALSE FALSE FALSE
```

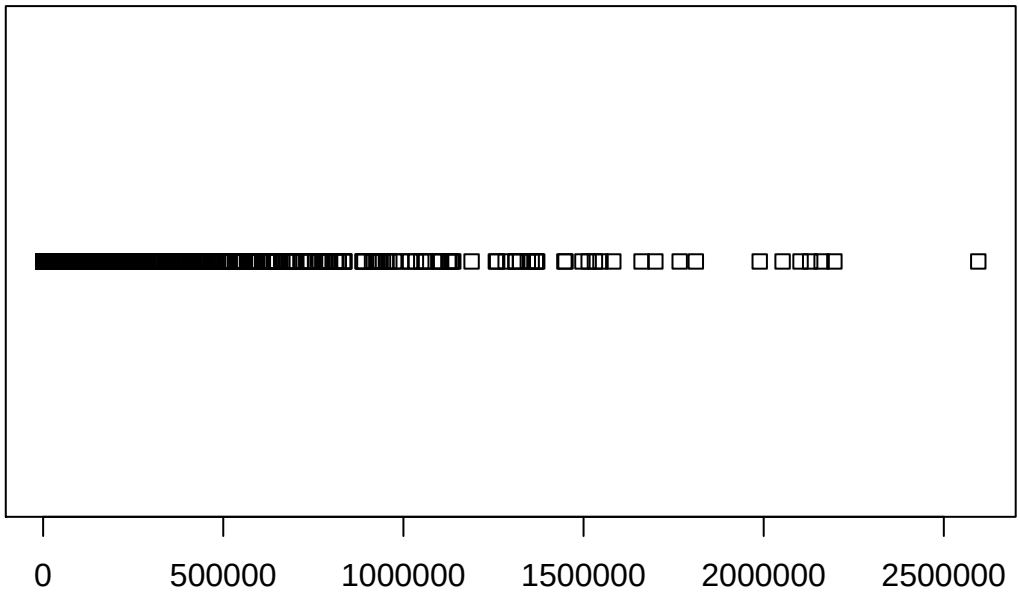

Podemos ver que los outliers son muy abundantes y serán outliers por encima, esto era de esperar ya que al tratarse de datos físicos lo normal en muchos casos más al tratarse de energia son valores constantes o que varían muy poco, excepto cuando como en este caso se de el caso de una gran cantidad de energia liberada, con la que obtendremos outliers por encima.

BoxPlot

Vamos a utilizar un boxplot para ver estos outliers, para ello usarmeos la función:

MiBoxPlot_IQR_Univariate_Outliers = function (datos, indice.de.columna, coef = 1.5)

```
MiBoxPlot_IQR_Univariate_Outliers(mydata.numeric.scaled,indice.columna, coef = 1.5)
```

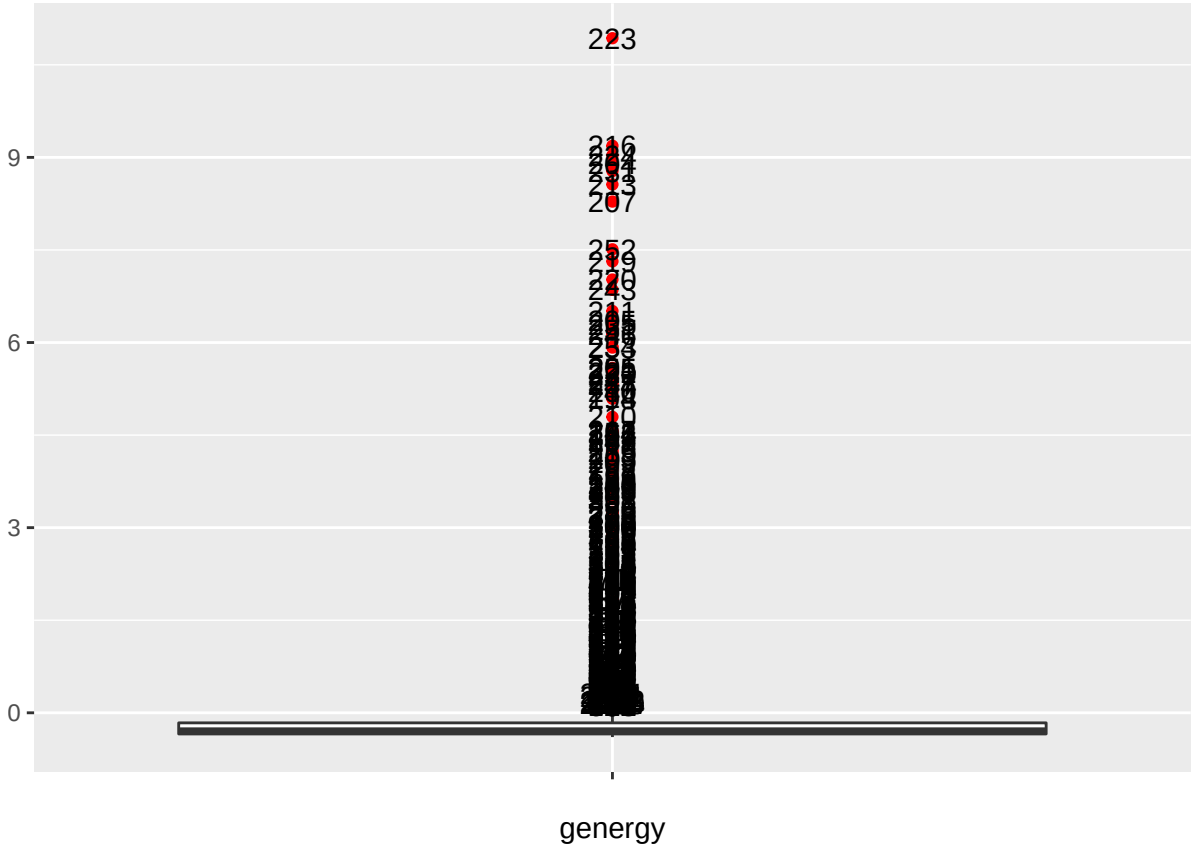

Al representar encima los valores o nombres de los outliers el gráfico se emborrona, por lo que podremos usar boxplot nativo sobre todos los datos para ver mejor estos outliers:

```
boxplot(mydata.numeric.scaled)
```

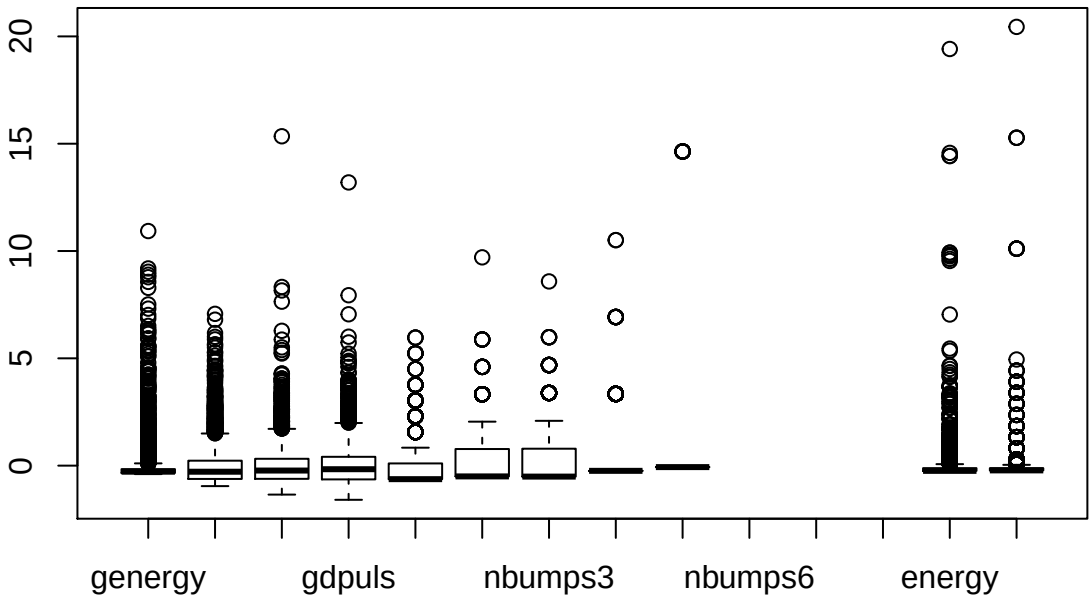

Vemos que la presencia de outliers es muy fuerte en todo el dataset, y como predejimos, estos vienen dados por encima en la mayoria de los casos teniendo medianas muy bajas y constantes lo que indica la estabilidad de los datos durante todas las medidas.

Cómputo de los outliers IQR con funciones propias

En este punto realizaremos el estudio IQR de los datos, pero usando funciones propias:

```
vector_outliers<-vector_es_outlier_IQR(mydata.numeric, indice.columna)
vector_claves_outliers<-vector_claves_outliers_IQR(mydata.numeric, indice.columna)
```

Trabajamos con varias columnas simultáneamente

Lo interesante de usar estas funciones, reside en la obtención de los outliers en las distintas columnas. Aunque el análisis es aún centrandonos en una sola variable, podremos vamos a obtener todos los outliers usando la función:

vector_claves_outliers_IQR_en_alguna_columna = function(datos, coef = 1.5)

```
indices.de.outliers.en.alguna.columna<-vector_claves_outliers_IQR_en_alguna_columna(mydata.numeric)
```

Esta variable contiene los índices de aquellos registros que tienen un valor anómalo con respecto a alguna columna. Si mostramos los datos normalizados de dichos registros, debe salir lo siguiente:

```
mydata.numeric[indices.de.outliers.en.alguna.columna,]
```

```
##        genergy gpuls gdenergy gdpuls nbumps nbumps2 nbumps3 nbumps4
## 7       207930   614       -6     18      2       2       0       0
## 10      247620   675        4     25      1       1       0       0
## 13      166180   448      -30    -19      1       1       0       0
## 16      225040   575       -3      5      2       0       2       0
## 25      424650  1069        1      7      2       0       2       0
## 28      212260   729      -50    -28      2       1       1       0
## 30      172290   437      -57    -55      1       1       0       0
## 31      395110  1043       46     40      3       0       3       0
## 33      144880   361      -46    -52      1       0       1       0
## 34      477750  1132       86     60      3       3       0       0
## 36      127360   351      -54    -53      1       1       0       0
## 37      514800  1369       95     94      7       4       2       1
## 46      250030   687       -8     -5      0       0       0       0
## 49      309010   983       15     38      2       1       1       0
## 52      248900   739       -9      0      1       1       0       0
## 58      269070   767       -1      4      2       2       0       0
## 60      372770   975       37     32      3       3       0       0
## 66      147520   472       -2     -6      0       0       0       0
## 67      202640   588      -33    -41      2       1       1       0
## 68      259110  1409      -11     46      1       1       0       0
## 71      590510  1780       23     -6      1       1       0       0
## 74      317360  1068      -36    -44      0       0       0       0
## 75      227990   734      -52    -59      2       1       1       0
## 77      210960   773      -44    -35      1       0       1       0
## 79      302440  1250      -16      9      2       2       0       0
## 81      436650  1232       23      6      0       0       0       0
## 84      169370   644      -53    -45      0       0       0       0
## 86      233810   839      -31    -24      0       0       0       0
## 87      149050   697      -54    -35      1       0       1       0
## 89      194580   697      -35    -32      0       0       0       0
## 91      194580   697      -35    -32      0       0       0       0
## 94      285750   791        1    -19      0       0       0       0
```

```
## 97      298230   916        9     -2      0       0       0       0
## 100     172120   537      -35    -41      0       0       0       0
## 102     270040   717       10    -14      2       2       0       0
## 108     166700   363      -34    -56      0       0       0       0
## 109     274170   997       15     34      0       0       0       0
## 111     226790   717        2      0      0       0       0       0
## 112     134640   611      -41    -16      0       0       0       0
## 114     328050   707       51      0      1       1       0       0
## 115     140090   380      -40    -46      0       0       0       0
## 117     157740   440      -31    -35      0       0       0       0
## 118     325750  1068       50     67      1       0       1       0
## 119     300520   894       37     37      0       0       0       0
## 120     465730  1325       -7    -12      1       0       1       0
## 121     336600   984      -32    -34      1       0       1       0
## 123     951410  1332       98     -7      0       0       0       0
## 124     203850   476      -14    -32      1       0       1       0
## 125     715390  1923       36     36      1       1       0       0
## 126     160350   828      -31     23      0       0       0       0
## 128     373180  1246      -32    -14      1       0       1       0
## 129     481630  1678      -10     17      0       0       0       0
## 130     620720  1789       17     23      0       0       0       0
## 132     280830   689       94     39      1       0       1       0
## 133     557230  1642        2     11      0       0       0       0
## 135     270490   865       83     78      0       0       0       0
## 136     307540  1020      -44    -32      0       0       0       0
## 138     314100   904      -41    -37      0       0       0       0
## 139     368340  1325      -28     -4      1       0       1       0
## 141     316200  1089      -37    -21      3       1       2       0
## 142     209760   919       46     89      0       0       0       0
## 144     372380  1264      -26     -9      0       0       0       0
## 146     396530  1209      -10    -13      1       0       1       0
## 150     303610  1034      -26    -21      0       0       0       0
## 151     278230  1060      -31    -18      1       1       0       0
## 153     498960  1447       30     17      1       1       0       0
## 154     443740  1321       20     10      0       0       0       0
## 156     788230  1484       -1     -1      0       0       0       0
## 157     119460   269      -70    -64      0       0       0       0
## 159    1049580  1807       31     21      0       0       0       0
## 160     715540  1471      -13     -4      2       2       0       0
##        nbumps5 nbumps6 nbumps7 nbumps89 energy maxenergy
## 7            0       0       0        0   1000     7e+02
## 10           0       0       0        0    500     5e+02
## 13           0       0       0        0    400     4e+02
## 16           0       0       0        0   7000     6e+03
## 25           0       0       0        0   6000     4e+03
## 28           0       0       0        0   1400     1e+03
## 30           0       0       0        0    600     6e+02
## 31           0       0       0        0   6000     2e+03
## 33           0       0       0        0   2000     2e+03
## 34           0       0       0        0   1500     6e+02
## 36           0       0       0        0    700     7e+02
## 37           0       0       0        0  15700     1e+04
## 46           0       0       0        0      0     0e+00
## 49           0       0       0        0   1800     1e+03
```

```
## 52          0       0       0       0    400     4e+02
## 58          0       0       0       0    800     4e+02
## 60          0       0       0       0   1400     7e+02
## 66          0       0       0       0      0     0e+00
## 67          0       0       0       0   4300     4e+03
## 68          0       0       0       0    900     9e+02
## 71          0       0       0       0    800     8e+02
## 74          0       0       0       0      0     0e+00
## 75          0       0       0       0   4300     4e+03
## 77          0       0       0       0   5000     5e+03
## 79          0       0       0       0    600     3e+02
## 81          0       0       0       0      0     0e+00
## 84          0       0       0       0      0     0e+00
## 86          0       0       0       0      0     0e+00
## 87          0       0       0       0   6000     6e+03
## 89          0       0       0       0      0     0e+00
## 91          0       0       0       0      0     0e+00
## 94          0       0       0       0      0     0e+00
## 97          0       0       0       0      0     0e+00
## 100         0       0       0       0      0     0e+00
## 102         0       0       0       0    800     5e+02
## 108         0       0       0       0      0     0e+00
## 109         0       0       0       0      0     0e+00
## 111         0       0       0       0      0     0e+00
## 112         0       0       0       0      0     0e+00
## 114         0       0       0       0    200     2e+02
## 115         0       0       0       0      0     0e+00
## 117         0       0       0       0      0     0e+00
## 118         0       0       0       0   3000     3e+03
## 119         0       0       0       0      0     0e+00
## 120         0       0       0       0   4000     4e+03
## 121         0       0       0       0   4000     4e+03
## 123         0       0       0       0      0     0e+00
## 124         0       0       0       0   3000     3e+03
## 125         0       0       0       0    300     3e+02
## 126         0       0       0       0      0     0e+00
## 128         0       0       0       0   2000     2e+03
## 129         0       0       0       0      0     0e+00
## 130         0       0       0       0      0     0e+00
## 132         0       0       0       0   3000     3e+03
## 133         0       0       0       0      0     0e+00
## 135         0       0       0       0      0     0e+00
## 136         0       0       0       0      0     0e+00
## 138         0       0       0       0      0     0e+00
## 139         0       0       0       0   2000     2e+03
## 141         0       0       0       0   2700     1e+03
## 142         0       0       0       0      0     0e+00
## 144         0       0       0       0      0     0e+00
## 146         0       0       0       0   6000     6e+03
## 150         0       0       0       0      0     0e+00
## 151         0       0       0       0    900     9e+02
## 153         0       0       0       0    900     9e+02
## 154         0       0       0       0      0     0e+00
## 156         0       0       0       0      0     0e+00
```

```
## 157          0       0       0        0      0     0e+00
## 159          0       0       0        0      0     0e+00
## 160          0       0       0        0    900     6e+02
##  [ reached getOption("max.print") -- omitted 1924 rows ]
```

Estamos ante un data set con muchos outliers (+75%), tantos que tendremos que buscar una manera de condensar estos de manera que podamos estudiarlos, ya que los datos son tan dispares y en cierta medida complejos que no podrán obtenerse conclusiones lógicas con tan solo observarlos.

Ampliación

Realizaremos el estudio anterior, pero solo utilizando ordenes básicas de R, es decir, sin recurrir a la función usada anteriormente.

Índices y valores de los outliers

Obtendremos por tanto, para cada columna un vector lógico que nos indique si estamos ante un outlier o no y guardamos todo en una matriz.

```
frame.es.outlier <- sapply(1:ncol(mydata.numeric),vector_es_outlier_IQR, datos=mydata.numeric)

head(frame.es.outlier)
```

```
##       [,1]  [,2]  [,3]  [,4]  [,5]  [,6]  [,7]  [,8]  [,9] [,10] [,11]
## [1,] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [2,] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [3,] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [4,] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [5,] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [6,] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
##      [,12] [,13] [,14]
## [1,] FALSE FALSE FALSE
## [2,] FALSE FALSE FALSE
## [3,] FALSE FALSE FALSE
## [4,] FALSE FALSE FALSE
## [5,] FALSE FALSE FALSE
## [6,] FALSE FALSE FALSE
```

Ahora obtendremos el número total de outliers por columna: help(sapply)

```
numero.total.outliers.por.columna <- apply(frame.es.outlier, 2, sum)
numero.total.outliers.por.columna
```

```
##  [1] 334 201 141  95 277  77  68 158  12   0   0   0 319 313
```

Como hemos dicho anteriormente, podemos comprobar que el número de *univariate outliers* en el problema es muy elevado y excepto den dos columnas, los tenemos presentes en todas.

Con el fin de obtener los datos con los outliers, obtendremos ahora las claves de las filas que en alguna de sus columnas tienen outliers.

```
indices.de.outliers.en.alguna.columna<- sapply(1:ncol(mydata.numeric),vector_claves_outliers_IQR, datos=
indices.de.outliers.en.alguna.columna <- sort(unique(unlist(indices.de.outliers.en.alguna.columna)))
```

Desviación de los outliers con respecto a la media de la columna

```
mydata.numeric[indices.de.outliers.en.alguna.columna,]
```

```
##      genergy gpuls gdenergy gdpuls nbumps nbumps2 nbumps3 nbumps4 nbumps5
## 7     207930   614       -6     18      2       2       0       0       0
## 10    247620   675        4     25      1       1       0       0       0
## 13    166180   448      -30    -19      1       1       0       0       0
## 14     64540   215        0      9      1       0       1       0       0
## 16    225040   575       -3      5      2       0       2       0       0
## 25    424650  1069        1      7      2       0       2       0       0
## 28    212260   729      -50    -28      2       1       1       0       0
## 29     42950   172      -76    -61      1       0       1       0       0
## 30    172290   437      -57    -55      1       1       0       0       0
## 31    395110  1043       46     40      3       0       3       0       0
## 32     51320   239       11     23      1       0       1       0       0
## 33    144880   361      -46    -52      1       0       1       0       0
## 34    477750  1132       86     60      3       3       0       0       0
## 35     71840   255       54     28      1       0       1       0       0
## 36    127360   351      -54    -53      1       1       0       0       0
## 37    514800  1369       95     94      7       4       2       1       0
## 46    250030   687       -8     -5      0       0       0       0       0
## 49    309010   983       15     38      2       1       1       0       0
## 50     59060   264       65     85      1       0       1       0       0
## 52    248900   739       -9      0      1       1       0       0       0
## 53     51620   186       51     34      1       0       1       0       0
## 58    269070   767       -1      4      2       2       0       0       0
## 60    372770   975       37     32      3       3       0       0       0
## 66    147520   472       -2     -6      0       0       0       0       0
## 67    202640   588      -33    -41      2       1       1       0       0
## 68    259110  1409      -11     46      1       1       0       0       0
## 71    590510  1780       23     -6      1       1       0       0       0
## 72     75930   305      -38    -27      1       0       1       0       0
## 74    317360  1068      -36    -44      0       0       0       0       0
## 75    227990   734      -52    -59      2       1       1       0       0
## 77    210960   773      -44    -35      1       0       1       0       0
## 79    302440  1250      -16      9      2       2       0       0       0
## 80     46160   250      -16     15      1       0       1       0       0
## 81    436650  1232       23      6      0       0       0       0       0
## 84    169370   644      -53    -45      0       0       0       0       0
## 86    233810   839      -31    -24      0       0       0       0       0
## 87    149050   697      -54    -35      1       0       1       0       0
## 89    194580   697      -35    -32      0       0       0       0       0
## 91    194580   697      -35    -32      0       0       0       0       0
## 94    285750   791        1    -19      0       0       0       0       0
## 96     25580   120      -54    -53      1       0       1       0       0
## 97    298230   916        9     -2      0       0       0       0       0
## 100   172120   537      -35    -41      0       0       0       0       0
## 102   270040   717       10    -14      2       2       0       0       0
## 108   166700   363      -34    -56      0       0       0       0       0
## 109   274170   997       15     34      0       0       0       0       0
## 111   226790   717        2      0      0       0       0       0       0
## 112   134640   611      -41    -16      0       0       0       0       0
## 114   328050   707       51      0      1       1       0       0       0
```

```
## 115   140090   380      -40    -46      0       0       0       0       0
## 117   157740   440      -31    -35      0       0       0       0       0
## 118   325750  1068       50     67      1       0       1       0       0
## 119   300520   894       37     37      0       0       0       0       0
## 120   465730  1325       -7    -12      1       0       1       0       0
## 121   336600   984      -32    -34      1       0       1       0       0
## 123   951410  1332       98     -7      0       0       0       0       0
## 124   203850   476      -14    -32      1       0       1       0       0
## 125   715390  1923       36     36      1       1       0       0       0
## 126   160350   828      -31     23      0       0       0       0       0
## 128   373180  1246      -32    -14      1       0       1       0       0
## 129   481630  1678      -10     17      0       0       0       0       0
## 130   620720  1789       17     23      0       0       0       0       0
## 132   280830   689       94     39      1       0       1       0       0
## 133   557230  1642        2     11      0       0       0       0       0
## 135   270490   865       83     78      0       0       0       0       0
## 136   307540  1020      -44    -32      0       0       0       0       0
## 138   314100   904      -41    -37      0       0       0       0       0
## 139   368340  1325      -28     -4      1       0       1       0       0
## 140   114540   488      -23      0      2       0       2       0       0
## 141   316200  1089      -37    -21      3       1       2       0       0
## 142   209760   919       46     89      0       0       0       0       0
##      nbumps6 nbumps7 nbumps89 energy maxenergy
## 7          0       0        0   1000     7e+02
## 10         0       0        0    500     5e+02
## 13         0       0        0    400     4e+02
## 14         0       0        0   6000     6e+03
## 16         0       0        0   7000     6e+03
## 25         0       0        0   6000     4e+03
## 28         0       0        0   1400     1e+03
## 29         0       0        0   6000     6e+03
## 30         0       0        0    600     6e+02
## 31         0       0        0   6000     2e+03
## 32         0       0        0   6000     6e+03
## 33         0       0        0   2000     2e+03
## 34         0       0        0   1500     6e+02
## 35         0       0        0   6000     6e+03
## 36         0       0        0    700     7e+02
## 37         0       0        0  15700     1e+04
## 46         0       0        0      0     0e+00
## 49         0       0        0   1800     1e+03
## 50         0       0        0   6000     6e+03
## 52         0       0        0    400     4e+02
## 53         0       0        0   7000     7e+03
## 58         0       0        0    800     4e+02
## 60         0       0        0   1400     7e+02
## 66         0       0        0      0     0e+00
## 67         0       0        0   4300     4e+03
## 68         0       0        0    900     9e+02
## 71         0       0        0    800     8e+02
## 72         0       0        0   6000     6e+03
## 74         0       0        0      0     0e+00
## 75         0       0        0   4300     4e+03
## 77         0       0        0   5000     5e+03
```

```
## 79          0       0        0    600     3e+02
## 80          0       0        0   6000     6e+03
## 81          0       0        0      0     0e+00
## 84          0       0        0      0     0e+00
## 86          0       0        0      0     0e+00
## 87          0       0        0   6000     6e+03
## 89          0       0        0      0     0e+00
## 91          0       0        0      0     0e+00
## 94          0       0        0      0     0e+00
## 96          0       0        0   6000     6e+03
## 97          0       0        0      0     0e+00
## 100         0       0        0      0     0e+00
## 102         0       0        0    800     5e+02
## 108         0       0        0      0     0e+00
## 109         0       0        0      0     0e+00
## 111         0       0        0      0     0e+00
## 112         0       0        0      0     0e+00
## 114         0       0        0    200     2e+02
## 115         0       0        0      0     0e+00
## 117         0       0        0      0     0e+00
## 118         0       0        0   3000     3e+03
## 119         0       0        0      0     0e+00
## 120         0       0        0   4000     4e+03
## 121         0       0        0   4000     4e+03
## 123         0       0        0      0     0e+00
## 124         0       0        0   3000     3e+03
## 125         0       0        0    300     3e+02
## 126         0       0        0      0     0e+00
## 128         0       0        0   2000     2e+03
## 129         0       0        0      0     0e+00
## 130         0       0        0      0     0e+00
## 132         0       0        0   3000     3e+03
## 133         0       0        0      0     0e+00
## 135         0       0        0      0     0e+00
## 136         0       0        0      0     0e+00
## 138         0       0        0      0     0e+00
## 139         0       0        0   2000     2e+03
## 140         0       0        0   8000     5e+03
## 141         0       0        0   2700     1e+03
## 142         0       0        0      0     0e+00
##  [ reached getOption("max.print") -- omitted 719 rows ]
```

BoxPlot

Por último utilizamos boxplot para obtener el gráfico con los outliers:

```
boxplot(mydata.numeric)
```

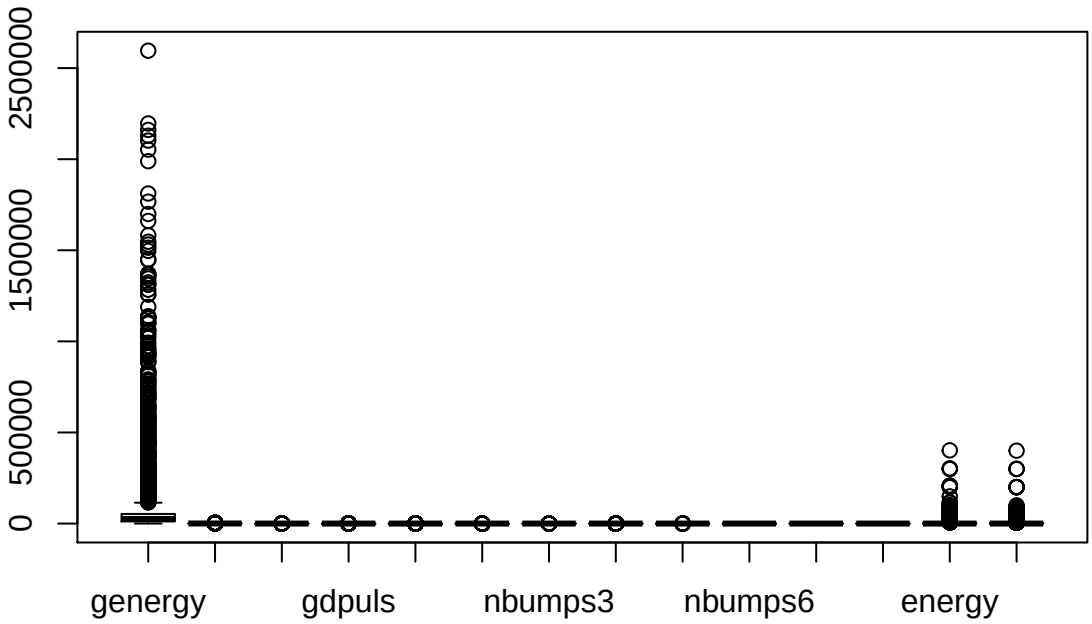

Dado el gran volumen de datos no usaremos la función que los representa con etiquetas ya que de ser así estos se verían representados como una mancha, dado el gran volumen de outliers.

Test estadísticos sobre los outliers

Cuando trabajamos con la detección de outliers, así como con otras diversas vertientes dentro de la ciencia de datos, saber si los resultados son estadísticamente significativos será casi tan importante, o incluso más, que los procesos anteriores de minería de datos. En esta sección trataremos de sobre estos ello

Los resultados, están basados en el código del profesor de la asignatura (J.C Cubero) y se han aplicado sobre el conjunto de datos seismic que tenemos entre manos a lo largo de la práctica. Dado que la presencia de outliers en nuestro dataset es muy elevada, realizaremos los test estadisticos para columnas de datos en el caso de tener varios outliers (> de 2).

Por ello el principal proceso, será obtener sobre que columna vamos a realizar el estudio estadístico.

```
numero.total.outliers.por.columna <- apply(frame.es.outlier, 2, sum)
numero.total.outliers.por.columna
```

```
##  [1] 334 201 141  95 277  77  68 158  12   0   0   0 319 313
```

Nos quedaremos con la columna 4 por ejemplo, con 95 outliers.

```
mydata.numeric  = seismic[,-c(1,2,3,8,19)]
datos.con.varios.outliers <- mydata.numeric[,4]

mydata.numeric = datos.con.varios.outliers
test.de.rosner = rosnerTest(mydata.numeric, k=95)
```

```
## Warning in rosnerTest(mydata.numeric, k = 95): The true Type I error may be larger than assumed.
## Although the help file for 'rosnerTest' has a table with information
## on the estimated Type I error level,
## simulations were not run for k > 10 or k > floor(n/2).
```

```
is.outlier.rosner = test.de.rosner$all.stats$Outlier
k.mayores.desviaciones.de.la.media = test.de.rosner$all.stats$Obs.Num
```

```
indices.de.outliers.rosner = k.mayores.desviaciones.de.la.media[is.outlier.rosner]
valores.de.outliers.rosner = mydata.numeric[indices.de.outliers.rosner]

print("Índices de las k-mayores desviaciones de la media")
```

```
## [1] "Índices de las k-mayores desviaciones de la media"
```

```
k.mayores.desviaciones.de.la.media
```

```
##  [1] 1692 1342 1693 1798 2550 1799 1822 1373 1621 2433 1772 2183 1559 1368
## [15] 1660 1208 2181 1534 1551 1367 1343 2082 1541 1550 2252 1536 2230 1357
## [29] 1392 1533 1821 2492 2184 2403 1585 1694 2253 1552 2038 1583 1895 2294
## [43] 1647  656 1112 2185 2182 1560 1575 1393 1530  907 1557  555 1546 1304
## [57] 1360 2254 1531 1542 1535 1501 2178 1741 1298 1363 1523 1702 1231 1325
## [71] 2580 2566 1720 1726 1335 1532 2180 1517  351 1558 1359 1092 2523 1210
## [85] 1614 2179 1287 1742 1586 1837 1648 1495 1485 2546 2551
```

```
print("De los k valores fijados, ¿Quién es outlier?")
```

```
## [1] "De los k valores fijados, ¿Quién es outlier?"
```

```
is.outlier.rosner
```

```
##  [1]  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
## [12]  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
## [23]  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE FALSE FALSE
## [34] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [45] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [56] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [67] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [78] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [89] FALSE FALSE FALSE FALSE FALSE FALSE FALSE
```

```
print("Los índices de los outliers son:")
```

```
## [1] "Los índices de los outliers son:"
```

```
indices.de.outliers.rosner
```

```
##  [1] 1692 1342 1693 1798 2550 1799 1822 1373 1621 2433 1772 2183 1559 1368
## [15] 1660 1208 2181 1534 1551 1367 1343 2082 1541 1550 2252 1536 2230 1357
## [29] 1392 1533 1821
```

```
print("Los valores de los outliers son:")
```

```
## [1] "Los valores de los outliers son:"
```

```
valores.de.outliers.rosner
```

```
##  [1] 838 506 450 384 367 334 323 313 311 310 309 305 295 278 278 258 256
## [18] 255 255 251 249 248 245 243 239 235 234 233 227 227 226
```

```
MiPlot_Univariate_Outliers (mydata.numeric, indices.de.outliers.rosner, "Test de Rosner")
```

```
##
## N?mero de datos: 2584
## ?Qui?n es outlier?: FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FA
```

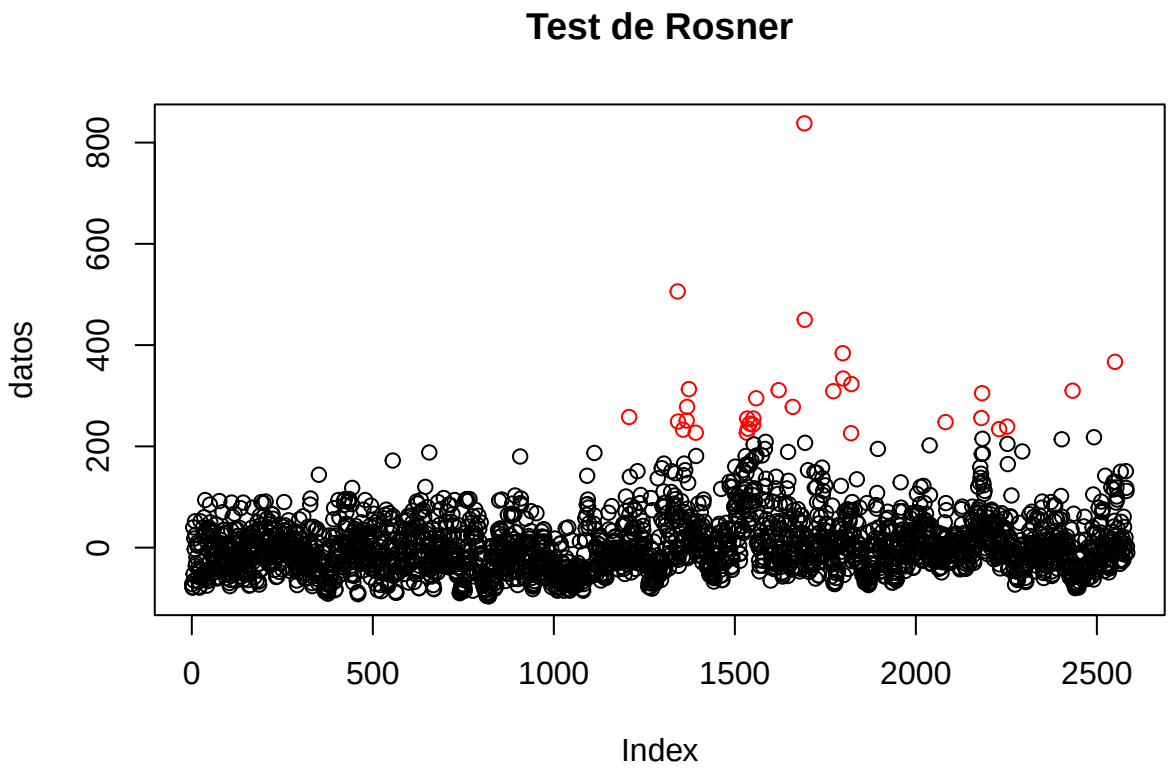

El test de Rosner funciona, y nos muestra los outliers en esta variable que hemos cogido como muestra.

Análisis de outliers en varias variables

Los outliers, podrán ser denominados como tal como resultado de la aparición de valores anómalos en una o varias de sus variables. En este estudio, obtendremos los valores de estos en como resultados de combinaciones de variables utilizando distribuciones normales.

Los datos que usaremos, son los mismos que en el anterior apartado, pero solo nos quedaremos con algunas de las variables ya que en pasos anteriores podremos usar como máximo 10 variables, para mejorar esto, eliminaremos aquellas variables muy correlacionadas, algo que podría influir tambien en la obtención de outliers multivariable. Eliminaremos de primeras las variables nbumps6, nbumps7, nbumps89, ya que siempre tienen valor 0 y no aportan nada.

```
library(corrplot)
M <- cor(seismic[,-c(1,2,3,8,14,15,16,19)])
corrplot(M, method = "circle")
```

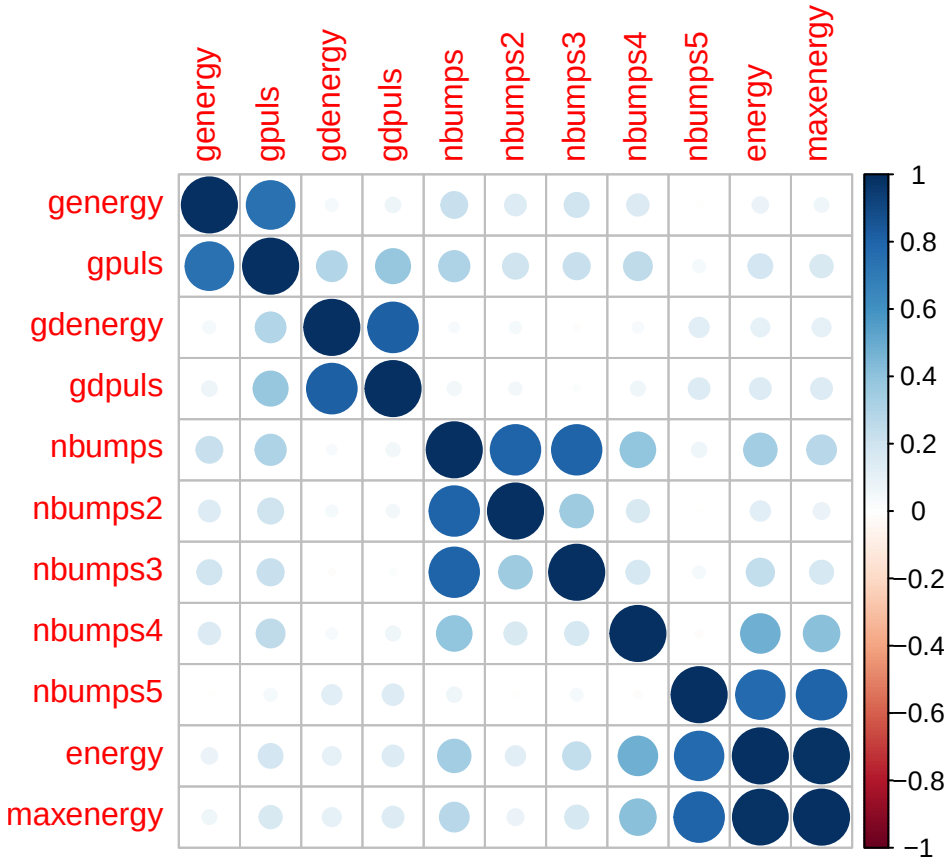

Podemos ver por tanto que enery y maxenergy tienen correlación de 1 prácticamente, por lo que nos quedaremos solo con energy. Tambien podremos eliminar. También eliminaremos genergy, gdenergy, nbums5 y nbums2 y 1 ya que nbums 3 será alto si las anteriores lo han sido.

```
mydata.numeric <- seismic[,-c(1,2,3,4,6,8,10,11,12,13,16,15,14,18,19)]
mydata.numeric.scaled <- scale(mydata.numeric)
```

Paquete mvoutlier

En esta sección, usaremos el paquete mvoutlier.

Obtención de los outliers multivariantes

Utilizaremos el paquete mvoutlier para la obtención de los outliers que son considerados como tal por la combinacion de varias de sus variables. Estos outliers son obtenidos por medio de la distancia de Mahalanobis, por lo que podremos usar los datos sin normalizar ya que esta medida es muy robusta a la escala.

Declaramos los parámetros de entradas y una semilla para poder reproducir resultados.

```
alpha.value = 0.05
alpha.value.penalizado = 1 - ( 1 - alpha.value) ^ (1 / nrow(mydata.numeric))
set.seed(12)
```

Analizaremos los outliers provocados entre las variables gpuls y pgpuls, ya que si añadimos las demás variables uniplot no es capaz de obtener los resultados debido a la singularidad de la matriz que forma para sus cálculos.

```
mvoutlier.plot<-suppressWarnings(uni.plot(mydata.numeric[,c(1,2)], symb=FALSE, alpha = alpha.value.penal
```

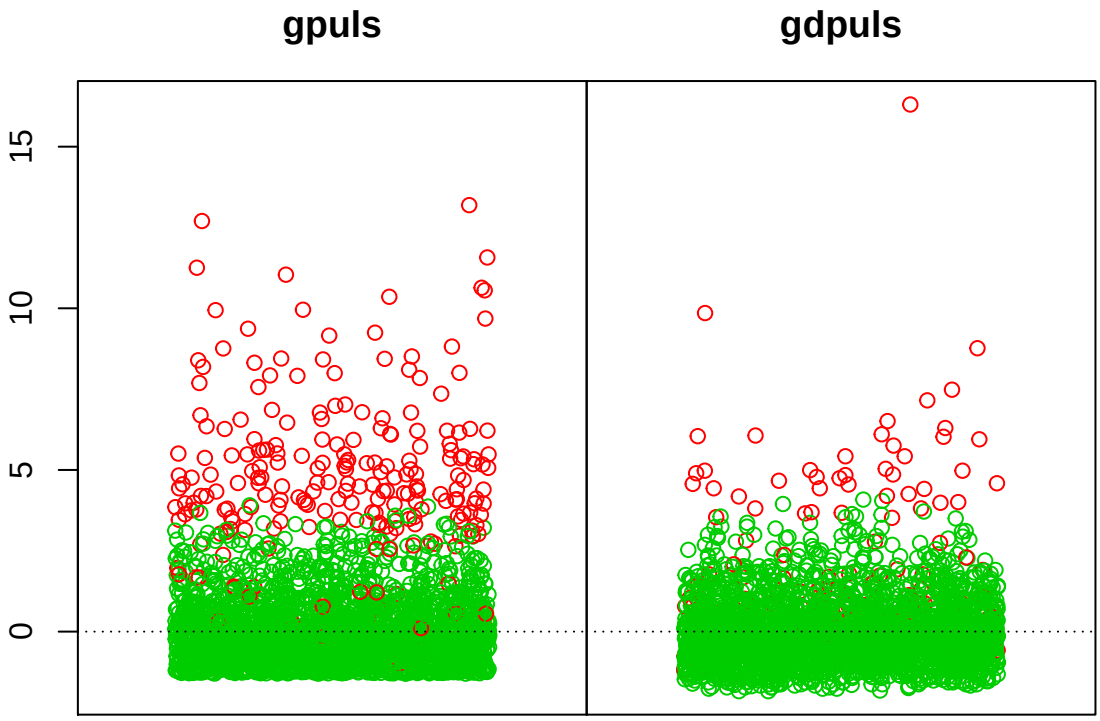

Si analizamos el gráfico podemos ver en rojo los outliers y en verde los ejemplos que no son outliers. Los datos interesantes en este caso, son aquellos, que no son outliers por sus valores altos, sino los que están situados en valores "normales" ya que estos serán outliers por combinaciones de varias de estas variables.

Análisis de los outliers

El gráfico anterior nos da una idea global de las anomalías en nuestro problema, pero será mucho más interesante obtener los ejemplos que representan a los datos en rojo (outliers). Para ello accedemos a los outliers del objeto mvoutlier.plot.

```
is.MCD.outlier <-mvoutlier.plot$outliers
numero.de.outliers.MCD<-sum(is.MCD.outlier, na.rm = T)
numero.de.outliers.MCD
```

```
## [1] 436
```

Tenemos por tanto 436 observaciones que son outliers en nuestro problema en función de estas variables. El siguiente paso, será obtener los outliers puros, es decir, aquellos que están debidos a combinaciones de variables y no a valores anómalos inusualmente altos o bajos en una de sus variables.

Para ello, construimos las siguientes variables:

Por tanto, debemos construir las siguientes variables:

- indices.de.outliers.en.alguna.columna -> A través de la función vector_claves_outliers_IQR_en_alguna_columna
- indices.de.outliers.multivariantes.MCD -> A partir de la variable is.MCD.outlier calculada anteriormente
- indices.de.outliers.multivariantes.MCD.pero.no.1variantes (debe usar setdiff sobre las anteriores variables)
- nombres.de.outliers.multivariantes.MCD.pero.no.1variantes (debe usar rownames)

```
indices.de.outliers.en.alguna.columna<-vector_claves_outliers_IQR_en_alguna_columna(mydata.numeric.scal

indices.de.outliers.multivariantes.MCD<-which(is.MCD.outlier)

indices.de.outliers.multivariantes.MCD.pero.no.1variantes<-setdiff(indices.de.outliers.multivariantes.M

nombres.de.outliers.multivariantes.MCD.pero.no.1variantes<-row.names(mydata.numeric)[indices.de.outlier

unique<-unique(nombres.de.outliers.multivariantes.MCD.pero.no.1variantes)
unique
```

```
##   [1] "25"   "50"   "74"   "75"   "79"   "81"   "110"  "120"  "121"  "123"
##  [11] "128"  "136"  "138"  "139"  "144"  "146"  "150"  "151"  "154"  "163"
##  [21] "166"  "184"  "194"  "245"  "248"  "277"  "322"  "323"  "335"  "340"
##  [31] "356"  "442"  "443"  "479"  "503"  "551"  "584"  "665"  "666"  "671"
##  [41] "672"  "673"  "681"  "682"  "685"  "688"  "689"  "700"  "701"  "726"
##  [51] "739"  "856"  "885"  "891"  "893"  "908"  "909"  "952"  "1087" "1090"
##  [61] "1091" "1093" "1094" "1095" "1111" "1268" "1272" "1493" "1547" "1548"
##  [71] "1549" "1556" "1562" "1572" "1576" "1580" "1604" "1616" "1617" "1623"
##  [81] "1635" "1637" "1638" "1689" "1696" "1699" "1700" "1712" "1721" "1727"
##  [91] "1736" "1743" "1749" "1769" "1865" "1893" "1958" "2177" "2186" "2237"
## [101] "2244" "2247" "2263" "2540" "2547" "2554" "2581"
```

Tenemos por tanto 107 outliers debidos a combinaciones de gdpuls y gpuls. Vamos a obtener todos los ejemplos que son outliers. Como nuestros nombres son numéricos puede hacerse de manera sencilla:

```
data.frame.solo.outliers<-data.frame(mydata.numeric.scaled[as.numeric(unique),])
data.frame.solo.outliers
```

```
##            gpuls       gdpuls     nbumps       energy
## 1    0.942714432  0.039436993  0.8357512  0.050106961
## 2   -0.488008703  1.274267643  0.1029446  0.050106961
## 3    0.940937136 -0.767952278 -0.6298621 -0.243279618
## 4    0.347320332 -1.005419710  0.8357512 -0.033019236
## 5    1.264404975  0.071099318  0.8357512 -0.213940960
## 6    1.232413651  0.023605831 -0.6298621 -0.243279618
## 7   -0.562655128  1.337592292  0.1029446  0.001209198
## 8    1.397702162 -0.261355088  0.1029446 -0.047688565
## 9    0.791644287 -0.609640656  0.1029446 -0.047688565
## 10   1.410143233 -0.182199277 -0.6298621 -0.243279618
## 11   1.257295792 -0.293017412  0.1029446 -0.145484092
## 12   0.855626937 -0.577978332 -0.6298621 -0.243279618
## 13   0.649460622 -0.657134142 -0.6298621 -0.243279618
## 14   1.397702162 -0.134705791  0.1029446 -0.145484092
## 15   1.289287117 -0.213861601 -0.6298621 -0.243279618
## 16   1.191535847 -0.277186250  0.1029446  0.050106961
## 17   0.880509078 -0.403835548 -0.6298621 -0.243279618
## 18   0.926718770 -0.356342061  0.1029446 -0.199271631
## 19   1.390592979  0.086930480 -0.6298621 -0.243279618
## 20   1.474125882 -0.261355088  0.8357512 -0.125924987
## 21   1.237745538 -0.435497872  0.1029446  0.001209198
## 22   0.873399895 -0.577978332 -0.6298621 -0.243279618
## 23   0.841408570 -0.736289953  0.8357512  0.001209198
## 24   1.148880747 -0.293017412 -0.6298621 -0.243279618
## 25   0.796976175 -0.546316007  0.8357512 -0.174822750
```

```
## 26   1.497230728 -0.720458791 -0.6298621 -0.243279618
## 27   1.234190946 -0.530484845 -0.6298621 -0.243279618
## 28   1.445689149 -0.372173223  0.8357512 -0.062357894
## 29   1.445689149 -0.625471818  0.1029446 -0.223720513
## 30   1.273291454 -0.783783440  0.8357512 -0.209051184
## 31   1.230636355 -0.989588548  0.1029446 -0.223720513
## 32  -0.504004366  1.290098806  0.1029446 -0.145484092
## 33  -0.388480137  1.796695995  0.8357512 -0.130814763
## 34  -0.799035472  1.416748103  0.1029446 -0.228610289
## 35  -0.834581388  0.989306724  0.1029446  0.001209198
## 36  -0.797258176  0.846826265  0.1029446 -0.145484092
## 37  -0.822140317  0.767670454 -0.6298621 -0.243279618
## 38   1.159544522 -0.704627629  0.1029446 -0.096586329
## 39   1.129330493 -0.688796467  0.1029446 -0.233500066
## 40   0.704556792 -0.847108089  0.8357512 -0.165043197
## 41   1.036911110 -0.039718817 -0.6298621 -0.243279618
## 42   1.102671056  0.007774669  0.1029446 -0.223720513
## 43   1.267959567  0.102761642  0.8357512 -0.189492079
## 44   1.122221310 -0.039718817  0.1029446  0.001209198
## 45   0.812971837 -0.340510899 -0.6298621 -0.243279618
## 46   0.704556792 -0.482991359  0.8357512 -0.199271631
## 47   1.321278442 -0.071381142  0.8357512 -0.179712526
## 48   1.237745538 -0.150536953  0.1029446 -0.194381855
## 49   0.875177191 -0.403835548  0.8357512 -0.067247671
## 50  -0.344047742  1.416748103 -0.6298621 -0.243279618
## 51   1.243077426 -0.672965305  0.1029446 -0.145484092
## 52  -0.818585726  1.432579265 -0.6298621 -0.243279618
## 53  -0.804367359  1.305929968 -0.6298621 -0.243279618
## 54  -0.815031134  0.973475562  0.1029446 -0.218830737
## 55  -0.758157668  1.559228563 -0.6298621 -0.243279618
## 56  -0.756380372  1.321761130 -0.6298621 -0.243279618
## 57  -0.719057160  1.464241590 -0.6298621 -0.243279618
## 58  -0.838135980  1.005137886 -0.6298621 -0.243279618
## 59  -0.845245163  0.846826265 -0.6298621 -0.243279618
## 60  -0.839913276  0.957644400 -0.6298621 -0.243279618
## 61  -0.825694909  1.274267643 -0.6298621 -0.243279618
## 62  -0.783039809  1.290098806 -0.6298621 -0.243279618
## 63  -0.747493893  1.432579265 -0.6298621 -0.243279618
## 64  -0.738607414  1.179280670 -0.6298621 -0.243279618
## 65   1.497230728  0.672683481 -0.6298621 -0.243279618
## 66  -0.546659465  1.480072752 -0.6298621 -0.243279618
## 67  -0.626637777  1.100124859 -0.6298621 -0.243279618
## 68  -0.118331173  1.828358320 -0.6298621 -0.243279618
## 69   1.294619004  1.717540184  0.1029446 -0.228610289
## 70   1.282177934  1.701709022  0.1029446 -0.228610289
## 71   1.195090438  1.575059725 -0.6298621 -0.243279618
## 72   1.310614667  1.385085779  0.1029446 -0.218830737
## 73   1.411920528  1.052631373 -0.6298621 -0.243279618
## 74   1.056461364  0.292735588  0.1029446  0.001209198
## 75  -0.386702842  1.448410427 -0.6298621 -0.243279618
## 76   1.010251673  0.181917453  0.8357512 -0.062357894
## 77  -0.640856144  1.369254616 -0.6298621 -0.243279618
## 78   1.232413651  0.213579777  0.1029446 -0.209051184
## 79   1.100893760  0.102761642 -0.6298621 -0.243279618
```

```
## 80   0.894727445 -0.118874628  0.1029446 -0.213940960
## 81   1.280400638  0.071099318  0.1029446 -0.047688565
## 82   0.903613924 -0.213861601 -0.6298621 -0.243279618
## 83   0.635242255 -0.419666710 -0.6298621 -0.243279618
## 84   1.342605991  0.340229075 -0.6298621 -0.243279618
## 85   0.878731782 -0.023887655 -0.6298621 -0.243279618
## 86   0.976483053  0.055268156 -0.6298621 -0.243279618
## 87   0.827190204 -0.071381142 -0.6298621 -0.243279618
## 88   1.079566210  0.071099318  0.1029446 -0.096586329
## 89  -0.306724530  1.796695995 -0.6298621 -0.243279618
## 90  -0.390257433  1.353423454 -0.6298621 -0.243279618
## 91  -0.392034729  1.337592292 -0.6298621 -0.243279618
## 92  -0.347602333  1.575059725 -0.6298621 -0.243279618
## 93   1.161321818  0.482709534  0.1029446  0.050106961
## 94  -0.674624764  1.242605319 -0.6298621 -0.243279618
## 95  -0.669292877  1.321761130 -0.6298621 -0.243279618
## 96   1.298173596  1.638384374 -0.6298621 -0.243279618
## 97   0.279783091  1.970838779  0.1029446 -0.145484092
## 98   1.054684069  1.955007617  0.1029446 -0.047688565
## 99   0.007856831  1.970838779  0.8357512 -0.121035210
## 100  1.330164921  1.005137886 -0.6298621 -0.243279618
## 101  1.019138152  0.561865345  0.1029446 -0.228610289
## 102  1.253741200  0.846826265 -0.6298621 -0.243279618
## 103  0.887618262 -0.340510899 -0.6298621 -0.243279618
## 104  0.071839480  1.812527157  0.1029446  0.001209198
## 105  0.025629789  1.749202509 -0.6298621 -0.243279618
## 106  0.059398409  1.812527157 -0.6298621 -0.243279618
## 107  0.029184380  1.796695995 -0.6298621 -0.243279618
```

```
row.names(data.frame.solo.outliers)
```

```
##   [1] "1"   "2"   "3"   "4"   "5"   "6"   "7"   "8"   "9"   "10"  "11"
##  [12] "12"  "13"  "14"  "15"  "16"  "17"  "18"  "19"  "20"  "21"  "22"
##  [23] "23"  "24"  "25"  "26"  "27"  "28"  "29"  "30"  "31"  "32"  "33"
##  [34] "34"  "35"  "36"  "37"  "38"  "39"  "40"  "41"  "42"  "43"  "44"
##  [45] "45"  "46"  "47"  "48"  "49"  "50"  "51"  "52"  "53"  "54"  "55"
##  [56] "56"  "57"  "58"  "59"  "60"  "61"  "62"  "63"  "64"  "65"  "66"
##  [67] "67"  "68"  "69"  "70"  "71"  "72"  "73"  "74"  "75"  "76"  "77"
##  [78] "78"  "79"  "80"  "81"  "82"  "83"  "84"  "85"  "86"  "87"  "88"
##  [89] "89"  "90"  "91"  "92"  "93"  "94"  "95"  "96"  "97"  "98"  "99"
## [100] "100" "101" "102" "103" "104" "105" "106" "107"
```

Por último obtenemos el gráfico de estos outliers. Representaremos en rojo todos los outliers y etiquetaremos aquellos que son outliers debidos a combinaciones anómalas de las variables gdpuls y gpuls.

```
mydata.numeric <- seismic[,-c(1,2,3,4,6,8,10,16,15,14,18,19)]
mydata.numeric.scaled <- scale(mydata.numeric)
is.MCD.outlier[1:length(is.MCD.outlier)]<-FALSE
is.MCD.outlier[as.numeric(unique)]<-TRUE
MiBoxPlot_juntos(mydata.numeric.scaled,is.MCD.outlier)
```

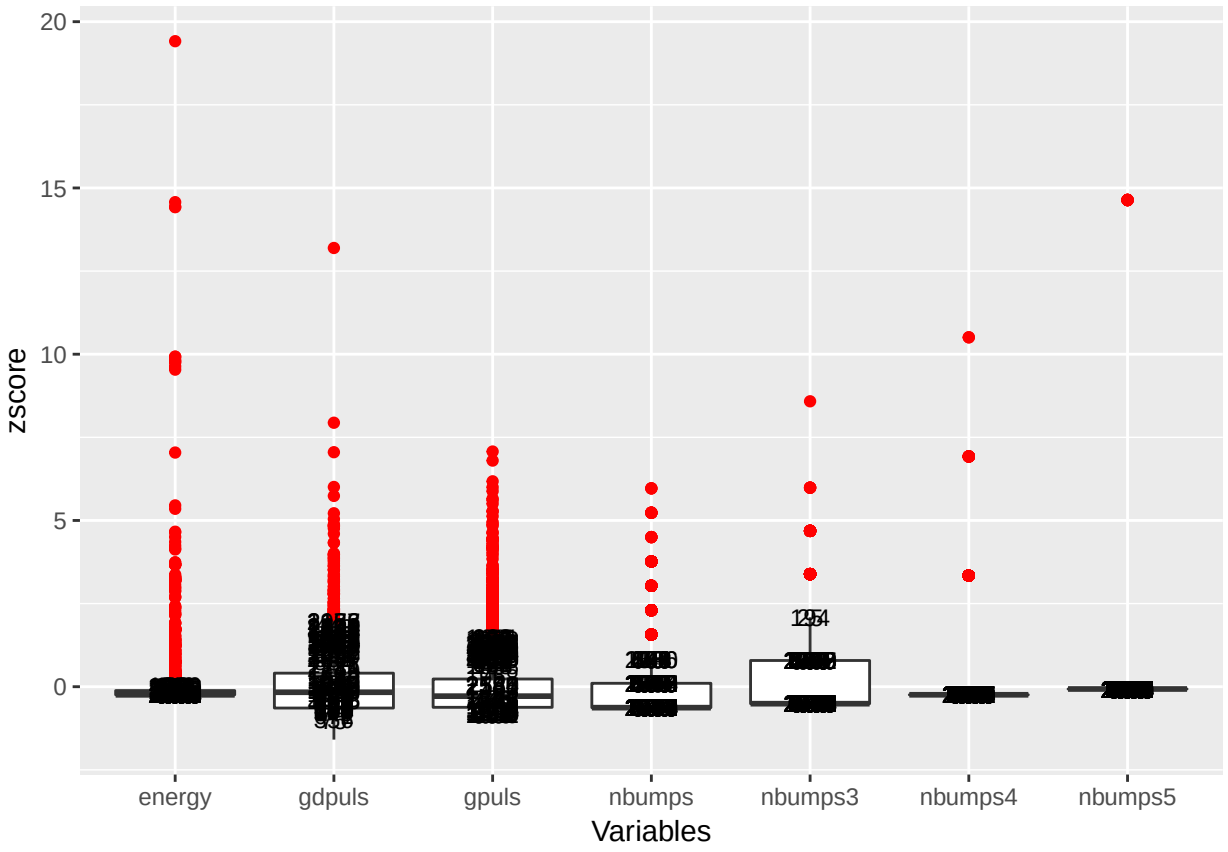

El gráfico es poco revelador debido a que los números se superponen el gráfico, por lo que deberíamos encontrar algún otro método de visualización. Usaremos el biplot.

```
MiBiPlot_Multivariate_Outliers(mydata.numeric.scaled, is.MCD.outlier, "Outliers-Biplot")
```

```
##                          NA                          NA                       NA NA    NA  NA
```

```
## Warning: Removed 107 rows containing missing values (geom_text).
```

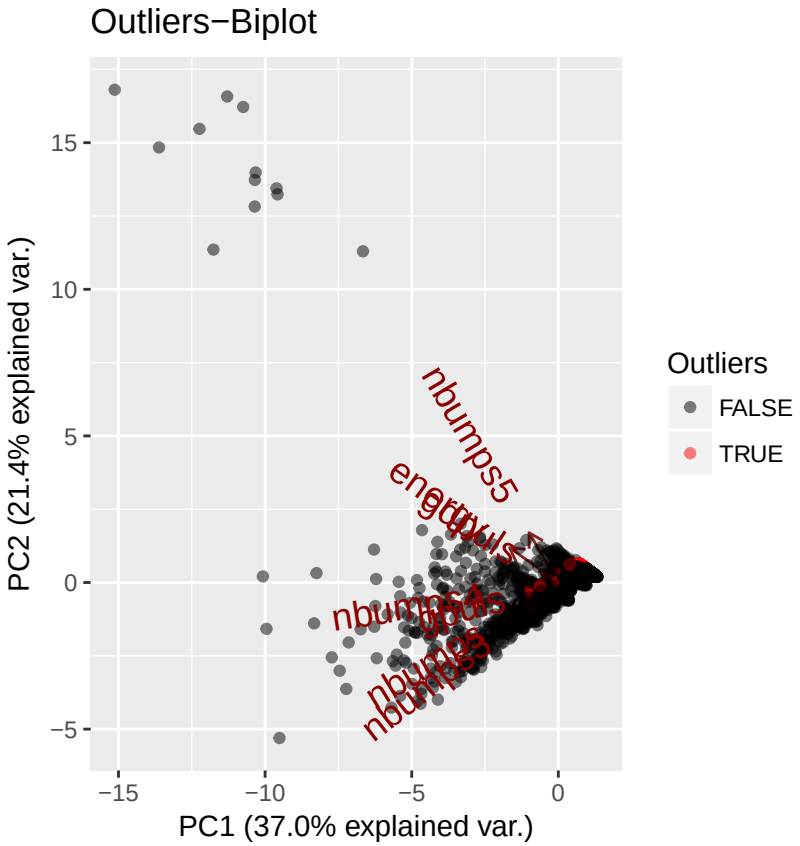

Nuevamente se hace muy complicado el estudio de los outliers, ya que los datos son muchos y las variables siguen estando muy correladas lo que implica que casi todo el gráfico vaya en la misma dirección. Además solo se han tenido en cuenta dos variables para que su combinación de como resultado un outlier.

Trataremos de centrarnos en los índices de outliers 2 varite que hemos obtenido antes para analizar que puede estar pasando, antes trataremos de mostrar en rojos estos outliers respecto a las correlaciones de las variables para intentar de encontrar algun patrón.

```
indices_de_Outliers<-which(rownames(mydata.numeric)==unique)
```

```
## Warning in rownames(mydata.numeric) == unique: longitud de objeto mayor no
## es múltiplo de la longitud de uno menor
```

```
MiPlot_Univariate_Outliers(mydata.numeric, indices_de_Outliers, "UnivariateOutliers")
```

```
##
## N?mero de datos: 2584
## ?Qui?n es outlier?: FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FA
```

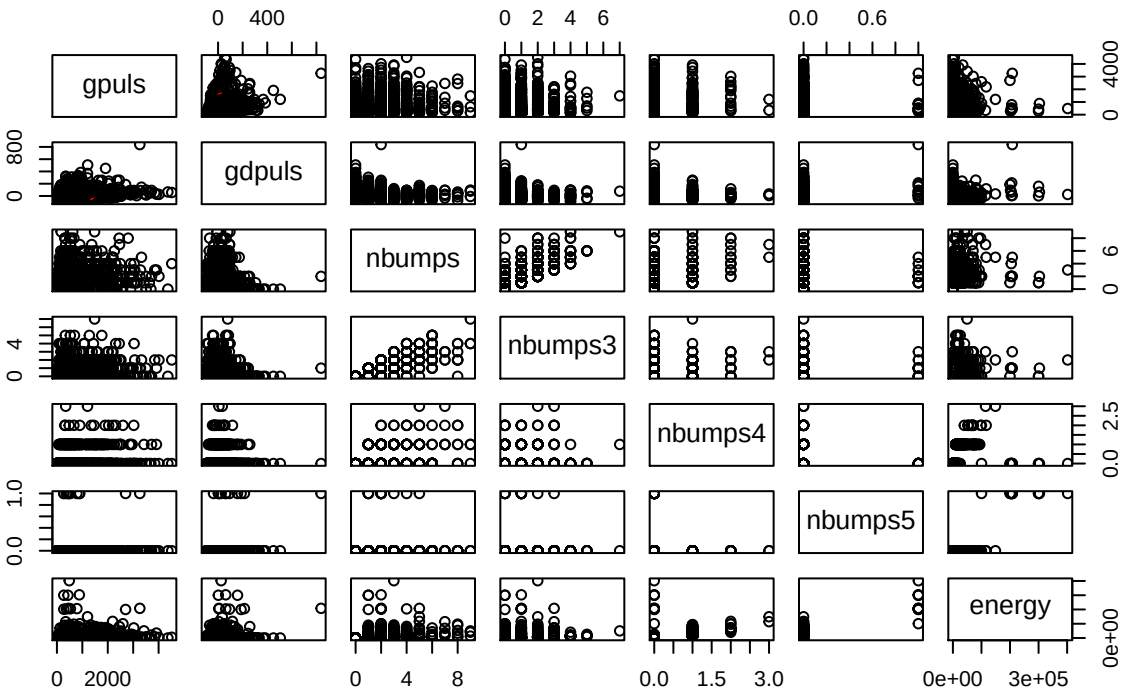

Nuevamente la gran cantidad de datos hace imposible obtener ninguna interpretación gráfica sobre los datos. Igualmente, todo el proceso viene afectado por los problemas con la funcion uni.plot().

```
summary(mydata.numeric.scaled)
```

```
##       gpuls              gdpuls             nbumps           nbumps3
##  Min.   :-0.9537   Min.   :-1.5912   Min.   :-0.6299   Min.   :-0.5103
##  1st Qu.:-0.6195   1st Qu.:-0.6413   1st Qu.:-0.6299   1st Qu.:-0.5103
##  Median :-0.2836   Median :-0.1664   Median :-0.6299   Median :-0.5103
##  Mean   : 0.0000   Mean   : 0.0000   Mean   : 0.0000   Mean   : 0.0000
##  3rd Qu.: 0.2318   3rd Qu.: 0.4075   3rd Qu.: 0.1029   3rd Qu.: 0.7889
##  Max.   : 7.0726   Max.   :13.1951   Max.   : 5.9654   Max.   : 8.5840
##     nbumps4           nbumps5             energy
##  Min.   :-0.2427   Min.   :-0.06829   Min.   :-0.2433
##  1st Qu.:-0.2427   1st Qu.:-0.06829   1st Qu.:-0.2433
##  Median :-0.2427   Median :-0.06829   Median :-0.2433
##  Mean   : 0.0000   Mean   : 0.00000   Mean   : 0.0000
##  3rd Qu.:-0.2427   3rd Qu.:-0.06829   3rd Qu.:-0.1161
##  Max.   :10.5077   Max.   :14.63729   Max.   :19.4136
```

```
summary(mydata.numeric.scaled[as.numeric(unique),])
```

```
##       gpuls              gdpuls             nbumps           nbumps3
##  Min.   :-0.8452   Min.   :-1.0054   Min.   :-0.6299   Min.   :-0.51032
##  1st Qu.:-0.3894   1st Qu.:-0.2930   1st Qu.:-0.6299   1st Qu.:-0.51032
##  Median : 0.8805   Median : 0.2136   Median :-0.6299   Median :-0.51032
##  Mean   : 0.5153   Mean   : 0.4874   Mean   :-0.1710   Mean   :-0.08536
##  3rd Qu.: 1.2360   3rd Qu.: 1.3376   3rd Qu.: 0.1029   3rd Qu.: 0.78887
##  Max.   : 1.4972   Max.   : 1.9708   Max.   : 0.8358   Max.   : 2.08806
##     nbumps4           nbumps5             energy
##  Min.   :-0.2427   Min.   :-0.06829   Min.   :-0.24328
```

```
##  1st Qu.:-0.2427   1st Qu.:-0.06829   1st Qu.:-0.24328
##  Median :-0.2427   Median :-0.06829   Median :-0.24328
##  Mean   :-0.2427   Mean   :-0.06829   Mean   :-0.18392
##  3rd Qu.:-0.2427   3rd Qu.:-0.06829   3rd Qu.:-0.14548
##  Max.   :-0.2427   Max.   :-0.06829   Max.   : 0.05011
```

Dado que los gráficos no ofrecen mucha información en nuestro problema, hemos intentado obtener por medios de datos estadísticos, de medias, medianas y cuartiles alguna razon de porque estos pueden estar siendo considerados outliers. Para ello calculamos las estadísticas del dataset completo y de los datos que son considerados outliers en función de estas dos variables.

Los datos tampoco son concluyentes y todo parece apuntar a que los outliers que tendremos vendrán dados casi en la totalidad por valores anómalos en una variable, que a muy seguro tambien serán anómalos otras al tratarse de medidas de energía y que **están muy correlacionadas** como hemos visto anteriormente.

Descartamos por tanto el método de Mahalanobis para la obtención de outliers, dado que estos son muchos en nuestro problema y tienen valores similares entre las variables y las observaciones (poca varianza) que además están muy correlacionadas por lo que usaremos otras técnicas que puedan comportarse mejor en nuestro problema como LOF o técnicas de clustering que será lo que veremos en la siguiente sección.

Outliers Multivariante: LOF

Dado que tanto las técnicas LOF como las basadas en clustering trabajan con distancias, deberemos basarnos en datos normalizados. Para ello, basandonos en el estudio de correlaciones visto anteriormente para reducir las instancias, nos quedaremos con las variables numéricas más importantes y menos correlacionadas para este estudio.

Creamos los objetos que contendrán los datos que usaremos:

```
mydata.numeric <- seismic[,-c(1,2,3,4,6,8,10,14,15,16,18,19)]
mydata.numeric.scaled <- scale(mydata.numeric)
row.names(mydata.numeric.scaled)<-row.names(mydata.numeric)
```

Antes de comenzar a usar estas técnicas, volveremos a realiazr un análisis *grosso modo* utilizando las técnicas de distantacias Manhalanobis, demostrando como en la anterior sección que estas no pueden aplicarse al dominio de nuestro problema.

```
#Obtenemos los outliers del plot de la sección anterior
is.MCD.outlier <-mvoutlier.plot$outliers
numero.de.outliers.MCD<-sum(is.MCD.outlier, na.rm = T)

#Dibujamos un gráfico de correlación con las medidas Manhalobis
corr.plot(mydata.numeric.scaled[,1], mydata.numeric.scaled[,2])
```

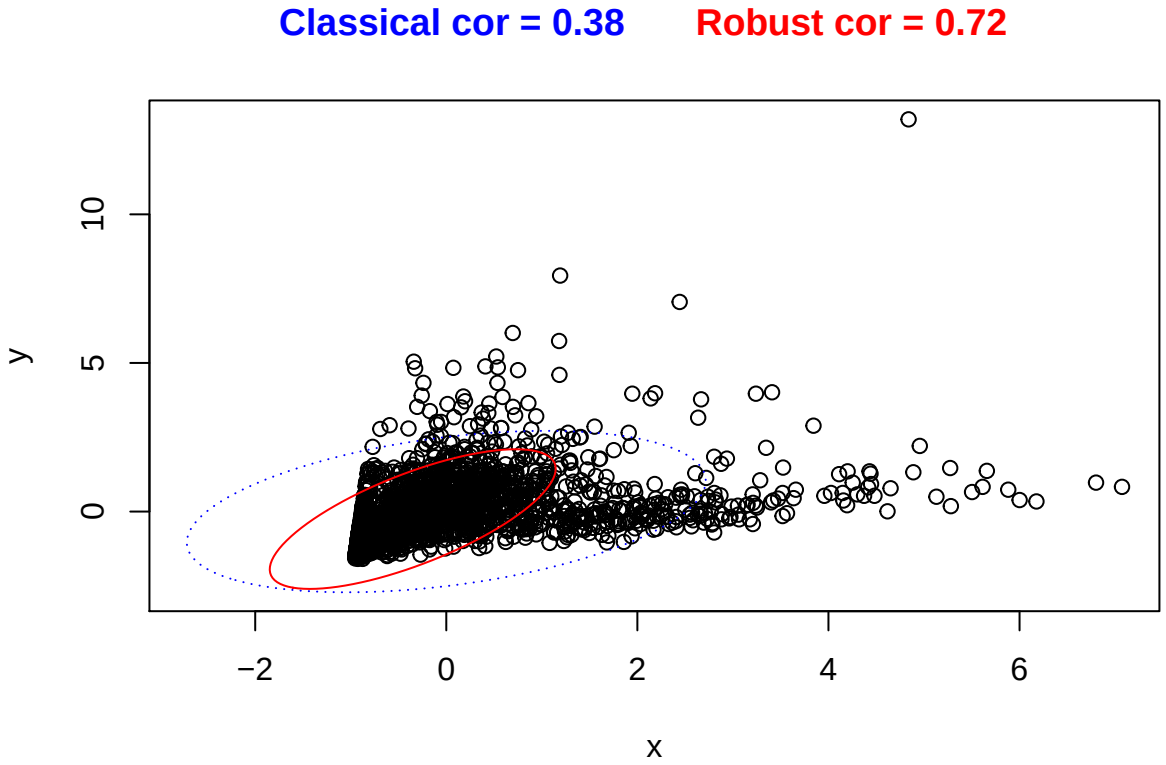


```
## $cor.cla
## [1] 0.3829059
##
## $cor.rob
## [1] 0.7200234
```

Si analiazamos el gráfico anterior, podemos comprobar como la elipse azul (distancia Manhalobis) si que es capaz de discernir entre ciertos outliers, ya que aunque solo hace un grupo, engloba a los más representativos aunque sin duda para neustro problema es muy optimista. Por otro lado, la medida **Manhalobis robusta** (elipse roja) engloba al grupo mayoritario y consideraría outliers todo lo demás, algo que se ajusta para nada a la realidad. Por último, vamos a analizar el biplot, pero eliminaremos algunos datos para obtener una mejor representación:

```
mydata.numeric2<-mydata.numeric[1:500,]
MiBiplot(mydata.numeric2)
```

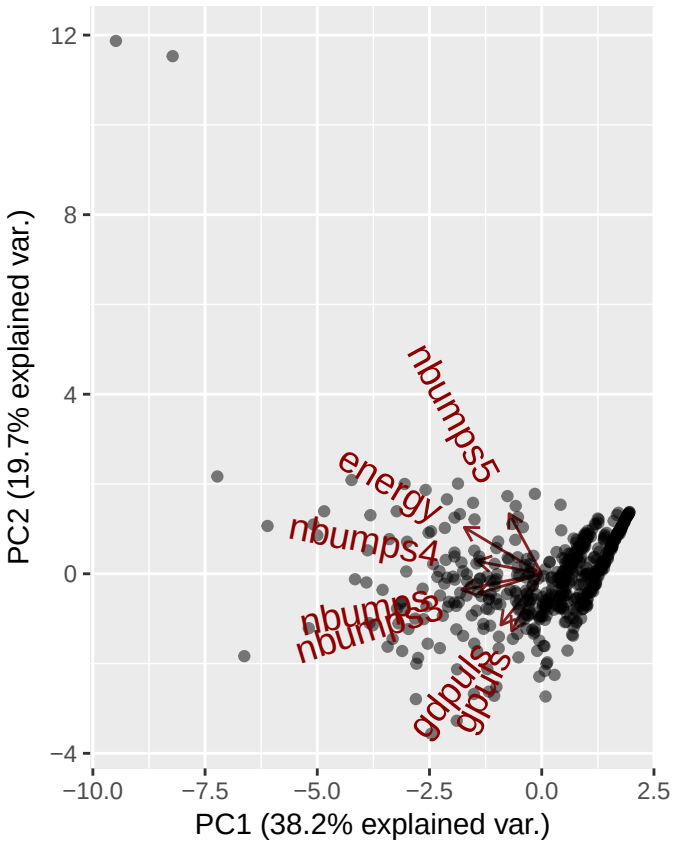

Nuevamente vemos una estrecha correlacion entre las variables, aunque ahora si que podemos ver algo mejor la distribución de los datos que igualmente, tienen mucho solapamiento y problemente variaznas no muy elevadas. Estudiaremos por tanto los outliers con distancia LOF.

El primer paso será obtener el vector con los scrores LOF para cada uno de los ejemplos, para esto, deberemos definir el número de vecinos LOF.

```
numero.de.vecinos.lof = 5
lof.scores<-lofactor(mydata.numeric.scaled,k=numero.de.vecinos.lof)
lof.scores<-lof.scores[is.finite(lof.scores)]
plot(lof.scores)
```

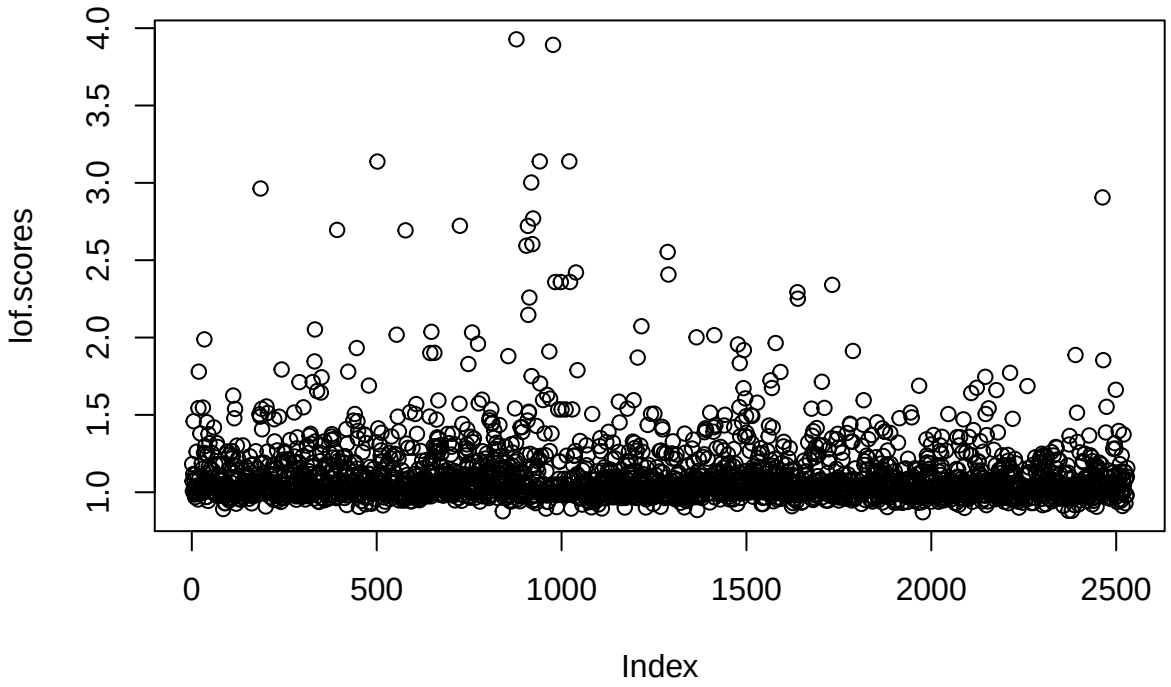

Si análiamos el gráfico, podemos contabilizar unos **25 ejemplos** que salen mucho de lo normal en el gráfico, por lo que usaremos estos ejemplos como partida para la siguiente variable. Además, obtendremos los indices de las muestras que aparecen consideradas como outliers segun la métrica LOF.

```
numero.de.outliers = 25
names(lof.scores)<-1:length(lof.scores)
lof.scores<-sort(lof.scores,decreasing = T)
indices.de.lof.outliers.ordenados <- as.integer(names(lof.scores))
#Seleccionamos los 25 primeros
indices.de.lof.top.outliers<-indices.de.lof.outliers.ordenados[1:25]
```

Por último, obtendremos estos outliers en un vector lógico y utilizaremos la representación biplot.

```
is.lof.outlier<- row.names(mydata.numeric.scaled) %in% indices.de.lof.top.outliers
MiBiPlot_Multivariate_Outliers(mydata.numeric.scaled, is.lof.outlier, "Biplot de los outliers LOF")
```

```
##
```

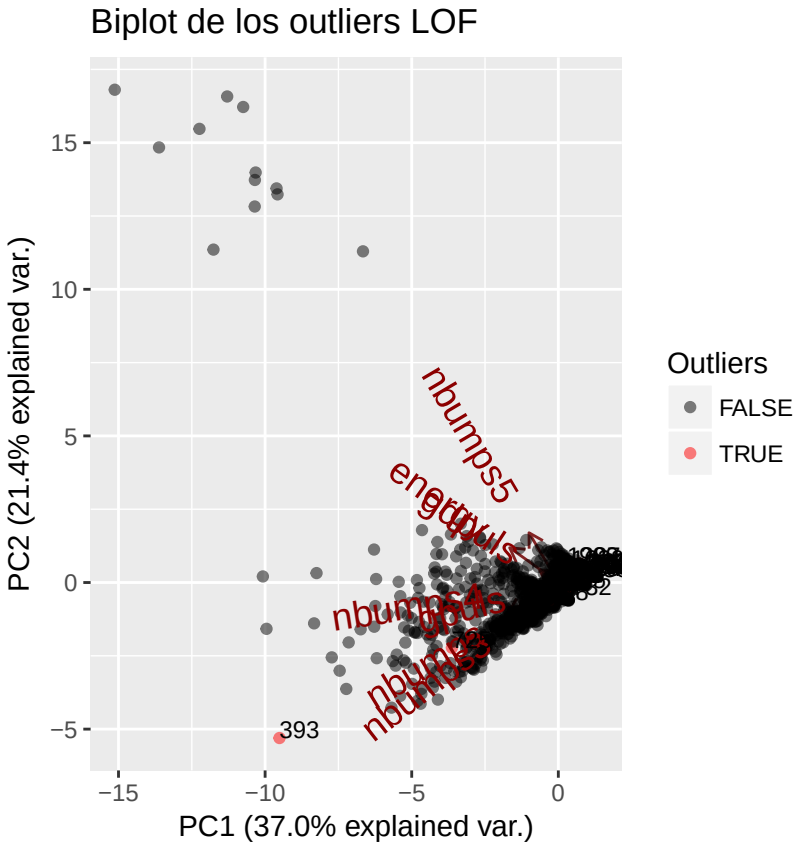

Nuevamente la gran cantidad de datos que tiene el dataset nos dificulta ver donde se situan los outliers, aunque tenemos claro que están sitados en el mismo lugar que nos ofrecia la medida Manhalobis, es decir, reunidos en el centro. Aún así, de este modo, encontramos la medida 393, que está correctamente localizada como outlier y puede ser que sea un outlier 2-variate debido a combinaciones anómalas de las gpuls y nbumps. Vamos a comprobar esta premisa.

```
#Mostramos las variables estadisticas del dataset escalado:
summary(mydata.numeric.scaled)
```

```
##      gpuls             gdpuls             nbumps           nbumps3
##  Min.   :-0.9537   Min.   :-1.5912   Min.   :-0.6299   Min.   :-0.5103
##  1st Qu.:-0.6195   1st Qu.:-0.6413   1st Qu.:-0.6299   1st Qu.:-0.5103
##  Median :-0.2836   Median :-0.1664   Median :-0.6299   Median :-0.5103
##  Mean   : 0.0000   Mean   : 0.0000   Mean   : 0.0000   Mean   : 0.0000
##  3rd Qu.: 0.2318   3rd Qu.: 0.4075   3rd Qu.: 0.1029   3rd Qu.: 0.7889
##  Max.   : 7.0726   Max.   :13.1951   Max.   : 5.9654   Max.   : 8.5840
##     nbumps4           nbumps5             energy
##  Min.   :-0.2427   Min.   :-0.06829   Min.   :-0.2433
##  1st Qu.:-0.2427   1st Qu.:-0.06829   1st Qu.:-0.2433
##  Median :-0.2427   Median :-0.06829   Median :-0.2433
##  Mean   : 0.0000   Mean   : 0.00000   Mean   : 0.0000
##  3rd Qu.:-0.2427   3rd Qu.:-0.06829   3rd Qu.:-0.1161
##  Max.   :10.5077   Max.   :14.63729   Max.   :19.4136
```

```
#Mostramos los valores para la muestra:
mydata.numeric.scaled[c(393,878,1021,502),]
```

```
##           gpuls     gdpuls     nbumps    nbumps3    nbumps4    nbumps5
```

```
## 393   1.6767376  1.1634495  5.9653978  8.5840132  3.3407840 -0.0682922
## 878  -0.8736819 -0.1188746  0.8357512  0.7888664 -0.2426888 -0.0682922
## 1021 -0.8879003 -0.1030435 -0.6298621 -0.5103247 -0.2426888 -0.0682922
## 502  -0.9092278 -0.6254718 -0.6298621 -0.5103247 -0.2426888 -0.0682922
##            energy
## 393   2.191828989
## 878  -0.008570355
## 1021 -0.243279618
## 502  -0.243279618
```

Parece que todos las otras observaciones que hemos comprobado, siguen una cierta pogresión en nbumps, que son el número de medidas de cierta energia de manera ordinal que se obtienen, pero la que salio de ojo en neustro estudio la 393, tiene una gran diferencia con todas las demás en este punto, por lo que puede ser un outlier debido además de porque contiene outliers en sus columnas, la combinacion de datos en la variables nbumps es muy anómala.

Comparacion LOF con outliers en una sola dimensión

En primer lugar, obtenemos los outliers IQR.

```
vector.claves.outliers.IQR.en.alguna.columna<-vector_claves_outliers_IQR_en_alguna_columna(mydata.numeri
vector.es.outlier.IQR.en.alguna.columna <- vector_es_outlier_IQR_en_alguna_columna(mydata.numeric.scale
vector.claves.outliers.IQR.en.alguna.columna<-unique(vector.claves.outliers.IQR.en.alguna.columna)
MiBiPlot_Multivariate_Outliers(mydata.numeric.scaled, vector.es.outlier.IQR.en.alguna.columna, "Biplot
```

```
##                 16                 31    34    37                 53        60        68    71
```

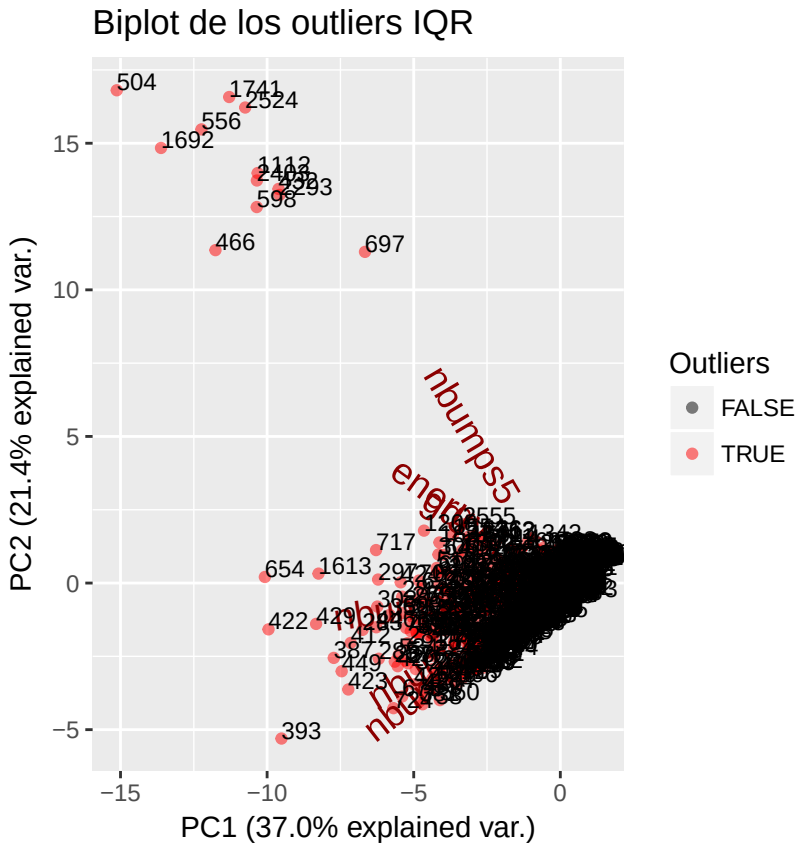

Vemos como el número de outliers aumentan y se localiazan aquellos que tienen datos anómalos en una

columna al menos. Tras obtener estos, los comparamos con **setdiff** con aquellos que son outliers LOF, quedandonos solo con aquellos que son outliers por combinación de variables.

```
indices.de.outliers.multivariantes.LOF.pero.no.1variantes<-setdiff(indices.de.lof.top.outliers, vector.
```

Por último vamos a mostrar sobre los datos reales estos ejemplos y compararlos con las medidas estadísticas básicas para ver que puede ocurrir con ellos

```
summary(mydata.numeric.scaled)
```

```
##      gpuls             gdpuls            nbumps           nbumps3
##  Min.   :-0.9537   Min.   :-1.5912   Min.   :-0.6299   Min.   :-0.5103
##  1st Qu.:-0.6195   1st Qu.:-0.6413   1st Qu.:-0.6299   1st Qu.:-0.5103
##  Median :-0.2836   Median :-0.1664   Median :-0.6299   Median :-0.5103
##  Mean   : 0.0000   Mean   : 0.0000   Mean   : 0.0000   Mean   : 0.0000
##  3rd Qu.: 0.2318   3rd Qu.: 0.4075   3rd Qu.: 0.1029   3rd Qu.: 0.7889
##  Max.   : 7.0726   Max.   :13.1951   Max.   : 5.9654   Max.   : 8.5840
##     nbumps4           nbumps5            energy
##  Min.   :-0.2427   Min.   :-0.06829   Min.   :-0.2433
##  1st Qu.:-0.2427   1st Qu.:-0.06829   1st Qu.:-0.2433
##  Median :-0.2427   Median :-0.06829   Median :-0.2433
##  Mean   : 0.0000   Mean   : 0.00000   Mean   : 0.0000
##  3rd Qu.:-0.2427   3rd Qu.:-0.06829   3rd Qu.:-0.1161
##  Max.   :10.5077   Max.   :14.63729   Max.   :19.4136
```

```
mydata.numeric.scaled[indices.de.outliers.multivariantes.LOF.pero.no.1variantes,]
```

```
##           gpuls       gdpuls     nbumps    nbumps3    nbumps4    nbumps5
## 878  -0.8736819 -0.118874628  0.8357512  0.7888664 -0.2426888 -0.0682922
## 977  -0.8950094 -0.577978332 -0.6298621 -0.5103247 -0.2426888 -0.0682922
## 941  -0.8950094 -1.227055981 -0.6298621 -0.5103247 -0.2426888 -0.0682922
## 1021 -0.8879003 -0.103043466 -0.6298621 -0.5103247 -0.2426888 -0.0682922
## 502  -0.9092278 -0.625471818 -0.6298621 -0.5103247 -0.2426888 -0.0682922
## 918  -0.7990355  0.118592804 -0.6298621 -0.5103247 -0.2426888 -0.0682922
## 186  -0.6479653 -1.227055981 -0.6298621 -0.5103247 -0.2426888 -0.0682922
## 2463 -0.5235546 -0.688796467 -0.6298621 -0.5103247 -0.2426888 -0.0682922
## 909  -0.7190572  1.464241590 -0.6298621 -0.5103247 -0.2426888 -0.0682922
## 578  -0.4311352  0.007774669 -0.6298621 -0.5103247 -0.2426888 -0.0682922
## 921  -0.8967867 -0.688796467 -0.6298621 -0.5103247 -0.2426888 -0.0682922
## 905  -0.6692929 -0.213861601  0.8357512 -0.5103247 -0.2426888 -0.0682922
## 1039 -0.9056732 -0.514653683 -0.6298621 -0.5103247 -0.2426888 -0.0682922
## 1289 -0.5715416 -0.752121116 -0.6298621 -0.5103247 -0.2426888 -0.0682922
## 983  -0.9038959 -0.467160196 -0.6298621 -0.5103247 -0.2426888 -0.0682922
## 998  -0.9056732 -0.514653683 -0.6298621 -0.5103247 -0.2426888 -0.0682922
## 1023 -0.9163370 -0.736289953 -0.6298621 -0.5103247 -0.2426888 -0.0682922
## 1638  0.6352423 -0.419666710 -0.6298621 -0.5103247 -0.2426888 -0.0682922
## 913  -0.8647954 -0.672965305 -0.6298621 -0.5103247 -0.2426888 -0.0682922
## 1639  0.2175777  1.321761130 -0.6298621 -0.5103247 -0.2426888 -0.0682922
##            energy
## 878  -0.008570355
## 977  -0.243279618
## 941  -0.243279618
## 1021 -0.243279618
## 502  -0.243279618
## 918  -0.243279618
## 186  -0.243279618
```

```
## 2463 -0.243279618
## 909  -0.243279618
## 578  -0.243279618
## 921  -0.243279618
## 905  -0.194381855
## 1039 -0.243279618
## 1289 -0.243279618
## 983  -0.243279618
## 998  -0.243279618
## 1023 -0.243279618
## 1638 -0.243279618
## 913  -0.243279618
## 1639 -0.243279618
```

Es complicado ver que variables pueden estar influenciadas en estos outliers, ya que aunque todas están dentro del baremo habra ciertas tendencias que un experto en la materia sería capaz de analizar y de las cuales obtendría información muy relevante de cara al enfoque posterior del problema.

Ampliación

Dado que siempre utilizamos las columnas numéricas, usaremos la función sapply para obtener solo las columnas numéricas del dataframe:

```
numericseismic<-seismic[,sapply(seismic, is.numeric)]
```

Análisis multivariante basados en clustering

En esta última sección usaremos análisis basados en clustering para la identificación de outliers. Estos enfoques residen en la obtención de distancias a los centroides de cluster, catalagoando como outliers aquellos ejemplos que queden fuera del 'radio' de una determianada distancia.

Para evitar posibles problemas y cambios sobre los datos reales que se hayan llevado a cabo en procesos anteriores, volveremos a declarar nuestros datos. Dado que trabajaremos con distancias, estos deberán estar una vez más normalizados.

```
mydata.numeric <- seismic[,-c(1,2,3,4,6,8,10,14,15,16,18,19)]
mydata.numeric.scaled <- scale(mydata.numeric)
row.names(mydata.numeric.scaled)<-row.names(mydata.numeric)
```

Declaramos también una serie de variables globales que serán utilizadas en procesos posteriores como el número de clusters y los outliers, que acorde a lo visto en la etapa anterior podría ser 20. También fijaremos una semilla para poder replicar los experimentos.

```
numero.de.outliers   <- 20
numero.de.clusters   <- 3
set.seed(2)  # Para establecer la semilla para la primera iteración de kmeans
```

Comenzaremos creando un modelo k-means, del cual obtendremos los indices del cluster y los centros.

```
modelo.kmeans <- kmeans(mydata.numeric.scaled,numero.de.clusters)
indices.clustering <- modelo.kmeans$cluster
centroides.normalizados <- modelo.kmeans$centers
```

Ahora, calcularemos la distancia euclidea para cada ejemplo con su centroide, para ello podemos usar la siguiente función:

```
distancias_a_centroides <- function (datos.normalizados, indices.asignacion.clustering, datos.centroides
{
  sqrt(rowSums(   (datos.normalizados - datos.centroides.normalizados[indices.asignacion.clustering,])^
}

dist.centroides <- distancias_a_centroides(mydata.numeric.scaled, indices.clustering, centroides.normali

# Ordenamos las distancias
dist.centroides <- dist.centroides[order(dist.centroides, decreasing = T)]

# Nos quedamos con las mayores que serán los outliers
dist.centroides <- dist.centroides[1:numero.de.outliers]
dist.centroides
```

```
##       504      1692      1741      2524       556      1112       466
## 22.143953 20.842418 18.751465 18.668476 18.637182 16.355337 16.348843
##      2403       598      2293       432       697       393       422
## 16.233300 15.997292 15.975624 15.971244 14.425771  9.263867  8.832334
##       654      1342      1693       223       423       224
##  8.740730  8.152515  7.562146  6.574908  6.347526  6.257301
```

Dado que estas tareas que hemos realizado, se suelen realizar con bastante regularidad, generalizaremos las operaciones en una función:

```
top_clustering_outliers <- function(datos.normalizados, indices.asignacion.clustering, datos.centroides
{
  dist.centroides <- distancias_a_centroides(datos.normalizados, indices.asignacion.clustering, datos.c
  dist.centroides <- dist.centroides[order(dist.centroides, decreasing = T)]
  dist.centroides <- dist.centroides[1:numero.de.outliers]

  return(list("Indices"=as.integer(names(dist.centroides)),
              "Distancias"=unname(dist.centroides)))
}

listaoutliers<-top_clustering_outliers(mydata.numeric.scaled, indices.clustering, centroides.normalizad

listaoutliers
```

```
## $Indices
##  [1]  504 1692 1741 2524  556 1112  466 2403  598 2293  432  697  393  422
## [15]  654 1342 1693  223  423  224
##
## $Distancias
##  [1] 22.143953 20.842418 18.751465 18.668476 18.637182 16.355337 16.348843
##  [8] 16.233300 15.997292 15.975624 15.971244 14.425771  9.263867  8.832334
## [15]  8.740730  8.152515  7.562146  6.574908  6.347526  6.257301
```

Ahora, dibujaremos los datos en un biplot, pero dejando los colores en funcion de los cluster creados.

```
numero.de.datos   = nrow(mydata.numeric.scaled)
is.kmeans.outlier = rep(FALSE, numero.de.datos)
is.kmeans.outlier[listaoutliers$Indices] <- TRUE


BIPLOT.isOutlier             = is.kmeans.outlier
BIPLOT.cluster.colors        = c("blue","red","brown")
```

```
BIPLOT.asignaciones.clusters = indices.clustering
MiBiPlot_Clustering_Outliers(mydata.numeric.scaled, "K-Means Clustering Outliers")
```

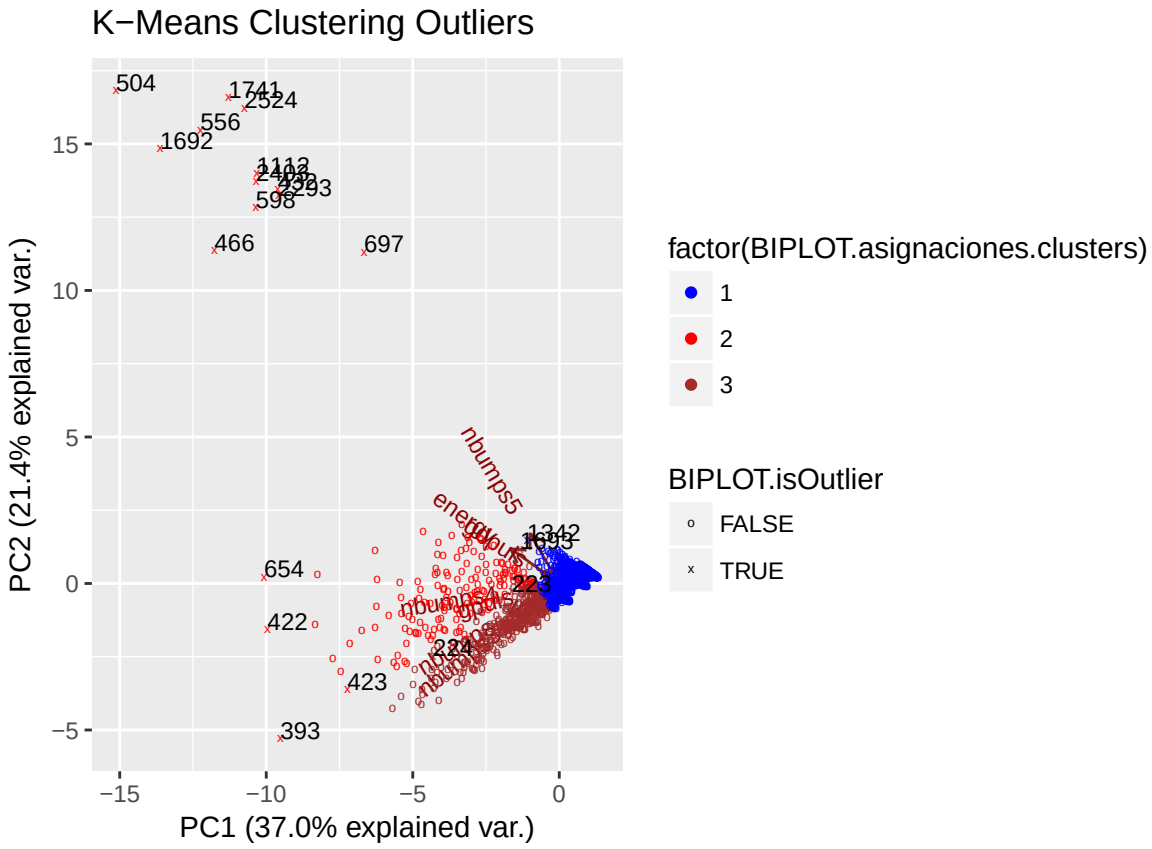

Por último puede resultar interesante revertir el proceso de normalización de los datos sobre los centroides obtenidos. Para ello, tendremos que utilizar la siguiente formula:

z-score = (dato - media.columna) / sd.columna

```
#obtenemos la media de cada columna
mis.datos.medias<- colMeans(modelo.kmeans$centers)

#obtenemos las desviaciones típicas
mis.datos.desviaciones <- apply(modelo.kmeans$centers,2,sd)

#multiplicamos cada dato del centroide por la desviación de cada columna
centroides.por.desviacion<-sweep(centroides.normalizados,2,mis.datos.desviaciones,"*")

#por último sumamos las medias y ya tenemos los valores reales
centroides.valores<-sweep(centroides.por.desviacion,2,mis.datos.medias,"+")
centroides.valores
```

```
##       gpuls    gdpuls    nbumps   nbumps3   nbumps4   nbumps5    energy
## 1 0.3715413 0.1669847 0.4150628 0.2842089 0.4700631 0.2367932 0.4477519
## 2 1.2674007 0.2870143 2.3140105 1.2030685 8.3265039 0.8589054 4.4704760
## 3 1.2248891 0.2412342 2.2525744 2.0402926 0.4700631 0.2367932 0.8330207
```

Ampliación:

En la ampliación de las sección de análisis de outliers basado en clustering, usaremos clustering basado en medoides en lugar de centros, es decir PAM (partition around medoids).

El primer paso será obtener las distancias de cada uno de los objetos, sobre las que después utilizaremos la función, pam del paquete cluster.

```
m.dist<-dist(mydata.numeric, method = "euclidean")
modelo.pam<-pam(m.dist, k=numero.de.clusters)
modelo.pam$medoids
```

```
## [1] 1972 2048  320
```

Ya tenemos nuestros medoides y los registros con su cluster asociado. Podemos obtener los registros pertenecientes por tanto a los medoides normalizados y sin normalizar.

```
medoides.valores<-mydata.numeric[modelo.pam$medoids,]
medoides.valores
```

```
##      gpuls gdpuls nbumps nbumps3 nbumps4 nbumps5 energy
## 1972   350    -26      1       0       0       0    100
## 2048   719     32      1       1       0       0   7000
## 320   1268    -26      1       0       1       0  70000
```

```
medoides.valores.normalizados<-mydata.numeric.scaled[modelo.pam$medoids,]
medoides.valores.normalizados
```

```
##           gpuls     gdpuls    nbumps    nbumps3    nbumps4    nbumps5
## 1972 -0.3351613 -0.4829914 0.1029446 -0.5103247 -0.2426888 -0.0682922
## 2048  0.3206609  0.4352160 0.1029446  0.7888664 -0.2426888 -0.0682922
## 320   1.2963963 -0.4829914 0.1029446 -0.5103247  3.3407840 -0.0682922
##           energy
## 1972 -0.23838984
## 2048  0.09900472
## 320   3.17956381
```

Llegados a este punto, ya tenemos todos los datos necesarios para obtener los cluster haciendo uso de la función top_clustering_outliers que implementamos anteriormente.

```
top.pam<-top_clustering_outliers(mydata.numeric.scaled, modelo.pam$clustering, medoides.valores.normali
top.pam
```

```
## $Indices
##  [1]  504 1692 1741  556 2524  466 2403 1112  598  432 2293  697  393  422
## [15]  654 1342  423 1693  449  223
##
## $Distancias
##  [1] 22.452801 21.828706 19.137954 19.066632 18.945061 17.341406 17.050341
##  [8] 16.951710 16.831815 16.723339 16.639371 15.241078 10.995744  9.672946
## [15]  9.085491  8.590746  8.275864  8.064713  7.610792  7.319739
```

Los siguientes puntos, están basados en el código del profesor de la asignatura (J.C. Cubero).

```
top_clustering_outliers_distancia_relativa = function(datos.normalizados,
                                                      indices.asignacion.clustering,
                                                      datos.centroides.normalizados,
                                                      numero.de.outliers){

  dist_centroides = distancias_a_centroides (datos.normalizados,
```

```
                                          indices.asignacion.clustering,
                                          datos.centroides.normalizados)

  cluster.ids = unique(indices.asignacion.clustering)
  k           = length(cluster.ids)

  distancias.a.centroides.por.cluster    = sapply(1:k ,
                                                  function(x) dist_centroides [indices.asignacion.cluste

  distancias.medianas.de.cada.cluster    = sapply(1:k ,
                                                  function(x) median(dist_centroides[[x]]))

  todas.las.distancias.medianas.de.cada.cluster  = distancias.medianas.de.cada.cluster[indices.asignacio
  ratios = dist_centroides   /  todas.las.distancias.medianas.de.cada.cluster

  indices.top.outliers           = order(ratios, decreasing=T)[1:numero.de.outliers]

  list(distancias = ratios[indices.top.outliers]  , indices = indices.top.outliers)
}


top.outliers.kmeans.distancia.relativa = top_clustering_outliers_distancia_relativa(mydata.numeric.scale


cat("Índices de los top k clustering outliers (k-means, usando distancia relativa)")
```

```
## Índices de los top k clustering outliers (k-means, usando distancia relativa)
```

```
top.outliers.kmeans.distancia.relativa$indices
```

```
##  [1]  504 1692 1741 2524  556 1112  466 2403  598 2293  432  697 1342 1693
## [15]  393  422  654 1798  223 2550
```

```
cat("Distancias a sus centroides de los top k clustering outliers (k-means, usando distancia relativa)")
```

```
## Distancias a sus centroides de los top k clustering outliers (k-means, usando distancia relativa)
```

```
top.outliers.kmeans.distancia.relativa$distancias
```

```
##       504      1692      1741      2524       556      1112       466
## 11.867644 11.170111 10.049503 10.005027  9.988255  8.765342  8.761862
##      2403       598      2293       432       697      1342      1693
##  8.699939  8.573455  8.561842  8.559495  7.731227  6.169236  5.332857
##       393       422       654      1798       223      2550
##  4.964799  4.733527  4.684434  4.666775  4.636652  4.540024
```