

Detección de Anomalías

joseangeldiazg

19/2/2018

Datos

Vamos a trabajar con el dataset Seismic, que contiene informacion sobre medidas sísmicas. Trata de detectar el peligro sísmico en función de ciertas características de medida y registros. Sus datos, en inglés, son:

Attribute information:

- 1. seismic: result of shift seismic hazard assessment in the mine working obtained by the seismic method (a - lack of hazard, b - low hazard, c - high hazard, d - danger state);
- 2. seismoacoustic: result of shift seismic hazard assessment in the mine working obtained by the seismoacoustic method;
- 3. shift: information about type of a shift (W - coal-getting, N -preparation shift);
- 4. genenergy: seismic energy recorded within previous shift by the most active geophone (GMax) out of geophones monitoring the longwall;
- 5. gpuls: a number of pulses recorded within previous shift by GMax;
- 6. gdenergy: a deviation of energy recorded within previous shift by GMax from average energy recorded during eight previous shifts;
- 7. gdpuls: a deviation of a number of pulses recorded within previous shift by GMax from average number of pulses recorded during eight previous shifts;
- 8. ghazard: result of shift seismic hazard assessment in the mine working obtained by the seismoacoustic method based on registration coming from GMax only; - 9. nbumps: the number of seismic bumps recorded within previous shift;
- 10. nbumps2: the number of seismic bumps (in energy range $[10^2, 10^3)$) registered within previous shift;
- 11. nbumps3: the number of seismic bumps (in energy range $[10^3, 10^4)$) registered within previous shift;
- 12. nbumps4: the number of seismic bumps (in energy range $[10^4, 10^5)$) registered within previous shift;
- 13. nbumps5: the number of seismic bumps (in energy range $[10^5, 10^6)$) registered within the last shift;
- 14. nbumps6: the number of seismic bumps (in energy range $[10^6, 10^7)$) registered within previous shift;
- 15. nbumps7: the number of seismic bumps (in energy range $[10^7, 10^8)$) registered within previous shift;
- 16. nbumps89: the number of seismic bumps (in energy range $[10^8, 10^{10})$) registered within previous shift;
- 17. energy: total energy of seismic bumps registered within previous shift;
- 18. maxenergy: the maximum energy of the seismic bumps registered within previous shift;
- 19. class: the decision attribute - '1' means that high energy seismic bump occurred in the next shift ('hazardous state'), '0' means that no high energy seismic bumps occurred in the next shift ('non-hazardous state').

Los datos han sido recopilados del repositorio UCI y vienen en formato arrf.

```
library(foreign)
seismic<-read.arff("data/seismic-bumps.arff")
head(seismic,5)
```

```
## seismic seismoacoustic shift genergy gpuls gdenergy gdpuls ghazard
## 1      a              a      N   15180   48    -72   -72      a
## 2      a              a      N   14720   33    -70   -79      a
## 3      a              a      N    8050   30    -81   -78      a
## 4      a              a      N   28820  171    -23    40      a
## 5      a              a      N   12640   57    -63   -52      a
## nbumps nbumps2 nbumps3 nbumps4 nbumps5 nbumps6 nbumps7 nbumps89 energy
## 1      0      0      0      0      0      0      0      0      0
## 2      1      0      1      0      0      0      0      0    2000
## 3      0      0      0      0      0      0      0      0      0
## 4      1      0      1      0      0      0      0      0    3000
## 5      0      0      0      0      0      0      0      0      0
## maxenergy class
## 1      0      0
## 2     2000     0
## 3      0      0
## 4     3000     0
## 5      0      0
```

```
str(seismic)
```

```
## 'data.frame': 2584 obs. of 19 variables:
## $ seismic : Factor w/ 2 levels "a","b": 1 1 1 1 1 1 1 1 1 1 ...
## $ seismoacoustic: Factor w/ 3 levels "a","b","c": 1 1 1 1 1 1 1 1 1 1 ...
## $ shift : Factor w/ 2 levels "N","W": 1 1 1 1 1 2 2 1 1 2 ...
## $ genergy : num 15180 14720 8050 28820 12640 ...
## $ gpuls : num 48 33 30 171 57 195 614 194 303 675 ...
## $ gdenergy : num -72 -70 -81 -23 -63 -73 -6 -27 54 4 ...
## $ gdpuls : num -72 -79 -78 40 -52 -65 18 -3 52 25 ...
## $ ghazard : Factor w/ 3 levels "a","b","c": 1 1 1 1 1 1 1 1 1 1 ...
## $ nbumps : num 0 1 0 1 0 0 2 1 0 1 ...
## $ nbumps2 : num 0 0 0 0 0 0 2 0 0 1 ...
## $ nbumps3 : num 0 1 0 1 0 0 0 1 0 0 ...
## $ nbumps4 : num 0 0 0 0 0 0 0 0 0 0 ...
## $ nbumps5 : num 0 0 0 0 0 0 0 0 0 0 ...
## $ nbumps6 : num 0 0 0 0 0 0 0 0 0 0 ...
## $ nbumps7 : num 0 0 0 0 0 0 0 0 0 0 ...
## $ nbumps89 : num 0 0 0 0 0 0 0 0 0 0 ...
## $ energy : num 0 2000 0 3000 0 0 1000 4000 0 500 ...
## $ maxenergy : num 0 2000 0 3000 0 0 700 4000 0 500 ...
## $ class : Factor w/ 2 levels "0","1": 1 1 1 1 1 1 1 1 1 1 ...
```

Para este análisis nos quedaremos con las variables numéricas, eliminando todas las demas de nuestros datos. Dado el caracter de las funciones que usaremos, ademas tendremos que definir un indice de columna y un nomre para los gráficos.

```
mydata.numeric = seismic[,-c(1,2,3,8,19)]
indice.columna = 1
nombre.mydata = "seismic"
head(mydata.numeric,5)
```

```
## genergy gpuls gdenergy gdpuls nbumps nbumps2 nbumps3 nbumps4 nbumps5
```

```
## 1 15180 48 -72 -72 0 0 0 0 0
## 2 14720 33 -70 -79 1 0 1 0 0
## 3 8050 30 -81 -78 0 0 0 0 0
## 4 28820 171 -23 40 1 0 1 0 0
## 5 12640 57 -63 -52 0 0 0 0 0
## nbumps6 nbumps7 nbumps89 energy maxenergy
## 1 0 0 0 0 0
## 2 0 0 0 2000 2000
## 3 0 0 0 0 0
## 4 0 0 0 3000 3000
## 5 0 0 0 0 0
```

Por último para facilitar tambien procesos posteriores obtendremos los datos escalados:

```
mydata.numeric.scaled<-scale(mydata.numeric)
columna<-mydata.numeric[indice.columna]
nombre.columna<-names(columna)
columna.scaled<-mydata.numeric.scaled[,nombre.columna]
```

Análisis estadístico de Outliers en una variable mediante IQR

En esta primera parte se obtendrán los outliers de manera manual sin utilizar funciones. Para obtener estos, usaremos el IQR, o lo que es lo mismo la distancia intercuartil, es decir, necesitaremos obtener el primer cuartil, el tercer cuartil y la diferencia entre ambos.

```
cuartil.primerio<-quantile(columna.scaled,0.25)
cuartil.primerio
```

```
##      25%
## -0.3428549
```

```
cuartil.tercero<-quantile(columna.scaled,0.75)
cuartil.tercero
```

```
##      75%
## -0.1632196
```

```
iqr<-IQR(columna.scaled)
iqr
```

```
## [1] 0.1796353
```

Ahora debemos obtener los límites normales y extremops, que se calcularán de la siguiente manera:

- extremo.superior.outlier.normal = cuartil tercero + 1.5 IQR
- extremo.inferior.outlier.normal = cuartil primero - 1.5 IQR
- extremo.superior.outlier.extremo = cuartil tercero + 3 IQR
- extremo.inferior.outlier.extremo = cuartil primero - 3 IQR

```
extremo.superior.outlier.normal<-cuartil.tercero+1.5*iqr
extremo.inferior.outlier.normal<-cuartil.primerio-1.5*iqr
extremo.superior.outlier.extremo<-cuartil.tercero+3*iqr
extremo.inferior.outlier.extremo<-cuartil.primerio-3*iqr
```

Una vez tenemos todas estas variables, deberemos estudiar si hay outliers comparando la columna con el valor minimo y maximo de outliers normales y extremos.

Calculamos los **outliers normales**:

```
vector.es.outlier.normal<-columna.scaled>extremo.superior.outlier.normal | columna.scaled<extremo.inferior
```

Calculamos los **outliers extremos**:

```
vector.es.outlier.extremo<-columna.scaled>extremo.superior.outlier.extremo | columna.scaled<extremo.inferior
```

En base a los resultados obtenidos parece que estamos ante un problema con bastantes outliers, y dado que estos provienen de sensores sismicos, el problema es a la par complejo e interesante porque a muy seguro estos outliers, valores que se salen del las tablas por decirlo de alguna manera, indicarán o podrán indicar un riesgo de terremoto alto. Vamos a analizar estos outliers.

Índices y valores de los outliers

Vamos a obtener los indices de los outliers, para posteriormente mostrar todos sus datos.

Para los normales:

```
claves.outliers.normales<-which(vector.es.outlier.normal)
claves.outliers.normales
```

```
##      [1]      7     10     13     16     25     28     30     31     33     34     36     37     46     49
##     [15]     52     58     60     66     67     68     71     74     75     77     79     81     84     86
##     [29]     87     89     91     94     97    100    102    108    109    111    112    114    115    117
##     [43]    118    119    120    121    123    124    125    126    128    129    130    132    133    135
##     [57]    136    138    139    141    142    144    146    150    151    153    154    156    157    159
##     [71]    160    162    163    165    166    167    168    169    170    171    172    174    175    176
##     [85]    177    178    180    181    182    183    184    187    188    189    190    191    192    193
##     [99]    194    195    196    197    198    199    200    201    202    203    204    205    206    207
##    [113]    208    209    210    211    212    213    214    215    216    217    218    219    220    221
##    [127]    222    223    224    225    226    227    228    229    230    231    232    233    234    235
##    [141]    236    237    238    239    240    241    242    243    244    245    246    247    248    249
##    [155]    250    251    252    253    254    255    256    257    258    259    260    261    262    263
##    [169]    264    265    266    267    268    269    270    271    272    273    274    275    276    277
##    [183]    278    279    280    281    282    283    284    285    286    287    288    289    296    297
##    [197]    298    299    300    301    302    303    304    305    306    307    308    309    310    314
##    [211]    315    316    317    318    319    320    321    322    323    324    325    326    327    328
##    [225]    329    330    331    335    336    337    338    339    340    341    342    343    344    345
##    [239]    346    347    348    350    351    352    353    354    355    356    357    358    362    363
##    [253]    364    365    381    384    387    390    391    392    393    399    558    665    666    672
##    [267]    675    681    682    684    686    687    688    689    690    693    694    695    696    700
##    [281]    702    703    704    705    706    707    708    713    714    715    716    717    718    719
##    [295]    720    721    722    723    724    725    735    737    738    823    825    826    828    831
##    [309]    843    844    846    847    849    850    852    853    854    855    861    862    864    865
##    [323]    870    873    882    883    936    937   1692   2178   2180   2181   2211   2214
```

```
data.frame.outliers.normales<-data.frame(mydata.numeric[claves.outliers.normales,])
data.frame.outliers.normales
```

```
##      genergy gpuls gdenenergy gdpuls nbumps nbumps2 nbumps3 nbumps4 nbumps5
## 7      207930   614         -6     18      2      2      0      0      0
## 10     247620   675          4     25      1      1      0      0      0
## 13     166180   448        -30    -19      1      1      0      0      0
## 16     225040   575         -3      5      2      0      2      0      0
## 25     424650  1069          1      7      2      0      2      0      0
## 28     212260   729        -50    -28      2      1      1      0      0
## 30     172290   437        -57    -55      1      1      0      0      0
```

## 31	395110	1043	46	40	3	0	3	0	0
## 33	144880	361	-46	-52	1	0	1	0	0
## 34	477750	1132	86	60	3	3	0	0	0
## 36	127360	351	-54	-53	1	1	0	0	0
## 37	514800	1369	95	94	7	4	2	1	0
## 46	250030	687	-8	-5	0	0	0	0	0
## 49	309010	983	15	38	2	1	1	0	0
## 52	248900	739	-9	0	1	1	0	0	0
## 58	269070	767	-1	4	2	2	0	0	0
## 60	372770	975	37	32	3	3	0	0	0
## 66	147520	472	-2	-6	0	0	0	0	0
## 67	202640	588	-33	-41	2	1	1	0	0
## 68	259110	1409	-11	46	1	1	0	0	0
## 71	590510	1780	23	-6	1	1	0	0	0
## 74	317360	1068	-36	-44	0	0	0	0	0
## 75	227990	734	-52	-59	2	1	1	0	0
## 77	210960	773	-44	-35	1	0	1	0	0
## 79	302440	1250	-16	9	2	2	0	0	0
## 81	436650	1232	23	6	0	0	0	0	0
## 84	169370	644	-53	-45	0	0	0	0	0
## 86	233810	839	-31	-24	0	0	0	0	0
## 87	149050	697	-54	-35	1	0	1	0	0
## 89	194580	697	-35	-32	0	0	0	0	0
## 91	194580	697	-35	-32	0	0	0	0	0
## 94	285750	791	1	-19	0	0	0	0	0
## 97	298230	916	9	-2	0	0	0	0	0
## 100	172120	537	-35	-41	0	0	0	0	0
## 102	270040	717	10	-14	2	2	0	0	0
## 108	166700	363	-34	-56	0	0	0	0	0
## 109	274170	997	15	34	0	0	0	0	0
## 111	226790	717	2	0	0	0	0	0	0
## 112	134640	611	-41	-16	0	0	0	0	0
## 114	328050	707	51	0	1	1	0	0	0
## 115	140090	380	-40	-46	0	0	0	0	0
## 117	157740	440	-31	-35	0	0	0	0	0
## 118	325750	1068	50	67	1	0	1	0	0
## 119	300520	894	37	37	0	0	0	0	0
## 120	465730	1325	-7	-12	1	0	1	0	0
## 121	336600	984	-32	-34	1	0	1	0	0
## 123	951410	1332	98	-7	0	0	0	0	0
## 124	203850	476	-14	-32	1	0	1	0	0
## 125	715390	1923	36	36	1	1	0	0	0
## 126	160350	828	-31	23	0	0	0	0	0
## 128	373180	1246	-32	-14	1	0	1	0	0
## 129	481630	1678	-10	17	0	0	0	0	0
## 130	620720	1789	17	23	0	0	0	0	0
## 132	280830	689	94	39	1	0	1	0	0
## 133	557230	1642	2	11	0	0	0	0	0
## 135	270490	865	83	78	0	0	0	0	0
## 136	307540	1020	-44	-32	0	0	0	0	0
## 138	314100	904	-41	-37	0	0	0	0	0
## 139	368340	1325	-28	-4	1	0	1	0	0
## 141	316200	1089	-37	-21	3	1	2	0	0
## 142	209760	919	46	89	0	0	0	0	0

## 144	372380	1264	-26	-9	0	0	0	0	0
## 146	396530	1209	-10	-13	1	0	1	0	0
## 150	303610	1034	-26	-21	0	0	0	0	0
## 151	278230	1060	-31	-18	1	1	0	0	0
## 153	498960	1447	30	17	1	1	0	0	0
## 154	443740	1321	20	10	0	0	0	0	0
## 156	788230	1484	-1	-1	0	0	0	0	0
## 157	119460	269	-70	-64	0	0	0	0	0
## 159	1049580	1807	31	21	0	0	0	0	0
## 160	715540	1471	-13	-4	2	2	0	0	0
##	nbumps6	nbumps7	nbumps8	nbumps9	energy	maxenergy			
## 7	0	0	0	0	1000	7e+02			
## 10	0	0	0	0	500	5e+02			
## 13	0	0	0	0	400	4e+02			
## 16	0	0	0	0	7000	6e+03			
## 25	0	0	0	0	6000	4e+03			
## 28	0	0	0	0	1400	1e+03			
## 30	0	0	0	0	600	6e+02			
## 31	0	0	0	0	6000	2e+03			
## 33	0	0	0	0	2000	2e+03			
## 34	0	0	0	0	1500	6e+02			
## 36	0	0	0	0	700	7e+02			
## 37	0	0	0	0	15700	1e+04			
## 46	0	0	0	0	0	0e+00			
## 49	0	0	0	0	1800	1e+03			
## 52	0	0	0	0	400	4e+02			
## 58	0	0	0	0	800	4e+02			
## 60	0	0	0	0	1400	7e+02			
## 66	0	0	0	0	0	0e+00			
## 67	0	0	0	0	4300	4e+03			
## 68	0	0	0	0	900	9e+02			
## 71	0	0	0	0	800	8e+02			
## 74	0	0	0	0	0	0e+00			
## 75	0	0	0	0	4300	4e+03			
## 77	0	0	0	0	5000	5e+03			
## 79	0	0	0	0	600	3e+02			
## 81	0	0	0	0	0	0e+00			
## 84	0	0	0	0	0	0e+00			
## 86	0	0	0	0	0	0e+00			
## 87	0	0	0	0	6000	6e+03			
## 89	0	0	0	0	0	0e+00			
## 91	0	0	0	0	0	0e+00			
## 94	0	0	0	0	0	0e+00			
## 97	0	0	0	0	0	0e+00			
## 100	0	0	0	0	0	0e+00			
## 102	0	0	0	0	800	5e+02			
## 108	0	0	0	0	0	0e+00			
## 109	0	0	0	0	0	0e+00			
## 111	0	0	0	0	0	0e+00			
## 112	0	0	0	0	0	0e+00			
## 114	0	0	0	0	200	2e+02			
## 115	0	0	0	0	0	0e+00			
## 117	0	0	0	0	0	0e+00			
## 118	0	0	0	0	3000	3e+03			

```
## 119      0      0      0      0      0e+00
## 120      0      0      0 4000      4e+03
## 121      0      0      0 4000      4e+03
## 123      0      0      0      0      0e+00
## 124      0      0      0 3000      3e+03
## 125      0      0      0  300      3e+02
## 126      0      0      0      0      0e+00
## 128      0      0      0 2000      2e+03
## 129      0      0      0      0      0e+00
## 130      0      0      0      0      0e+00
## 132      0      0      0 3000      3e+03
## 133      0      0      0      0      0e+00
## 135      0      0      0      0      0e+00
## 136      0      0      0      0      0e+00
## 138      0      0      0      0      0e+00
## 139      0      0      0 2000      2e+03
## 141      0      0      0 2700      1e+03
## 142      0      0      0      0      0e+00
## 144      0      0      0      0      0e+00
## 146      0      0      0 6000      6e+03
## 150      0      0      0      0      0e+00
## 151      0      0      0  900      9e+02
## 153      0      0      0  900      9e+02
## 154      0      0      0      0      0e+00
## 156      0      0      0      0      0e+00
## 157      0      0      0      0      0e+00
## 159      0      0      0      0      0e+00
## 160      0      0      0  900      6e+02
## [ reached getOption("max.print") -- omitted 263 rows ]
```

```
nombres.outliers.normales <- row.names(data.frame.outliers.normales)
nombres.outliers.normales
```

```
## [1] "7"  "10" "13" "16" "25" "28" "30" "31" "33" "34"
## [11] "36" "37" "46" "49" "52" "58" "60" "66" "67" "68"
## [21] "71" "74" "75" "77" "79" "81" "84" "86" "87" "89"
## [31] "91" "94" "97" "100" "102" "108" "109" "111" "112" "114"
## [41] "115" "117" "118" "119" "120" "121" "123" "124" "125" "126"
## [51] "128" "129" "130" "132" "133" "135" "136" "138" "139" "141"
## [61] "142" "144" "146" "150" "151" "153" "154" "156" "157" "159"
## [71] "160" "162" "163" "165" "166" "167" "168" "169" "170" "171"
## [81] "172" "174" "175" "176" "177" "178" "180" "181" "182" "183"
## [91] "184" "187" "188" "189" "190" "191" "192" "193" "194" "195"
## [101] "196" "197" "198" "199" "200" "201" "202" "203" "204" "205"
## [111] "206" "207" "208" "209" "210" "211" "212" "213" "214" "215"
## [121] "216" "217" "218" "219" "220" "221" "222" "223" "224" "225"
## [131] "226" "227" "228" "229" "230" "231" "232" "233" "234" "235"
## [141] "236" "237" "238" "239" "240" "241" "242" "243" "244" "245"
## [151] "246" "247" "248" "249" "250" "251" "252" "253" "254" "255"
## [161] "256" "257" "258" "259" "260" "261" "262" "263" "264" "265"
## [171] "266" "267" "268" "269" "270" "271" "272" "273" "274" "275"
## [181] "276" "277" "278" "279" "280" "281" "282" "283" "284" "285"
## [191] "286" "287" "288" "289" "296" "297" "298" "299" "300" "301"
## [201] "302" "303" "304" "305" "306" "307" "308" "309" "310" "314"
## [211] "315" "316" "317" "318" "319" "320" "321" "322" "323" "324"
```

```
## [221] "325" "326" "327" "328" "329" "330" "331" "335" "336" "337"
## [231] "338" "339" "340" "341" "342" "343" "344" "345" "346" "347"
## [241] "348" "350" "351" "352" "353" "354" "355" "356" "357" "358"
## [251] "362" "363" "364" "365" "381" "384" "387" "390" "391" "392"
## [261] "393" "399" "558" "665" "666" "672" "675" "681" "682" "684"
## [271] "686" "687" "688" "689" "690" "693" "694" "695" "696" "700"
## [281] "702" "703" "704" "705" "706" "707" "708" "713" "714" "715"
## [291] "716" "717" "718" "719" "720" "721" "722" "723" "724" "725"
## [301] "735" "737" "738" "823" "825" "826" "828" "831" "843" "844"
## [311] "846" "847" "849" "850" "852" "853" "854" "855" "861" "862"
## [321] "864" "865" "870" "873" "882" "883" "936" "937" "1692" "2178"
## [331] "2180" "2181" "2211" "2214"
```

```
valores.outliers.normales <- mydata.numeric[claves.outliers.normales,indice.columna]
valores.outliers.normales
```

```
## [1] 207930 247620 166180 225040 424650 212260 172290 395110
## [9] 144880 477750 127360 514800 250030 309010 248900 269070
## [17] 372770 147520 202640 259110 590510 317360 227990 210960
## [25] 302440 436650 169370 233810 149050 194580 194580 285750
## [33] 298230 172120 270040 166700 274170 226790 134640 328050
## [41] 140090 157740 325750 300520 465730 336600 951410 203850
## [49] 715390 160350 373180 481630 620720 280830 557230 270490
## [57] 307540 314100 368340 316200 209760 372380 396530 303610
## [65] 278230 498960 443740 788230 119460 1049580 715540 974430
## [73] 696470 1124850 640820 1096910 155540 722590 582700 691310
## [81] 698810 716630 641120 384230 790830 390180 936850 432690
## [89] 441960 912890 446210 117040 414700 960770 763520 541040
## [97] 1127430 664090 320150 768080 474770 682910 1256570 576040
## [105] 782750 1371400 891720 1034700 2129020 1547010 924910 1988970
## [113] 218630 1018360 1189240 1582550 927530 2052510 1260100 1062280
## [121] 2196220 1138340 918020 1766860 1699290 301550 1355970 2595650
## [129] 2160800 1367850 251120 157450 129740 144520 1345240 2102300
## [137] 219070 628360 1449990 1531530 195510 1312110 315650 1061760
## [145] 1283710 1134540 525630 1661100 1310730 1101540 1496830 1323740
## [153] 943300 348780 154420 1514120 1811640 1446770 1132810 1367690
## [161] 814170 600400 886800 588930 542890 1104700 734930 509190
## [169] 480250 428740 450060 627380 448900 453850 779850 146840
## [177] 675030 811060 538060 372470 439210 286300 576200 833250
## [185] 836500 571990 754760 834760 450490 932410 568200 452730
## [193] 833660 131820 447360 993080 593950 570400 788650 383490
## [201] 415690 645750 649840 380320 401730 459160 285990 557510
## [209] 536260 498400 342050 434360 366500 507230 388530 329680
## [217] 579440 292040 261010 394660 464220 393140 742750 820600
## [225] 289580 577770 347400 268170 632800 332180 172250 256850
## [233] 199030 192650 320110 233800 206610 244480 430310 311200
## [241] 478520 379670 887140 690550 397280 609620 136810 358490
## [249] 581540 545470 532290 511560 546980 155980 189840 122850
## [257] 151660 122640 176830 122410 184710 127770 150220 122820
## [265] 132520 118860 182210 154830 121720 190960 133430 253510
## [273] 121870 148160 156780 127110 163510 134890 306400 128260
## [281] 186280 195950 117120 273200 121400 200350 130940 166220
## [289] 265250 162190 127010 229070 167100 132470 254750 151210
## [297] 118110 118120 185910 197590 134870 159910 172530 145440
## [305] 239660 229690 197620 179710 178220 121520 254510 180530
```



```
## [313] 362360 140610 211440 189170 232470 240350 147570 140890
## [321] 122030 154470 120690 161390 129190 125340 147400 175660
## [329] 135210 134070 124380 162810 151920 124850
```

Para los extremos:

```
claves.outliers.extremo<-which(vector.es.outlier.extremo)
claves.outliers.extremo
```

```
## [1] 7 10 16 25 28 31 34 37 46 49 52 58 60 67 68 71 74
## [18] 75 77 79 81 86 89 91 94 97 102 109 111 114 118 119 120 121
## [35] 123 124 125 128 129 130 132 133 135 136 138 139 141 142 144 146 150
## [52] 151 153 154 156 159 160 162 163 165 166 167 169 170 171 172 174 175
## [69] 176 177 178 180 181 182 183 184 188 189 190 191 192 193 194 195 196
## [86] 197 198 199 200 201 202 203 204 205 206 207 208 209 210 211 212 213
## [103] 214 215 216 217 218 219 220 221 222 223 224 225 226 230 231 232 233
## [120] 234 235 236 237 238 239 240 241 242 243 244 245 246 247 248 249 251
## [137] 252 253 254 255 256 257 258 259 260 261 262 263 264 265 266 267 268
## [154] 269 270 272 273 274 275 276 277 278 279 280 281 282 283 284 285 286
## [171] 287 288 296 297 298 299 300 301 302 303 304 305 306 307 308 309 310
## [188] 314 315 316 317 318 319 320 321 322 323 324 325 326 327 328 329 330
## [205] 331 335 336 337 339 340 341 342 343 344 345 346 347 348 350 351 352
## [222] 353 354 356 357 358 362 363 364 381 391 393 675 684 687 696 702 703
## [239] 705 707 714 717 720 724 725 825 826 828 831 843 846 847 849 852 853
## [256] 854 855
```

```
data.frame.outliers.extremo<-data.frame(mydata.numeric[claves.outliers.extremo,])
data.frame.outliers.extremo
```

```
##      genergy gpuls gdenenergy gdpuls nbumps nbumps2 nbumps3 nbumps4 nbumps5
## 7      207930    614         -6     18      2      2      0      0      0
## 10     247620    675          4     25      1      1      0      0      0
## 16     225040    575         -3      5      2      0      2      0      0
## 25     424650   1069          1      7      2      0      2      0      0
## 28     212260    729        -50    -28      2      1      1      0      0
## 31     395110   1043          46     40      3      0      3      0      0
## 34     477750   1132          86     60      3      3      0      0      0
## 37     514800   1369          95     94      7      4      2      1      0
## 46     250030    687         -8     -5      0      0      0      0      0
## 49     309010    983          15     38      2      1      1      0      0
## 52     248900    739         -9      0      1      1      0      0      0
## 58     269070    767         -1      4      2      2      0      0      0
## 60     372770    975          37     32      3      3      0      0      0
## 67     202640    588        -33    -41      2      1      1      0      0
## 68     259110   1409        -11     46      1      1      0      0      0
## 71     590510   1780          23     -6      1      1      0      0      0
## 74     317360   1068        -36    -44      0      0      0      0      0
## 75     227990    734        -52    -59      2      1      1      0      0
## 77     210960    773        -44    -35      1      0      1      0      0
## 79     302440   1250        -16      9      2      2      0      0      0
## 81     436650   1232          23      6      0      0      0      0      0
## 86     233810    839        -31    -24      0      0      0      0      0
## 89     194580    697        -35    -32      0      0      0      0      0
## 91     194580    697        -35    -32      0      0      0      0      0
## 94     285750    791          1    -19      0      0      0      0      0
## 97     298230    916          9     -2      0      0      0      0      0
```

## 102	270040	717	10	-14	2	2	0	0	0
## 109	274170	997	15	34	0	0	0	0	0
## 111	226790	717	2	0	0	0	0	0	0
## 114	328050	707	51	0	1	1	0	0	0
## 118	325750	1068	50	67	1	0	1	0	0
## 119	300520	894	37	37	0	0	0	0	0
## 120	465730	1325	-7	-12	1	0	1	0	0
## 121	336600	984	-32	-34	1	0	1	0	0
## 123	951410	1332	98	-7	0	0	0	0	0
## 124	203850	476	-14	-32	1	0	1	0	0
## 125	715390	1923	36	36	1	1	0	0	0
## 128	373180	1246	-32	-14	1	0	1	0	0
## 129	481630	1678	-10	17	0	0	0	0	0
## 130	620720	1789	17	23	0	0	0	0	0
## 132	280830	689	94	39	1	0	1	0	0
## 133	557230	1642	2	11	0	0	0	0	0
## 135	270490	865	83	78	0	0	0	0	0
## 136	307540	1020	-44	-32	0	0	0	0	0
## 138	314100	904	-41	-37	0	0	0	0	0
## 139	368340	1325	-28	-4	1	0	1	0	0
## 141	316200	1089	-37	-21	3	1	2	0	0
## 142	209760	919	46	89	0	0	0	0	0
## 144	372380	1264	-26	-9	0	0	0	0	0
## 146	396530	1209	-10	-13	1	0	1	0	0
## 150	303610	1034	-26	-21	0	0	0	0	0
## 151	278230	1060	-31	-18	1	1	0	0	0
## 153	498960	1447	30	17	1	1	0	0	0
## 154	443740	1321	20	10	0	0	0	0	0
## 156	788230	1484	-1	-1	0	0	0	0	0
## 159	1049580	1807	31	21	0	0	0	0	0
## 160	715540	1471	-13	-4	2	2	0	0	0
## 162	974430	1828	20	20	2	1	0	1	0
## 163	696470	1368	-16	-12	2	1	1	0	0
## 165	1124850	2153	37	39	3	1	2	0	0
## 166	640820	1235	-25	-23	1	0	1	0	0
## 167	1096910	2037	31	29	2	1	1	0	0
## 169	722590	2125	-17	30	2	0	2	0	0
## 170	582700	1232	-32	-28	1	0	1	0	0
## 171	691310	1416	-14	-6	0	0	0	0	0
## 172	698810	1279	-11	-14	3	0	3	0	0
## 174	716630	1677	-8	14	2	2	0	0	0
## 175	641120	1571	-17	6	1	1	0	0	0
## 176	384230	751	4	6	3	1	2	0	0
## 177	790830	1434	5	-4	2	0	1	1	0
## 178	390180	938	6	33	0	0	0	0	0

##	nbumps6	nbumps7	nbumps89	energy	maxenergy
## 7	0	0	0	1000	700
## 10	0	0	0	500	500
## 16	0	0	0	7000	6000
## 25	0	0	0	6000	4000
## 28	0	0	0	1400	1000
## 31	0	0	0	6000	2000
## 34	0	0	0	1500	600
## 37	0	0	0	15700	10000

## 46	0	0	0	0	0
## 49	0	0	0	1800	1000
## 52	0	0	0	400	400
## 58	0	0	0	800	400
## 60	0	0	0	1400	700
## 67	0	0	0	4300	4000
## 68	0	0	0	900	900
## 71	0	0	0	800	800
## 74	0	0	0	0	0
## 75	0	0	0	4300	4000
## 77	0	0	0	5000	5000
## 79	0	0	0	600	300
## 81	0	0	0	0	0
## 86	0	0	0	0	0
## 89	0	0	0	0	0
## 91	0	0	0	0	0
## 94	0	0	0	0	0
## 97	0	0	0	0	0
## 102	0	0	0	800	500
## 109	0	0	0	0	0
## 111	0	0	0	0	0
## 114	0	0	0	200	200
## 118	0	0	0	3000	3000
## 119	0	0	0	0	0
## 120	0	0	0	4000	4000
## 121	0	0	0	4000	4000
## 123	0	0	0	0	0
## 124	0	0	0	3000	3000
## 125	0	0	0	300	300
## 128	0	0	0	2000	2000
## 129	0	0	0	0	0
## 130	0	0	0	0	0
## 132	0	0	0	3000	3000
## 133	0	0	0	0	0
## 135	0	0	0	0	0
## 136	0	0	0	0	0
## 138	0	0	0	0	0
## 139	0	0	0	2000	2000
## 141	0	0	0	2700	1000
## 142	0	0	0	0	0
## 144	0	0	0	0	0
## 146	0	0	0	6000	6000
## 150	0	0	0	0	0
## 151	0	0	0	900	900
## 153	0	0	0	900	900
## 154	0	0	0	0	0
## 156	0	0	0	0	0
## 159	0	0	0	0	0
## 160	0	0	0	900	600
## 162	0	0	0	20600	20000
## 163	0	0	0	2400	2000
## 165	0	0	0	3900	2000
## 166	0	0	0	5000	5000
## 167	0	0	0	3700	3000

```
## 169      0      0      0  5000    4000
## 170      0      0      0  7000    7000
## 171      0      0      0      0      0
## 172      0      0      0  8000    4000
## 174      0      0      0   700     500
## 175      0      0      0   800     800
## 176      0      0      0  9700    6000
## 177      0      0      0 13000   10000
## 178      0      0      0      0      0
## [ reached getOption("max.print") -- omitted 186 rows ]
```

```
nombres.outliers.extremo <- row.names(data.frame.outliers.extremo)
nombres.outliers.extremo
```

```
## [1] "7" "10" "16" "25" "28" "31" "34" "37" "46" "49" "52"
## [12] "58" "60" "67" "68" "71" "74" "75" "77" "79" "81" "86"
## [23] "89" "91" "94" "97" "102" "109" "111" "114" "118" "119" "120"
## [34] "121" "123" "124" "125" "128" "129" "130" "132" "133" "135" "136"
## [45] "138" "139" "141" "142" "144" "146" "150" "151" "153" "154" "156"
## [56] "159" "160" "162" "163" "165" "166" "167" "169" "170" "171" "172"
## [67] "174" "175" "176" "177" "178" "180" "181" "182" "183" "184" "188"
## [78] "189" "190" "191" "192" "193" "194" "195" "196" "197" "198" "199"
## [89] "200" "201" "202" "203" "204" "205" "206" "207" "208" "209" "210"
## [100] "211" "212" "213" "214" "215" "216" "217" "218" "219" "220" "221"
## [111] "222" "223" "224" "225" "226" "230" "231" "232" "233" "234" "235"
## [122] "236" "237" "238" "239" "240" "241" "242" "243" "244" "245" "246"
## [133] "247" "248" "249" "251" "252" "253" "254" "255" "256" "257" "258"
## [144] "259" "260" "261" "262" "263" "264" "265" "266" "267" "268" "269"
## [155] "270" "272" "273" "274" "275" "276" "277" "278" "279" "280" "281"
## [166] "282" "283" "284" "285" "286" "287" "288" "296" "297" "298" "299"
## [177] "300" "301" "302" "303" "304" "305" "306" "307" "308" "309" "310"
## [188] "314" "315" "316" "317" "318" "319" "320" "321" "322" "323" "324"
## [199] "325" "326" "327" "328" "329" "330" "331" "335" "336" "337" "339"
## [210] "340" "341" "342" "343" "344" "345" "346" "347" "348" "350" "351"
## [221] "352" "353" "354" "356" "357" "358" "362" "363" "364" "381" "391"
## [232] "393" "675" "684" "687" "696" "702" "703" "705" "707" "714" "717"
## [243] "720" "724" "725" "825" "826" "828" "831" "843" "846" "847" "849"
## [254] "852" "853" "854" "855"
```

```
valores.outliers.extremo <- mydata.numeric[claves.outliers.extremo,indice.columna]
valores.outliers.extremo
```

```
## [1] 207930 247620 225040 424650 212260 395110 477750 514800
## [9] 250030 309010 248900 269070 372770 202640 259110 590510
## [17] 317360 227990 210960 302440 436650 233810 194580 194580
## [25] 285750 298230 270040 274170 226790 328050 325750 300520
## [33] 465730 336600 951410 203850 715390 373180 481630 620720
## [41] 280830 557230 270490 307540 314100 368340 316200 209760
## [49] 372380 396530 303610 278230 498960 443740 788230 1049580
## [57] 715540 974430 696470 1124850 640820 1096910 722590 582700
## [65] 691310 698810 716630 641120 384230 790830 390180 936850
## [73] 432690 441960 912890 446210 414700 960770 763520 541040
## [81] 1127430 664090 320150 768080 474770 682910 1256570 576040
## [89] 782750 1371400 891720 1034700 2129020 1547010 924910 1988970
## [97] 218630 1018360 1189240 1582550 927530 2052510 1260100 1062280
## [105] 2196220 1138340 918020 1766860 1699290 301550 1355970 2595650
```

```
## [113] 2160800 1367850 251120 1345240 2102300 219070 628360 1449990
## [121] 1531530 195510 1312110 315650 1061760 1283710 1134540 525630
## [129] 1661100 1310730 1101540 1496830 1323740 943300 348780 1514120
## [137] 1811640 1446770 1132810 1367690 814170 600400 886800 588930
## [145] 542890 1104700 734930 509190 480250 428740 450060 627380
## [153] 448900 453850 779850 675030 811060 538060 372470 439210
## [161] 286300 576200 833250 836500 571990 754760 834760 450490
## [169] 932410 568200 452730 833660 447360 993080 593950 570400
## [177] 788650 383490 415690 645750 649840 380320 401730 459160
## [185] 285990 557510 536260 498400 342050 434360 366500 507230
## [193] 388530 329680 579440 292040 261010 394660 464220 393140
## [201] 742750 820600 289580 577770 347400 268170 632800 332180
## [209] 256850 199030 192650 320110 233800 206610 244480 430310
## [217] 311200 478520 379670 887140 690550 397280 609620 358490
## [225] 581540 545470 532290 511560 546980 189840 176830 184710
## [233] 182210 190960 253510 306400 186280 195950 273200 200350
## [241] 265250 229070 254750 185910 197590 239660 229690 197620
## [249] 179710 178220 254510 180530 362360 211440 189170 232470
## [257] 240350
```

Tenemos un total de 257 outliers extremos y 334 outliers normales, y esto solo en la variable genergy por lo que a muy probablemente el número de outliers aumente.

Desviación de los outliers con respecto a la media de la columna

Por último, obtendremos los valores de los outliers pero para la columna normalizada.

```
valores.normalizados.outliers.normales<-columna.scaled[claves.outliers.normales]
valores.normalizados.outliers.extremo<-columna.scaled[claves.outliers.extremo]
```

Plot

Por último usaremos un gráfico para ver estos outliers para ello, llamamos a la siguiente función:

MiPlot_Univariate_Outliers (columna de datos, índices -claves numéricas- de outliers , nombre de columna)

```
MiPlot_Univariate_Outliers(columna,claves.outliers.normales,nombre.columna)
```

```
##
```

```
## N?mero de datos: 2584
```

```
## ?Qui?n es outlier?: FALSE FALSE FALSE FALSE FALSE FALSE TRUE FALSE FALSE TRUE FALSE FALSE TRUE FALSE
```


```
MiPlot_Univariate_Outliers(columna,claves.outliers.extremo,nombre.columna)
```

```
##
```

```
## N?mero de datos: 2584
```

```
## ?Qui?n es outlier?: FALSE FALSE FALSE FALSE FALSE FALSE TRUE FALSE FALSE TRUE FALSE FALSE FALSE FALSE
```

genergy



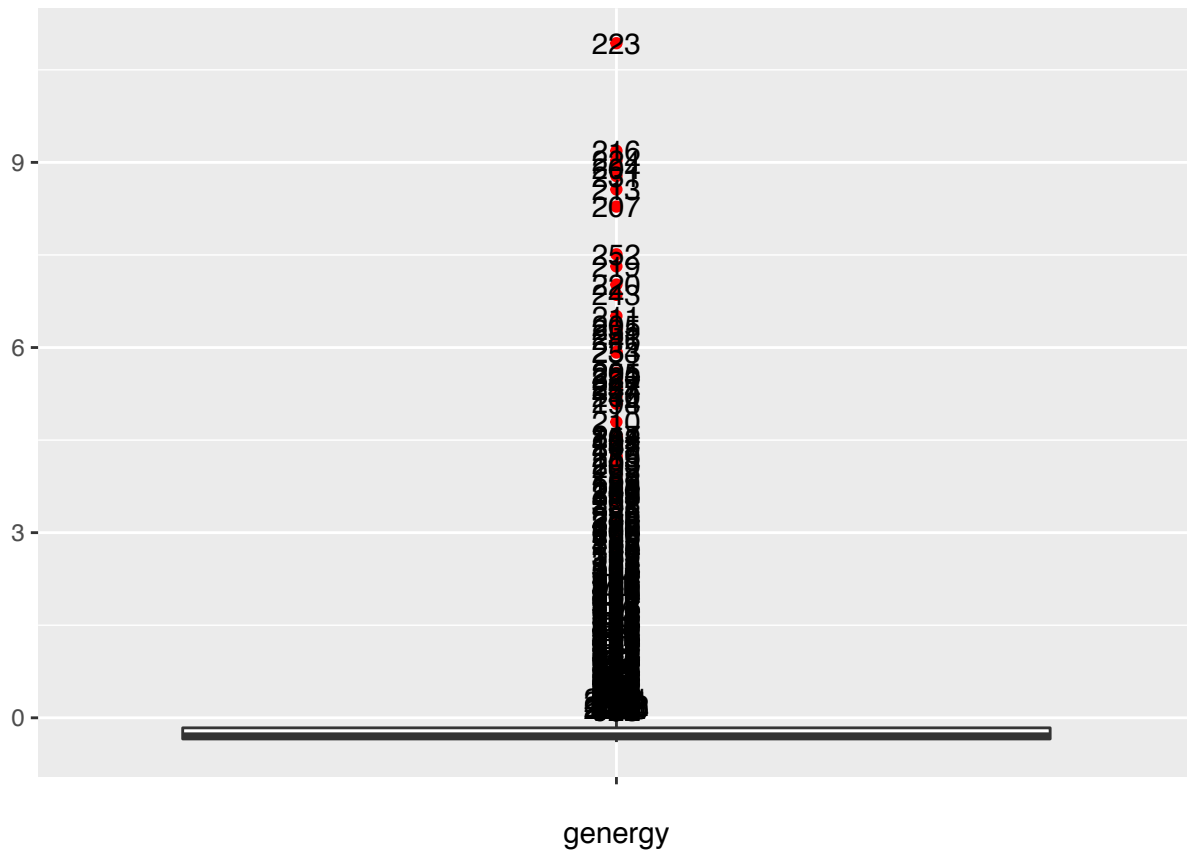
Podemos ver que los outliers son muy abundantes y serán outliers por encima, esto era de esperar ya que al tratarse de datos físicos lo normal en muchos casos más al tratarse de energía son valores constantes o que varían muy poco, excepto cuando como en este caso se de el caso de una gran cantidad de energía liberada, con la que obtendremos outliers por encima.

BoxPlot

Vamos a utilizar un boxplot para ver estos outliers, para ello usaremos la función:


```
MiBoxPlot_IQR_Univariate_Outliers = function (datos, indice.de.columna, coef = 1.5)
```

```
MiBoxPlot_IQR_Univariate_Outliers(mydata.numeric.scaled, indice.columna, coef = 1.5)
```



Al representar encima los valores o nombres de los outliers el gráfico se emborrona, por lo que podremos usar boxplot nativo sobre todos los datos para ver mejor estos outliers:

```
boxplot(mydata.numeric.scaled)
```



Vemos que la presencia de outliers es muy fuerte en todo el dataset, y como predejimos, estos vienen dados por encima en la mayoría de los casos teniendo medianas muy bajas y constantes lo que indica la estabilidad de los datos durante todas las medidas.

Cómputo de los outliers IQR con funciones propias

En este punto realizaremos el estudio IQR de los datos, pero usando funciones propias:

```
vector_outliers<-vector_es_outlier_IQR(mydata.numeric, indice.columna)
vector_claves_outliers<-vector_claves_outliers_IQR(mydata.numeric, indice.columna)
```

Trabajamos con varias columnas simultáneamente

Lo interesante de usar estas funciones, reside en la obtención de los outliers en las distintas columnas. Aunque el análisis es aún centrandonos en una sola variable, podremos vamos a obtener todos los outliers usando la función:

```
vector_claves_outliers_IQR_en_alguna_columna = function(datos, coef = 1.5)
```

```
indices.de.outliers.en.alguna.columna<-vector_claves_outliers_IQR_en_alguna_columna(mydata.numeric)
```

Esta variable contiene los índices de aquellos registros que tienen un valor anómalo con respecto a alguna columna. Si mostramos los datos normalizados de dichos registros, debe salir lo siguiente:

```
mydata.numeric[indices.de.outliers.en.alguna.columna,]
```

##	genergy	gpuls	gdenenergy	gdpuls	nbumps	nbumps2	nbumps3	nbumps4
## 7	207930	614	-6	18	2	2	0	0
## 10	247620	675	4	25	1	1	0	0
## 13	166180	448	-30	-19	1	1	0	0
## 16	225040	575	-3	5	2	0	2	0
## 25	424650	1069	1	7	2	0	2	0
## 28	212260	729	-50	-28	2	1	1	0
## 30	172290	437	-57	-55	1	1	0	0
## 31	395110	1043	46	40	3	0	3	0
## 33	144880	361	-46	-52	1	0	1	0
## 34	477750	1132	86	60	3	3	0	0
## 36	127360	351	-54	-53	1	1	0	0
## 37	514800	1369	95	94	7	4	2	1
## 46	250030	687	-8	-5	0	0	0	0
## 49	309010	983	15	38	2	1	1	0
## 52	248900	739	-9	0	1	1	0	0
## 58	269070	767	-1	4	2	2	0	0
## 60	372770	975	37	32	3	3	0	0
## 66	147520	472	-2	-6	0	0	0	0
## 67	202640	588	-33	-41	2	1	1	0
## 68	259110	1409	-11	46	1	1	0	0
## 71	590510	1780	23	-6	1	1	0	0
## 74	317360	1068	-36	-44	0	0	0	0
## 75	227990	734	-52	-59	2	1	1	0
## 77	210960	773	-44	-35	1	0	1	0
## 79	302440	1250	-16	9	2	2	0	0
## 81	436650	1232	23	6	0	0	0	0
## 84	169370	644	-53	-45	0	0	0	0
## 86	233810	839	-31	-24	0	0	0	0
## 87	149050	697	-54	-35	1	0	1	0
## 89	194580	697	-35	-32	0	0	0	0
## 91	194580	697	-35	-32	0	0	0	0
## 94	285750	791	1	-19	0	0	0	0

## 97	298230	916	9	-2	0	0	0	0
## 100	172120	537	-35	-41	0	0	0	0
## 102	270040	717	10	-14	2	2	0	0
## 108	166700	363	-34	-56	0	0	0	0
## 109	274170	997	15	34	0	0	0	0
## 111	226790	717	2	0	0	0	0	0
## 112	134640	611	-41	-16	0	0	0	0
## 114	328050	707	51	0	1	1	0	0
## 115	140090	380	-40	-46	0	0	0	0
## 117	157740	440	-31	-35	0	0	0	0
## 118	325750	1068	50	67	1	0	1	0
## 119	300520	894	37	37	0	0	0	0
## 120	465730	1325	-7	-12	1	0	1	0
## 121	336600	984	-32	-34	1	0	1	0
## 123	951410	1332	98	-7	0	0	0	0
## 124	203850	476	-14	-32	1	0	1	0
## 125	715390	1923	36	36	1	1	0	0
## 126	160350	828	-31	23	0	0	0	0
## 128	373180	1246	-32	-14	1	0	1	0
## 129	481630	1678	-10	17	0	0	0	0
## 130	620720	1789	17	23	0	0	0	0
## 132	280830	689	94	39	1	0	1	0
## 133	557230	1642	2	11	0	0	0	0
## 135	270490	865	83	78	0	0	0	0
## 136	307540	1020	-44	-32	0	0	0	0
## 138	314100	904	-41	-37	0	0	0	0
## 139	368340	1325	-28	-4	1	0	1	0
## 141	316200	1089	-37	-21	3	1	2	0
## 142	209760	919	46	89	0	0	0	0
## 144	372380	1264	-26	-9	0	0	0	0
## 146	396530	1209	-10	-13	1	0	1	0
## 150	303610	1034	-26	-21	0	0	0	0
## 151	278230	1060	-31	-18	1	1	0	0
## 153	498960	1447	30	17	1	1	0	0
## 154	443740	1321	20	10	0	0	0	0
## 156	788230	1484	-1	-1	0	0	0	0
## 157	119460	269	-70	-64	0	0	0	0
## 159	1049580	1807	31	21	0	0	0	0
## 160	715540	1471	-13	-4	2	2	0	0
##	nbumps5	nbumps6	nbumps7	nbumps89	energy	maxenergy		
## 7	0	0	0	0	1000	7e+02		
## 10	0	0	0	0	500	5e+02		
## 13	0	0	0	0	400	4e+02		
## 16	0	0	0	0	7000	6e+03		
## 25	0	0	0	0	6000	4e+03		
## 28	0	0	0	0	1400	1e+03		
## 30	0	0	0	0	600	6e+02		
## 31	0	0	0	0	6000	2e+03		
## 33	0	0	0	0	2000	2e+03		
## 34	0	0	0	0	1500	6e+02		
## 36	0	0	0	0	700	7e+02		
## 37	0	0	0	0	15700	1e+04		
## 46	0	0	0	0	0	0e+00		
## 49	0	0	0	0	1800	1e+03		

## 52	0	0	0	0	400	4e+02
## 58	0	0	0	0	800	4e+02
## 60	0	0	0	0	1400	7e+02
## 66	0	0	0	0	0	0e+00
## 67	0	0	0	0	4300	4e+03
## 68	0	0	0	0	900	9e+02
## 71	0	0	0	0	800	8e+02
## 74	0	0	0	0	0	0e+00
## 75	0	0	0	0	4300	4e+03
## 77	0	0	0	0	5000	5e+03
## 79	0	0	0	0	600	3e+02
## 81	0	0	0	0	0	0e+00
## 84	0	0	0	0	0	0e+00
## 86	0	0	0	0	0	0e+00
## 87	0	0	0	0	6000	6e+03
## 89	0	0	0	0	0	0e+00
## 91	0	0	0	0	0	0e+00
## 94	0	0	0	0	0	0e+00
## 97	0	0	0	0	0	0e+00
## 100	0	0	0	0	0	0e+00
## 102	0	0	0	0	800	5e+02
## 108	0	0	0	0	0	0e+00
## 109	0	0	0	0	0	0e+00
## 111	0	0	0	0	0	0e+00
## 112	0	0	0	0	0	0e+00
## 114	0	0	0	0	200	2e+02
## 115	0	0	0	0	0	0e+00
## 117	0	0	0	0	0	0e+00
## 118	0	0	0	0	3000	3e+03
## 119	0	0	0	0	0	0e+00
## 120	0	0	0	0	4000	4e+03
## 121	0	0	0	0	4000	4e+03
## 123	0	0	0	0	0	0e+00
## 124	0	0	0	0	3000	3e+03
## 125	0	0	0	0	300	3e+02
## 126	0	0	0	0	0	0e+00
## 128	0	0	0	0	2000	2e+03
## 129	0	0	0	0	0	0e+00
## 130	0	0	0	0	0	0e+00
## 132	0	0	0	0	3000	3e+03
## 133	0	0	0	0	0	0e+00
## 135	0	0	0	0	0	0e+00
## 136	0	0	0	0	0	0e+00
## 138	0	0	0	0	0	0e+00
## 139	0	0	0	0	2000	2e+03
## 141	0	0	0	0	2700	1e+03
## 142	0	0	0	0	0	0e+00
## 144	0	0	0	0	0	0e+00
## 146	0	0	0	0	6000	6e+03
## 150	0	0	0	0	0	0e+00
## 151	0	0	0	0	900	9e+02
## 153	0	0	0	0	900	9e+02
## 154	0	0	0	0	0	0e+00
## 156	0	0	0	0	0	0e+00

```
## 157      0      0      0      0      0      0e+00
## 159      0      0      0      0      0      0e+00
## 160      0      0      0      0    900      6e+02
## [ reached getOption("max.print") -- omitted 1924 rows ]
```

Estamos ante un data set con muchos outliers (+75%), tantos que tendremos que buscar una manera de condensar estos de manera que podamos estudiarlos, ya que los datos son tan dispares y en cierta medida complejos que no podrán obtenerse conclusiones lógicas con tan solo observarlos.

Ampliación

Realizaremos el estudio anterior, pero solo utilizando ordenes básicas de R, es decir, sin recurrir a la función usada anteriormente.

Índices y valores de los outliers

Obtendremos por tanto, para cada columna un vector lógico que nos indique si estamos ante un outlier o no y guardamos todo en una matriz.

```
frame.es.outlier <- sapply(1:ncol(mydata.numeric),vector_es_outlier_IQR, datos=mydata.numeric)
head(frame.es.outlier)
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11]
## [1,] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [2,] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [3,] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [4,] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [5,] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [6,] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
##      [,12] [,13] [,14]
## [1,] FALSE FALSE FALSE
## [2,] FALSE FALSE FALSE
## [3,] FALSE FALSE FALSE
## [4,] FALSE FALSE FALSE
## [5,] FALSE FALSE FALSE
## [6,] FALSE FALSE FALSE
```

Ahora obtendremos el número total de outliers por columna: `help(sapply)`

```
numero.total.outliers.por.columna <- apply(frame.es.outlier, 2, sum)
numero.total.outliers.por.columna
```

```
## [1] 334 201 141 95 277 77 68 158 12 0 0 0 319 313
```

Como hemos dicho anteriormente, podemos comprobar que el número de *univariate outliers* en el problema es muy elevado y excepto den dos columnas, los tenemos presentes en todas.

Con el fin de obtener los datos con los outliers, obtendremos ahora las claves de las filas que en alguna de sus columnas tienen outliers.

```
indices.de.outliers.en.alguna.columna<- sapply(1:ncol(mydata.numeric),vector_claves_outliers_IQR, datos=
indices.de.outliers.en.alguna.columna <- sort(unique(unlist(indices.de.outliers.en.alguna.columna)))
```

Desviación de los outliers con respecto a la media de la columna

```
mydata.numeric[indices.de.outliers.en.alguna.columna,]
```

##	genergy	gpuls	gdenergy	gdpuls	nbumps	nbumps2	nbumps3	nbumps4	nbumps5
## 7	207930	614	-6	18	2	2	0	0	0
## 10	247620	675	4	25	1	1	0	0	0
## 13	166180	448	-30	-19	1	1	0	0	0
## 14	64540	215	0	9	1	0	1	0	0
## 16	225040	575	-3	5	2	0	2	0	0
## 25	424650	1069	1	7	2	0	2	0	0
## 28	212260	729	-50	-28	2	1	1	0	0
## 29	42950	172	-76	-61	1	0	1	0	0
## 30	172290	437	-57	-55	1	1	0	0	0
## 31	395110	1043	46	40	3	0	3	0	0
## 32	51320	239	11	23	1	0	1	0	0
## 33	144880	361	-46	-52	1	0	1	0	0
## 34	477750	1132	86	60	3	3	0	0	0
## 35	71840	255	54	28	1	0	1	0	0
## 36	127360	351	-54	-53	1	1	0	0	0
## 37	514800	1369	95	94	7	4	2	1	0
## 46	250030	687	-8	-5	0	0	0	0	0
## 49	309010	983	15	38	2	1	1	0	0
## 50	59060	264	65	85	1	0	1	0	0
## 52	248900	739	-9	0	1	1	0	0	0
## 53	51620	186	51	34	1	0	1	0	0
## 58	269070	767	-1	4	2	2	0	0	0
## 60	372770	975	37	32	3	3	0	0	0
## 66	147520	472	-2	-6	0	0	0	0	0
## 67	202640	588	-33	-41	2	1	1	0	0
## 68	259110	1409	-11	46	1	1	0	0	0
## 71	590510	1780	23	-6	1	1	0	0	0
## 72	75930	305	-38	-27	1	0	1	0	0
## 74	317360	1068	-36	-44	0	0	0	0	0
## 75	227990	734	-52	-59	2	1	1	0	0
## 77	210960	773	-44	-35	1	0	1	0	0
## 79	302440	1250	-16	9	2	2	0	0	0
## 80	46160	250	-16	15	1	0	1	0	0
## 81	436650	1232	23	6	0	0	0	0	0
## 84	169370	644	-53	-45	0	0	0	0	0
## 86	233810	839	-31	-24	0	0	0	0	0
## 87	149050	697	-54	-35	1	0	1	0	0
## 89	194580	697	-35	-32	0	0	0	0	0
## 91	194580	697	-35	-32	0	0	0	0	0
## 94	285750	791	1	-19	0	0	0	0	0
## 96	25580	120	-54	-53	1	0	1	0	0
## 97	298230	916	9	-2	0	0	0	0	0
## 100	172120	537	-35	-41	0	0	0	0	0
## 102	270040	717	10	-14	2	2	0	0	0
## 108	166700	363	-34	-56	0	0	0	0	0
## 109	274170	997	15	34	0	0	0	0	0
## 111	226790	717	2	0	0	0	0	0	0
## 112	134640	611	-41	-16	0	0	0	0	0
## 114	328050	707	51	0	1	1	0	0	0

## 115	140090	380	-40	-46	0	0	0	0	0
## 117	157740	440	-31	-35	0	0	0	0	0
## 118	325750	1068	50	67	1	0	1	0	0
## 119	300520	894	37	37	0	0	0	0	0
## 120	465730	1325	-7	-12	1	0	1	0	0
## 121	336600	984	-32	-34	1	0	1	0	0
## 123	951410	1332	98	-7	0	0	0	0	0
## 124	203850	476	-14	-32	1	0	1	0	0
## 125	715390	1923	36	36	1	1	0	0	0
## 126	160350	828	-31	23	0	0	0	0	0
## 128	373180	1246	-32	-14	1	0	1	0	0
## 129	481630	1678	-10	17	0	0	0	0	0
## 130	620720	1789	17	23	0	0	0	0	0
## 132	280830	689	94	39	1	0	1	0	0
## 133	557230	1642	2	11	0	0	0	0	0
## 135	270490	865	83	78	0	0	0	0	0
## 136	307540	1020	-44	-32	0	0	0	0	0
## 138	314100	904	-41	-37	0	0	0	0	0
## 139	368340	1325	-28	-4	1	0	1	0	0
## 140	114540	488	-23	0	2	0	2	0	0
## 141	316200	1089	-37	-21	3	1	2	0	0
## 142	209760	919	46	89	0	0	0	0	0
##	nbumps6	nbumps7	nbumps89	energy	maxenergy				
## 7	0	0	0	1000	7e+02				
## 10	0	0	0	500	5e+02				
## 13	0	0	0	400	4e+02				
## 14	0	0	0	6000	6e+03				
## 16	0	0	0	7000	6e+03				
## 25	0	0	0	6000	4e+03				
## 28	0	0	0	1400	1e+03				
## 29	0	0	0	6000	6e+03				
## 30	0	0	0	600	6e+02				
## 31	0	0	0	6000	2e+03				
## 32	0	0	0	6000	6e+03				
## 33	0	0	0	2000	2e+03				
## 34	0	0	0	1500	6e+02				
## 35	0	0	0	6000	6e+03				
## 36	0	0	0	700	7e+02				
## 37	0	0	0	15700	1e+04				
## 46	0	0	0	0	0e+00				
## 49	0	0	0	1800	1e+03				
## 50	0	0	0	6000	6e+03				
## 52	0	0	0	400	4e+02				
## 53	0	0	0	7000	7e+03				
## 58	0	0	0	800	4e+02				
## 60	0	0	0	1400	7e+02				
## 66	0	0	0	0	0e+00				
## 67	0	0	0	4300	4e+03				
## 68	0	0	0	900	9e+02				
## 71	0	0	0	800	8e+02				
## 72	0	0	0	6000	6e+03				
## 74	0	0	0	0	0e+00				
## 75	0	0	0	4300	4e+03				
## 77	0	0	0	5000	5e+03				

```


## 79      0      0      0    600    3e+02
## 80      0      0      0   6000    6e+03
## 81      0      0      0      0    0e+00
## 84      0      0      0      0    0e+00
## 86      0      0      0      0    0e+00
## 87      0      0      0   6000    6e+03
## 89      0      0      0      0    0e+00
## 91      0      0      0      0    0e+00
## 94      0      0      0      0    0e+00
## 96      0      0      0   6000    6e+03
## 97      0      0      0      0    0e+00
## 100     0      0      0      0    0e+00
## 102     0      0      0    800    5e+02
## 108     0      0      0      0    0e+00
## 109     0      0      0      0    0e+00
## 111     0      0      0      0    0e+00
## 112     0      0      0      0    0e+00
## 114     0      0      0    200    2e+02
## 115     0      0      0      0    0e+00
## 117     0      0      0      0    0e+00
## 118     0      0      0   3000    3e+03
## 119     0      0      0      0    0e+00
## 120     0      0      0   4000    4e+03
## 121     0      0      0   4000    4e+03
## 123     0      0      0      0    0e+00
## 124     0      0      0   3000    3e+03
## 125     0      0      0    300    3e+02
## 126     0      0      0      0    0e+00
## 128     0      0      0   2000    2e+03
## 129     0      0      0      0    0e+00
## 130     0      0      0      0    0e+00
## 132     0      0      0   3000    3e+03
## 133     0      0      0      0    0e+00
## 135     0      0      0      0    0e+00
## 136     0      0      0      0    0e+00
## 138     0      0      0      0    0e+00
## 139     0      0      0   2000    2e+03
## 140     0      0      0   8000    5e+03
## 141     0      0      0   2700    1e+03
## 142     0      0      0      0    0e+00
## [ reached getOption("max.print") -- omitted 719 rows ]

```

BoxPlot

Por último utilizamos boxplot para obtener el gráfico con los outliers:

```
boxplot(mydata.numeric)
```



Dado el gran volumen de datos no usaremos la funcion que los representa con etiquetas ya que de ser así estos se verían representados como una mancha, dado el gran volumen de outliers.